



**T. C.
SIVAS CUMHURİYET ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

**SALDIRI TESPİT VE ÖNLEME SİSTEMLERİNDE KULLANILAN DERİN
ÖĞRENME ALGORİTMALARI**

YÜKSEK LİSANS TEZİ

**Mahmut ATİK
(20209257010)**

**Bilgisayar Mühendisliği Ana Bilim Dalı
Tez Danışmanı: Prof. Dr. Hidayet TAKCI**

**SİVAS
ŞUBAT 2025**

Mahmut ATİK'in hazırladığı ve “**SALDIRI TESPİT VE ÖNLEME SİSTEMLERİNDE KULLANILAN DERİN ÖĞRENME ALGORİTMALARI**” adlı bu çalışma aşağıdaki jüri tarafından **BİLGİSAYAR MÜHENDİSLİĞİ ANA BİLİM DALI**'nda **YÜKSEK LİSANS TEZİ** olarak kabul edilmiştir.

Tez Danışmanı	Prof. Dr. Hidayet TAKCI Sivas Cumhuriyet Üniversitesi	
Jüri Üyesi	Doç. Dr. Halil ARSLAN Sivas Cumhuriyet Üniversitesi	
Jüri Üyesi	Doç. Dr. Halit BAKIR Sivas Cumhuriyet Üniversitesi	

Bu tez, Sivas Cumhuriyet Üniversitesi Fen Bilimleri Enstitüsü tarafından **YÜKSEK LİSANS TEZİ** olarak onaylanmıştır.

Prof. Dr. Nail ALTUNAY
FEN BİLİMLERİ ENSTİTÜSÜ MÜDÜRÜ

Bu tez, Sivas Cumhuriyet Üniversitesi Senatosu'nun 20.08.2014 tarihli ve 7 sayılı kararı ile kabul edilen Fen Bilimleri Enstitüsü Lisansüstü Tez Yazım Kılavuzu (Yönerge)'nda belirtilen kurallara uygun olarak hazırlanmıştır.



Bütün hakları saklıdır.
Kaynak göstermek koşuluyla alıntı ve gönderme yapılabilir.

© Mahmut ATİK, 2025

ETİK

Sivas Cumhuriyet Üniversitesi Fen Bilimleri Enstitüsü, Tez Yazım Kılavuzu Yönergesinde belirtilen kurallara uygun olarak hazırladığım bu tez çalışmada;

- ✓ Bütün bilgi ve belgeleri akademik kurallar çerçevesinde elde ettiğimi,
- ✓ Görsel, işitsel ve yazılı tüm bilgi ve sonuçları bilimsel ahlak kurallarına uygun olarak sunduğumu,
- ✓ Başkalarının eserlerinden yararlanılması durumunda ilgili eserlere, bilimsel normlara uygun olarak atıfta bulunduğumu ve atıfta bulunduğum eserlerin tümünü kaynak olarak gösterdiğimi,
- ✓ Bütün bilgilerin doğru ve tam olduğunu, kullanılan verilerde herhangi bir değişiklik yapmadığımı,
- ✓ Tezin herhangi bir bölümünü, Sivas Cumhuriyet Üniversitesi veya bir başka üniversitede, bir başka tez çalışması olarak sunmadığımı; beyan ederim.

13.01.2025

Mahmut ATİK

KATKI BELİRTME VE TEŞEKKÜR

Bilgi ve deneyimlerinden sürekli yararlandığım, tezin her aşamasında yardımlarını esirgemeyen danışman hocam Prof. Dr. Hidayet TAKCI'ya çok teşekkür ederim.

Bu tez çalışması süresince sabırlı ve müşfik yaklaşımıyla yanımda olan eşim Mihriban KARATAŞ ATİK ve kızım Zümra ATİK'e teşekkür ederim.

Bana bu çalışma süresince moral destek sağlayan tüm arkadaşlarıma şükranlarımı sunarım.



ÖZET

SALDIRI TESPİT VE ÖNLEME SİSTEMLERİNDE KULLANILAN DERİN ÖĞRENME ALGORİTMALARI

Mahmut ATİK

Yüksek Lisans Tezi

Bilgisayar Mühendisliği Anabilim Dalı

Danışman: Prof. Dr. Hidayet TAKCI

2025, 100+xiii sayfa

Güvenlik yaşamın ayrılmaz bir parçasıdır. Siber dünyanın yüksek bir hızla büyüdüğü günümüzde siber güvenlik en önemli güvenlik konularından birisi haline gelmiştir. Bu çalışmada siber güvenliğin ayrılmaz bir parçası olarak kabul edilen Saldırı Tespit Sistemleri (STS) ve Saldırı Engelleme Sistemleri'nde (SES) (İng. IDS/IPS) kullanılan derin öğrenme algoritmaları ele alınmıştır. Başlangıçta bilgi güvenliğinin tanımı yapılmış, ardından Saldırı Tespit ve Saldırı Önleme sistemleri hakkında bilgiler sunulmuş, makine öğrenmesi ve derin öğrenme teknikleri açıklanmıştır. Bu açıklamalar ve tanımlar yapıldıktan sonra STS ve SES teknolojilerinde kullanılan derin öğrenme algoritmaları hakkında ayrıntılı bilgiler verilmiştir. Çeşitli çalışmalar incelenerek hangi saldırı türlerinde hangi derin öğrenme algoritmalarının daha etkili olduğu ve doğru sonuçlar verdiği ortaya konmaya gayret edilmiştir.

Anahtar kelimeler: Ağ, Saldırı Tespiti, Saldırı Önleme, Derin Öğrenme

ABSTRACT

DEEP LEARNING ALGORITHMS USED IN INTRUSION DETECTION AND PREVENTION SYSTEMS

Mahmut ATİK

Master of Science Thesis

Department of Computer Engineering

Supervisor: Prof. Dr. Hidayet TAKCI

2025, 100+xiii pages

Security is an integral part of life. Cyber security has become one of the most important security issues in today's world where the cyber world is growing at a high speed. In this study, deep learning algorithms used in Intrusion Detection Systems (IDS) and Intrusion Prevention Systems (IPS), which is considered an integral part of cyber security, will be examined. At the beginning, information security will be defined, information about Intrusion Detection and Intrusion Prevention systems will be presented, machine learning and deep learning techniques will be explained. After these general explanations and definitions are made, detailed information will be given about the deep learning algorithms used in IDS and IPS technologies. Various studies will be examined, and it will be tried to reveal which deep learning algorithms are more effective in which attack types and give accurate results.

Key Words: Network, Intrusion Detection, Intrusion Prevention, Deep Learning.

İÇİNDEKİLER

	Sayfa
ÖZET	vii
ABSTRACT.....	viii
ŞEKİLLER DİZİNİ.....	xi
ÇİZELGELER DİZİNİ.....	xii
KISALTMALAR DİZİNİ	xiii
1. GİRİŞ (KONU VE LİTERATÜR ÖZETİ)	1
1.1 Tezin Amacı, Kapsamı ve Katkıları	1
1.2 Tezin Bölümleri	4
2. YAKIN ZAMANDA YAPILAN ÇALIŞMALAR.....	6
3. SALDIRI VE SALDIRI TÜRLERİ	61
4. SALDIRI TESPİT VE ENGELLEME SİSTEMLERİ	65
5. SALDIRI TESPİT VE ENGELLEME SİSTEMLERİNDE MAKİNE ÖĞRENMESİ VE DERİN ÖĞRENME ALGORİTMALARININ KIYASLANMASI.....	67
5.1 STS / SES Sistemlerinde Kullanılan Derin Öğrenme Algoritmaları	67
5.1.1 BiRNN Algoritmaları	68
5.1.2 BiLSTM Algoritmaları	69
5.1.3 ESA Algoritmaları	70
5.1.4 CNN-LSTM Algoritmaları	71
5.1.5 DAE Algoritmaları	72
5.1.6 GRU Ağları.....	72
5.1.7 LSTM Algoritmaları	73
5.1.8 RNN Algoritmaları	74
5.2 Derin Öğrenme Algoritmalarının Karmaşıklık Matrisi Değerlendirmeleri	75
5.2.1 Dengesiz Veri Seti Üzerinde Bir, İki ve Üç Katmanlı DÖA'ların Doğruluk Oranlarının Saldırı Ataklarına Göre Karşılaştırılması	76
5.2.2 Dengeli Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA'ların Doğruluk Oranlarının Saldırı Ataklarına Göre Karşılaştırılması	77
6. VERİ SETLERİ/KÜMELERİ.....	79
6.1 KDD Cup 1999	79
6.2 NSL-KDD	80
6.3 UNSW-NB15	81
6.4 CIC-IDS2017	82
6.5 CSE-CIC-IDS2018	85

7. TARTIřMA, SONUÇ VE ÖNERİLER.....	87
KAYNAKLAR	90



ŞEKİLLER DİZİNİ

	Sayfa
Şekil 1 Google Akademikte yayınlanan makale sayıları.....	3
Şekil 2 Bilgi Güvenliğinin Unsurları.....	61
Şekil 3 Bilgi Güvenliğini Sağlama Katmanları	62
Şekil 4 Çeşitli STS/SES Tipleri.....	65
Şekil 5 Aykırılık Türleri	66
Şekil 6 Yapay Zekâ, Makine Öğrenimi ve Derin Öğrenme İlişkisi	67
Şekil 7 BiRNN'in Şematik Yapısı.....	69
Şekil 8 BiLSTM Ağının Yapısı	70
Şekil 9 Evrimsel Sinir Ağı'nın Yapısı	70
Şekil 10 CNN-LSTM Ağ Yapısı	71
Şekil 11 DAE Algoritması'nın Yapısı.....	72
Şekil 12 Geçitli Tekrarlayan Sinir Ağı'nın Yapısı	73
Şekil 13 Uzun Kısa Süreli Bellek Algoritmasının Yapısı	74
Şekil 14 Tekrarlayan Sinir Ağı'nın yapısı.....	74
Şekil 15 Karmaşıklık matrisi ikili sınıflandırma tablosu.....	75

ÇİZELGELER DİZİNİ

Sayfa

Çizelge 1 Yanlış Negatif Oranlarına Odaklanan Çalışmalar.....	57
Çizelge 2 Karmaşıklık matrisi değerlendirme metrik ve formülleri.....	76
Çizelge 3 Ham (Dengesiz) Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA'nın Saldırı Ataklarına Karşı Doğruluk Oranları	76
Çizelge 4 Dengeli Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA'ların Saldırı Ataklarına Karşı Doğruluk Oranları	77
Çizelge 5 KDD Cup 1999 veri setindeki kategorilere göre örnek sayıları.....	80
Çizelge 6 Her Sınıf İçin Eğitim ve Test Alt Veri Setlerindeki Kayıt Sayısı	82
Çizelge 7 CIC-IDS2017'ye Ait Dosya Tanımları	83
Çizelge 8 CIC-IDS2017 Veri Setinin Genel Özellikleri	84
Çizelge 9 CIC-IDS2017 Veri Setinin Sınıf Açısından Örnek Sayıları.....	84
Çizelge 10 CSE-CIC-IDS2018 Veri Setindeki Trafik Türüne Göre Dağılım Oranları..	85

KISALTMALAR DİZİNİ

AE	: Auto Encoder
AÖM	: Aşırı Öğrenme Makineleri
ASTS	: Ağ Saldırı Tespit Sistemi
BGP	: Sınır Ağ Geçidi Protokolü
BSTS	: Bilgisayar Saldırı Tespit Sistemi
ÇKA	: Çok Katmanlı Algılayıcı
ÇÜA	: Çekişmeli Üretken Ağ
DÖ	: Derin Öğrenme
DÖA	: Derin Öğrenme Algortimaları
DSA	: Derin Sisnir Ağı
DVM	: Destek Vektör Makinesi
ESA	: Evrimsel Sinir Ağı
FL	: Federated Learning
GGOK	: Gürültü Giderici Otomatik Kodlayıcı
GNB	: Gaussian Naive Bayes
GPU	: Graphics Processor Unit
GRU	: Geçitli Tekrarlayan Birim
IIoT	: Endüstriyel Nesnelerin İnterneti
IoT	: Nesnelerin İnterneti
KA	: Karar Ağacı
KKT	: Ki Kare Testi
LSTM	: Uzun Kısa Süreli Bellek
LSTM-AE	: Uzun Kısa Süreli Bellek-Otomatik Kodlayıcı
MIMO	: Çoklu Giriş Çoklu Çıkış
NB	: Naive Bayes
ÖÖE	: Özyinelemeli Öznitelik Eliminasyonu
RO	: Rasgele Orman
SDN	: Yazılım Tanımlı Ağlar
SMOTE	: Sentetik Azınlık Aşırı Örnekleme Tekniği
SQLi	: SQL Enjeksiyonu
SSA	: Salp Sürü Algoritması
SSKK	: Spearman Sıralama Korelasyon Katsayısı
STS	: Saldırı Tespit Sistemi
TBYSA	: Tam Bağlantılı Yapay Sinir Ağı
TCP	: İletim Kontrol Protokolü
UDP	: Kullanıcı Datagram Protokolü
XSS	: Siteler Arası Betik Çalıştırma
YSA	: Yinelemeli Sinir Ağı

1. GİRİŞ (KONU VE LİTERATÜR ÖZETİ)

1.1 Tezin Amacı, Kapsamı ve Katkıları

Farklı derin öğrenme mimarilerinin (örneğin, CNN, RNN, LSTM, ve bunların hibrit kombinasyonları) performansını, özellikle sıfıncı gün saldırıları dahil olmak üzere çeşitli ağ saldırılarını tespit etme yetenekleri açısından, çeşitli ağ izinsiz giriş veri setleri (Örneğin CSE-CIC-IDS2018) üzerinde karşılaştırmalı bir analiz yaparak değerlendirildiğinde son yıllardaki çalışmalarda durum nedir? Ayrıca, her mimarinin farklı saldırı türlerine karşı duyarlılığı ve yanlış negatif oranları da incelendiğinde literatürdeki genel görüntü nasıldır? Bu çalışmanın amacı bilgisayar ağına izinsiz girişleri önlemede kullanılan Derin Öğrenme (DÖ) algoritmalarını inceleyerek hangisinin daha üstün olduğunu ve gelecek vadettiğini ortaya koymaktır. Ayrıca ağa yetkisiz girişlerde çok ciddi sorun olan sıfıncı gün saldırılarını önlemede hangi DÖ algoritmalarının daha düşük yanlış negatif oranlar ürettiğini ortaya koymak da bir diğer amaçtır.

Bu çalışma ağ saldırı tespitinde kullanılan DÖ algoritmaları konusunda yapılacak çalışmalara ve araştırmacılara bir yol haritası sunması bakımından önemli katkılar sağlayacaktır.

Tez çalışmasında son on yılda yapılan “saldırı tespit sistemlerinde derin öğrenme tekniklerinin kullanımı” konusuyla ilgili literatür taraması yapılmıştır. Çalışma seçim kriterleri olarak başlıktaki kavramlar, anahtar kelimeler ve çalışmaların güncelliği kullanılmıştır. Başlığında “deep learning/derin öğrenme” ve “intrusion detection/izinsiz giriş tespiti” kavramlarının birlikte kullanıldığı, anahtar kelimelerinde bu iki kavramdan birisi geçen ve çoğunlukla son iki yılda yapılan çalışmalar Google Akademik başta olmak üzere makale veri tabanlarında taranmış ve konuyla ilişkisi yüksek bulunanlar seçilerek özetlenmiştir. Özetlenen tüm çalışmalardaki yöntemler; önemli özellikleri, kullanılan veri setleri ve sonuçları bakımından tablolar halinde sunulmuştur.


Tez araştırması sonucunda ortaya konacak DÖ algoritmaları kullanılarak sıfırıcı gün ataklarını da yüksek doğrulukla tespit edebilecek saldırı tespit ve engelleme sistemlerinin geliştirilmesine katkı sağlanması hedeflenmiştir. Çalışma kapsamında elde edilen bulguların kullanımı bu alandaki ekonomik kayıpları da minimize edebilecektir.

Bilgi ve İletişim Teknolojisi sistemleri ve ağları hem ağ içinden hem de ağ dışından gelen saldırılara açık olan çeşitli hassas kullanıcı verilerini işler [1]. Bu saldırılar manuel olarak ve makine tarafından oluşturulabilir, çeşitleri olabilir ve tespit edilemeyen veri ihlalleriyle sonuçlanan karartmalarla kademeli olarak ilerler. Örneğin, 2016 yılındaki Bitcoin ihlali o günkü değeriyle kabaca 70 milyon dolarlık bir kayıpla sonuçlandı [2]. Bu tür siber saldırılar, zamanla daha karmaşık ve akıllı hale gelmiştir [3]. Bilgisayar ağlarının tasarlanması ile güvenliğinin nasıl sağlanacağı konusu ağ tasarımcılarını meşgul edegelmiştir. Ağ güvenliğinden söz edilirken ağa izinsiz giriş ve verilere yetkisiz erişim de anlaşılmaktadır. Bir sistemi hedef alan izinsiz giriş ve izinsiz kullanım çabalarıyla izinsiz girişi engelleme çabaları başa baş bir biçimde yürümektedir. Bu nedenle saldırganlar sisteme izinsiz girişin ve sistemi izinsiz kullanmanın yeni yollarını bulmaya çalışırken güvenlik tasarımcıları da sistemi güvenli tutmanın yeni yollarını aramayı sürdürmektedirler. Kötü amaçlı siber saldırılar, yeni, esnek ve daha güvenilir bir saldırı tespit sistemine (STS) ihtiyaç duyan ciddi güvenlik sorunları oluşturur. STS, izinsiz girişleri, saldırıları veya güvenlik ilkeleri ihlallerini ağ düzeyinde ve ana bilgisayar düzeyinde altyapıda zamanında tespit etmek ve sınıflandırmak için kullanılan proaktif bir izinsiz giriş tespit aracıdır. Müdahaleci davranışlara dayalı olarak, izinsiz giriş tespiti, ağ tabanlı saldırı tespit sistemi (ASTS) ve bilgisayar tabanlı saldırı tespit sistemi (BSTS) olarak sınıflandırılır. Ağ trafik verilerini kullanan bir STS sistemine ASTS denir. Ağ verileri, anahtarlar, yönlendiriciler ve ağ bağlantıları gibi ağ cihazları tarafından yansıtma yoluyla ağ ekipmanı kullanılarak toplanır ve ağ trafiğinde gizlenen saldırıları ve olası tehditleri belirlemek için analiz edilir. Saldırıları tespit etmek için yerel ana bilgisayarda çalışan çeşitli günlük dosyaları biçimindeki sistem etkinliklerini kullanan bir STS sistemine BSTS denir. Günlük dosyaları yerel sensörler aracılığıyla toplanır. ASTS, ağ trafiği akışlarındaki her bir paket içeriğini incelerken, BSTS, sensör günlüklerini, sistem günlüklerini, yazılım günlüklerini, dosya sistemlerini, disk kaynaklarını, kullanıcı hesap

bilgilerini ve her sistemin diğer bilgilerini içeren günlük dosyalarının içeriğine güvenir. Ağ trafiği akışlarının analizi, yanlış kullanım tespiti, aykırılık tespiti ve durum bilgisi olan protokol analizi kullanılarak yapılır. Kötüye kullanım tespiti, saldırıları tespit etmek için önceden tanımlanmış imzaları ve filtreleri kullanır. İmza veritabanının sürekli güncellenmesi, insan girdilerine dayanır. Bu yöntem bilinen saldırıları bulmada başarılıdır ancak bilinmeyen saldırılarda tamamen etkisizdir. Aykırılık tespiti, bilinmeyen kötü amaçlı etkinlikleri bulmak için yenilikçi mekanizmalar kullanır. Çoğu senaryoda, aykırılık tespiti yüksek yanlış pozitif oranına sahiptir [4]. Bu çalışmada yanlış pozitif oranını azaltmaya dönük ileri sürülmüş başarılı çalışmaların yanında daha önemli olan yanlış negatif oranını azaltmaya dönük başarılı çalışmalara da odaklanılmıştır.

Bilgisayar ağlarının yaklaşık 50-60 yıllık bir geçmişi vardır. Zamanın teknolojilerine paralel olarak ağ güvenliğini sağlamak için önceleri makine öğrenmesi algoritmaları yoğun bir şekilde kullanılırken son yıllarda birtakım avantajları nedeniyle derin öğrenme algoritmalarının bu alanda kullanılmasıyla ilgili araştırmaların sayısı artmıştır.

Son 10 yılda Google Akademik veritabanında yayınlanan ve başlığında “**deep learning**” ve “**intrusion detection**” kavramları birlikte geçen makale sayıları Şekil 1’deki grafikte görülmektedir.



Şekil 1 Google Akademikte yayınlanan makale sayıları

Şekil 1’den görüleceği gibi son 3 yıl içinde yayınlanan makale sayısı toplamı (76) önceki 7 yıl içerisinde yayınlanan makale sayısı toplamının (35) iki katından fazladır.

Son 20 yılda Dergipark platformunda saldırı tespitiyle ilgili 64 adet makale yayınlandığı, bunların 62 tanesinin son 10 yılda olduğu, 50 tanesinin ise son 5 yılda yayınlandığı, son bir yıl içerisinde yayınlanan 10 tanesinin yarısından fazlasının da saldırı tespitinin derin öğrenme yöntemleriyle yapıldığı anlaşılmıştır. Bu durum saldırı tespitinde derin öğrenme yöntemlerinin ne denli önemli hale gelmeye başladığını göstermektedir.

Bilgisayar sistemlerinin güçlenmesi ve performansının artmasıyla da derin öğrenme algoritmalarıyla yapılan çalışmalar yoğunlaşmış durumdadır. Özellikle Grafik İşleme Birimi (GPU) alanında yaşanan gelişmeler derin öğrenme algoritmalarının çalışma hızı ve kapasitesini ciddi oranda arttırmıştır. Araştırmacıların da bu tür donanımlara erişiminin kolaylaştığı günümüzde derin öğrenme algoritmalarının gelişmesinde artışa neden olmuştur.

Bu çalışmada son yıllarda üzerinde yoğun çalışma yapılan derin öğrenme algoritmaları araştırılmış ve algoritmaların karşılaştırmaları verilmiştir.

1.2 Tezin Bölümleri

Tezin her bir bölümünde yapılan çalışmalar bu kısımda kısaca ele alınmıştır. Buna göre:

- Birinci bölümde tezin amacı, kapsamı ve literatüre sağladığı katkılar açıklanmıştır.
- İkinci bölümde saldırı tespitinde kullanılan derin öğrenme yöntemleri hakkında ilgi düzeyi yüksek nitelikteki çalışmalar incelenmiş ve özetlenmiştir. Özellikle son yıllardaki çalışmalar incelenmiş ve son iki yıldaki çalışmalara odaklanılmıştır.
- Üçüncü bölümde bilgi güvenliği kavramı ve unsurları açıklanmış, çeşitli ağ türlerinde karşılaşılan saldırı türleri konusunda ayrıntılı bilgiler verilmiştir.

- Dördüncü bölümde saldırı tespitinde ve saldırı engellenmesinde kullanılan araçlar hakkında bilgi verilmiş, yeni nesil araçların kullandığı teknik ve yöntemler açıklanmıştır.
- Beşinci bölümde yapay zekâ, makine öğrenmesi ve derin öğrenme kavramları hakkında bilgi verilmiştir.
- Altıncı bölümde derin öğrenme algoritmalarıyla birlikte sıkça kullanılan veri setleri ayrıntılı bir şekilde tanıtılmıştır.
- Yedinci bölümde tez çalışmasıyla elde edilen sonuçlar farklı açılardan değerlendirilmiştir. Ayrıca saldırı tespiti alanında çalışma yapacak araştırmacılara çalışmalarında destek olması ve yönlendirme yapması amacıyla çeşitli öneriler sıralanmıştır.

2. YAKIN ZAMANDA YAPILAN ÇALIŞMALAR

Bu tez çalışmasında son 5 yılda yapılan doksanın üzerinde çalışma incelenmiş ve özetlenmiştir. İncelenen çalışmaların büyük çoğunluğu bilimsel dergilerde yayınlanmış makalelerdir. Bunun yanında birkaç tane bildiri ve tez çalışması da incelemeye dâhil edilmiştir.

2019 yılında yapılan çalışmada ASTS’de Evrişimsel Sinir Ağı (ESA) DÖ algoritmasının önemli olduğu ve STS’de kullanılabileceği belirtilmiştir [5].

2024 yılında yapılan çalışmada ağ saldırılarını tespit etmek için iki aşamalı bir derin öğrenme çerçevesi önerilmiştir. Çalışma, geleneksel imza tabanlı tespit mekanizmalarının yeni ve karmaşık saldırıları tanımlamada yetersiz kaldığını belirtmiş ve bu nedenle daha sofistike ve uyarlanabilir yaklaşımların benimsenmesi gerektiğini vurgulamıştır. Çalışma sonucunda önerilen model, Otomatik Kodlayıcılar (AE) ve Uzun Kısa Süreli Bellek (LSTM) ağlarını birleştirerek, CICIDS2017 ve CSE-CICIDS2018 veri setleri üzerinde etkili bir şekilde saldırıları tespit edebilmiştir. Önerilen çerçeve iki aşamadan oluşmaktadır: ilk aşamada, ham ağ verilerini işleyerek hiyerarşik ve soyut temsiller çıkaran derin sinir ağı mimarileri kullanılmıştır. İkinci aşamada ise, dikkat mekanizmaları, transfer öğrenme veya adversarial eğitim gibi tekniklerle ilk tespitler üzerinde ince ayar yapılarak sistemin doğruluğu ve güvenilirliği artırılmıştır. Deneysel sonuçlar, önerilen LSTM-AE modelinin, Evrişimsel Sinir Ağı (ESA) ve Derin Sinir Ağı (DSA) modellerine kıyasla daha yüksek doğruluk, hassasiyet ve F1 skoru verdiğini göstermiştir. Bu model, ağ güvenliğini güçlendirmek için derin öğrenmenin potansiyelini ortaya koymakta ve gelecekteki araştırmalar için çeşitli geliştirme yolları sunmaktadır [6].

2022 yılında yapılan çalışmada derin öğrenme teknikleri kullanılarak ağ aykırılık tespiti üzerine odaklanılmıştır. Çalışma, ağ trafiği verilerini iletim kontrol protokolü (TCP), kullanıcı datagram protokolü (UDP) ve diğer protokol kategorilerine ayırarak her bir

kategoriyi bağımsız olarak ele almıştır. Model, sınıf dengesizliği sorununu çözmek için azınlık sınıflarını dengelemekte kullanılan sentetik azınlık aşırı örnekleme tekniği (SMOTE) kullanmıştır. Çalışma sonucunda önerilen model, UNSW-NB15 veri seti üzerinde test edilmiş ve TCP, UDP, DİĞER ve TÜM kategoriler için sırasıyla 0,85, 0,97, 0,86 ve 0,78 ağırlıklı ortalama f-skorları elde edilmiştir. Çalışma, protokol bazında veri işleme ve sınıflandırmanın, tüm protokollerin birleştirilmesine göre daha iyi sonuçlar verdiğini göstermiştir. Gelecekteki çalışmalar için, modelin adversarial saldırılara karşı dayanıklılığını artırmak ve farklı örnekleme tekniklerini karşılaştırmak gibi önerilerde bulunulmuştur [7].

2022 yılında yapılan çalışma, web uygulamalarında önemli güvenlik riskleri oluşturan SQL Enjeksiyonu (SQLi) ve Siteler Arası Betik Çalıştırma (XSS) saldırılarını tespit etmek için yeni bir özellik çıkarma yöntemi sunmuştur. Geleneksel yöntemlerin yanlış alarm durumlarını yeterince ele almadığı ve bu durumlarda işlevsiz kaldığı belirtilmiştir. Çalışmanın amacı, yanlış alarm seviyelerini düşürmek ve doğru tespit oranını artırmak olarak belirtilmiştir. Araştırma kapsamında, 13.157 SQLi ve XSS türü zararlı istek ve 10.000 normal HTTP isteği kullanılmıştır. Tüm HTTP istekleri aynı web sunucusundan alınmış ve normal isteklerle zararlı isteklerin birbirine yakın olduğu gözlemlenmiştir. Veri ön işleme aşamalarında, veriyi kelimelerle ifade etme ve sayısallaştırma işlemleri birlikte kullanılarak yeni bir yaklaşım sunulmuştur. Sınıflandırma için LSTM, Çok Katmanlı Algılayıcı (ÇKA), ESA, Gaussian Naive Bayes (GNB), Destek Vektör Makinesi (DVM), En Yakın Komşu, Karar Ağacı ve Rastgele Orman (RO) algoritmaları kullanılmış ve sonuçlar doğruluk, hassasiyet, özgüllük ve F1-skoru metrikleri ile değerlendirilmiştir. Çalışmanın bulguları arasında, bazı saldırı vektörlerinin görünürde farklı olsa da ön işlem sonrasında aynı karakteristikte olabileceği, kelimelerin sembolize edilmesinin saldırı vektörünün özelliğinin daha net görülmesini sağladığı ve kelimelerin Öklid uzaklıklarının hesaplanarak özniteliklerin çıkarılmasının başarıyı artırdığı yer almıştır. Bu yöntemin, gerçek zamanlı uygulamalarda kullanılmak üzere umut vaat etmekte olduğu belirtilmiştir [8].

2022 yılında yapılan başka bir çalışmada Android cihazlar için ağ trafiği analizi kullanılarak derin öğrenme tabanlı bir kötücül yazılım tespit sistemi geliştirilmesi amaçlanmıştır. Mobil cihazların artan işlevselliği ve yaygın kullanımı, onları saldırganlar için cazip hedefler haline getirdiği belirtilmiştir. Çalışmada, LSTM tabanlı bir DÖ modeli geliştirilmiş ve bu model, Naive Bayes (NB), RO, DVM, ÇKA, ESA, Yinelemeli Sinir Ağı (YSA) ve Geçitli Tekrarlayan Birim (GTB) gibi diğer modellerle karşılaştırılmıştır. Deneysel sonuçlar, LSTM modelinin %95 doğruluk oranı ile diğer modellere göre daha başarılı olduğunu göstermiştir. Çalışma, mobil cihazların ağ trafiği verilerini kullanarak kötücül yazılımların tespit edilmesine odaklanmakta ve bu alanda Türkçe literatüre katkı sağlamayı hedeflemiştir [9].

2022 yılında yapılan diğer bir çalışma derin öğrenme tekniklerini kullanarak yeni nesil bir güvenlik duvarı geliştirilmesini ele almıştır. Çalışmada, zararlı olabilecek görsellerin web sitelerinden filtrelenmesi hedeflenmiştir. Eğitim sürecinde, derin öğrenme modeli %97,6469 doğruluk ve %87,75526188 F1 skoru vermiştir. Model, mitmproxy aracılığıyla bir vekil sunucu üzerinde çalıştırılarak, ağ trafiğindeki görselleri analiz etmiş ve zararlı içerikleri filtrelemiştir. Çalışmada, özellikle alkollü içeceklerin tanımlanması üzerine odaklanılmış ve bu amaçla geniş bir veri seti oluşturulmuştur. Alkollü içecekler için hazır bir veri seti bulunmadığından, özel bir veri seti oluşturulmuştur. Bu veri seti, internetten Python ile tasarlanan bir web tarayıcı (crawler) yardımıyla toplanmıştır. Yaklaşık 3 milyon etiketsiz görsel elde edilmiştir.

Eğitim süreci boyunca çeşitli hiper-parametreler test edilmiş ve en iyi sonuçlar Adam algoritması kullanılarak elde edilmiştir. Yapılan çalışmada, derin öğrenme ve yapay sinir ağları konularında kapsamlı bir literatür taraması sunulmuş ve uygulama zorlukları ile çözüm önerileri tartışılmıştır [10].

2022 yılında yapılan başka bir çalışmada, Sınır Ağ Geçidi Protokolü (BGP) üzerindeki aykırılıkların tespiti için makine öğrenmesi ve derin öğrenme algoritmalarını birleştiren hibrit bir model önermişlerdir. BGP'nin, internetin temel yönlendirme protokollerinden biri olduğu, otonom sistemler arasında ağ erişilebilirlik bilgilerini yönettiği ve çeşitli

saldırlara maruz kalabileceği, bunun da internet kesintilerine yol açabileceği belirtilmiştir. Çalışmada, BGP aykırılıklarını tespit etmek için KA, RO ve ÇKA algoritmaları kullanılmıştır. Model, dolaylı BGP aykırılıkları ve bağlantı hatası aykırılıklarını doğruluk ve F1-puanı ölçütleriyle değerlendirmiştir. Slammer veri seti üzerinde yapılan testlerde, hibrit modelin %99,47 doğruluk ve %98,85 F1-puanı ile en iyi sonuçları verdiği görülmüştür. Çalışma, RIPE ve Route Views veri toplama sitelerinden elde edilen verilerle gerçekleştirilmiştir. Moscow Blackout, WannaCrypt ve Slammer gibi olaylar sırasında toplanan veriler kullanılarak, önerilen modelin performansı değerlendirilmiştir. Hibrit modelin, diğer TCP/IP protokollerine yönelik siber saldırı tespit sistemlerinde de kullanılabilecek potansiyele sahip olduğu belirtilmiştir. Sonuç olarak, önerilen hibrit modelin, BGP trafiğinde oluşan aykırılıkların tespitinde mevcut çalışmalara göre daha yüksek doğruluk oranları sağladığı belirtilmiştir [11] .

Başka bir çalışma sıfırinci gün saldırılarını tespit etmek ve yanlış pozitif oranlarını azaltmak amacıyla bir Hibrit Saldırı Tespit Sistemi geliştirmeyi hedeflemiştir. Geleneksel STS'lerin, bilinen saldırıları tespit etmek için imza tabanlı ve bilinmeyen saldırıları tespit etmek için aykırılık tabanlı olarak ikiye ayrıldığı belirtilmiştir. Ancak, aykırılık tabanlı sistemlerin genellikle yüksek yanlış pozitif oranlarına sahip olduğu ve bunun da ağın yavaşlamasına ve sürekli insan müdahalesine ihtiyaç duymasına neden olduğu belirtilmiştir. Bu çalışmada, sıfırinci gün saldırılarını tespit etmek ve yanlış pozitif oranlarını azaltmak için özellik seçimi yöntemleri ve veri setinin ince ayarını içeren bir çerçeve önerilmiştir. Çeşitli optimizasyonlar ve modellerle yapılan testler sonucunda, mevcut sistemlerden daha iyi performans gösteren bir model geliştirilmesi hedeflenmiştir. Önerilen model, özellik seçimi, makine öğrenimi algoritmaları, ince ayar ve optimizasyon tekniklerini bir araya getirerek, daha düşük yanlış pozitif oranları ve kabul edilebilir hızda çalışan bir sistem geliştirmeyi amaçlamıştır. İlk testler, önerilen iki aşamalı hibrit modelin umut verici sonuçlar verdiğini göstermiştir [12].

2019 yılında yapılan çalışmada bilgi güvenliğini sağlamak amacıyla STS'lerin performansının artırılması hedeflenmiştir. CICIDS2017 veri seti üzerinde detaylı bir analiz gerçekleştirilmiş ve farklı türdeki saldırılar ikili ve çoklu sınıflandırma için yeniden

düzenlenmiştir. Makine öğrenmesi tekniklerinden Tam Bağlantılı Yapay Sinir Ağı (TBYSA) kullanılarak bir model geliştirilmiş ve bu model TensorFlow-Keras kütüphaneleri ile kodlanmıştır. İkili sınıflandırma, saldırı var veya yok durumunu incelerken, çoklu sınıflandırma saldırı türlerini belirlemeye çalışmıştır. İkili sınıflandırmanın başarısı, yanlış alarm oranlarını azaltmada etkili olmuştur. Çalışma, derin öğrenme yöntemlerinin STS'lerle uyumunu incelemiş ve elde edilen sonuçlar, ikili sınıflandırmada %98 doğruluk oranına ulaşmıştır. Bu sonuçlar, derin öğrenme modellerinin saldırı tespit sistemlerinde etkili bir şekilde kullanılabileceğini göstermiştir [13].

2018 yılında yapılan çalışma bilgi teknolojilerinin hızla gelişmesiyle birlikte ortaya çıkan siber güvenlik tehditlerine karşı derin öğrenme modelleri kullanarak ağ aykırılık tespiti yapmayı amaçlamıştır. Çalışmada, NSL-KDD veri seti kullanılarak bir bilgisayar ağındaki normal akış verileri üzerinde otomatik özellik çıkarımı gerçekleştirilmiş ve bu veriler, derin öğrenme modeli olan otomatik kodlayıcılar ile işlenmiştir. Model, normal ve anormal davranışları ayırt edebilmek için eğitilmiş ve test edilmiştir. Önerilen yöntem, geleneksel saldırı tespit sistemlerinin yetersiz kaldığı sıfırıncı gün saldırılarına karşı daha etkili bir çözüm sunmayı hedeflemiştir. Çalışma, derin öğrenme modellerinin, özellikle ESA ve Gürültü Giderici Otomatik Kodlayıcı (GGOK)'lar kullanarak, ağ trafiğindeki aykırılık durumlarını yüksek başarıyla tespit edebileceğini göstermiştir. Elde edilen sonuçlar, literatürdeki diğer çalışmalarla karşılaştırıldığında, önerilen modelin daha yüksek bir performans sergilediğini ortaya koymuştur [14].

2021 yılında yapılan çalışma, artan siber saldırı tehditlerine karşı makine öğrenmesi tabanlı STS'nin performansını artırmayı hedeflemiştir. CSE-CIC-IDS2018 veri seti üzerinde, öznitelik seçiminin STS performansı üzerindeki etkileri incelenmiştir. Çalışmada Ki-Kare Testi (KKT), Spearman Sıralama Korelasyon Katsayısı (SSKK) ve Özyinelemeli Öznitelik Eliminasyonu (ÖÖE) gibi öznitelik seçim yöntemleri kullanılarak, veri setinin boyutu küçültülmüş ve işlem yükü azaltılmıştır. Bu yöntemlerle oluşturulan yeni veri setleri, çeşitli makine öğrenmesi algoritmaları ile sınıflandırılmış ve performansları karşılaştırılmıştır. Deneysel sonuçlar KKT ve SSKK yöntemlerinin işlem

süresini kısalttığını ancak hata oranını artırdığını göstermiştir. ÖÖE yöntemi ise, uygun ayar parametreleri ile işlem süresini kısaltırken hata oranını da düşürmüştür. Çalışma, doğru ayar parametreleri ile kullanılan ÖÖE öznitelik seçim yönteminin, makine öğrenimi tabanlı STS'lerin başarımları ve performansını artırabileceğini ortaya koymuştur. Gelecekte, saldırı tespitinin başarımlarını artırmak amacıyla, çalışmada birden fazla makine öğrenimi yönteminin tahminlerini birleştiren toplu bir öğrenme modeli önerilmiştir [15].

2022 yılında yapılan çalışmada, nesnelerin interneti (IoT) ortamlarında aykırılık tespiti için derin öğrenme ve makine öğrenmesi algoritmalarının karşılaştırılması amaçlanmıştır. Çalışmada, IoT sistemlerine yönelik çoğaltma, müdahale ve değişiklik saldırılarını tespit etmek için bir model geliştirilmiştir. DVM ve Naive Bayes (NB) gibi klasik makine öğrenmesi algoritmaları ile Uzun Kısa Süreli Bellek (LSTM) gibi derin öğrenme algoritmaları kullanılmıştır. Araştırma, LSTM algoritmasının, aykırılık tespitinde klasik makine öğrenmesi algoritmalarına göre daha yüksek doğruluk ve f1 skorları elde ettiğini göstermiştir. Ancak, LSTM'nin çalışma süresi açısından dezavantajları olduğu da belirtilmiştir. Sonuçlar, LSTM'nin siber güvenlik alanında aykırılık tespiti için etkili bir araç olabileceğini, ancak işlem süresi bakımından klasik yöntemlerin daha avantajlı olduğunu ortaya koymuştur. Çalışmada, IoT güvenliği için derin öğrenme algoritmalarının potansiyeli vurgulanmış ve veri seti dengesinin algoritma performansı üzerindeki etkileri incelenmiştir [16].

2018 yılında yapılan çalışmada, bilgisayar ve internetin günlük yaşamın vazgeçilmez bir parçası haline gelmesiyle birlikte artan siber güvenlik tehditlerine karşı STS'nin performansını artırmak amacıyla makine öğrenmesi ve öznitelik seçim yöntemleri kullanılmıştır. Çalışma, KDDCup99 veri seti üzerinde gerçekleştirilmiş ve Ki-Kare, Bilgi Kazancı, Kazanım Oranı, Gini Katsayısı, OneR, ReliefF, Genetik, İleriye Doğru ve Geriye Doğru Öznitelik Seçimi öznitelik seçim algoritmaları uygulanarak yeni veri setleri elde edilmiştir. Bu yeni veri setleri ile orijinal veri setini karşılaştırmak için en yakın k komşu (K- nn), DVM ve Aşırı Öğrenme Makineleri (AÖM) kullanılarak farklı modeller geliştirilmiştir. Analizler sonucunda, öznitelik seçim yöntemlerinin her üç sınıflama yöntemi için de başarı oranını artırdığı ve modellerin daha hızlı çalışmasını sağladığı

görülmüştür. Ayrıca, AÖM'nin yüksek başarı oranları, hızlı çalışmaları ve basit eğitim algoritmaları nedeniyle çevrimiçi saldırı tespit sistemlerine kolayca entegre edilebileceği ve alternatif bir yöntem olarak kullanılabileceği sonucuna varılmıştır [17].

2020 yılında yapılan çalışmada siber güvenlik tehditlerine karşı ağ aykırılık tespiti için DÖ tabanlı bir model geliştirilmiştir. Çalışma hem bilinen ağ saldırılarını hem de sıfıncı gün saldırılarını tespit etmeyi amaçlamış ve bu amaçla NSL-KDD veri seti kullanılmıştır. Geliştirilen model, ESA Tabanlı Gürültü Giderici Seyrekleştirilmiş Yığın Otomatik Kodlayıcı (ESA-GGSYOK) olarak adlandırılmıştır. Model, swish aktivasyon fonksiyonu ve SGDW optimizasyon algoritması kullanılarak, diğer makine öğrenimi ve DÖ modellerine kıyasla daha yüksek performans elde etmiştir. Çalışma, siber saldırıların engellenmesine yönelik mevcut uygulamaların, veri tabanlarında kayıtlı olan saldırı tiplerine karşı yeterli başarı gösterirken, sıfıncı gün saldırılarına karşı yetersiz kaldığını ortaya koymuştur. Bu nedenle, aykırılık tabanlı saldırı tespit sistemlerinin geliştirilmesi gerektiği vurgulanmıştır. Çalışmada, önerilen modelin, bilinen ve sıfıncı gün saldırılarının tespitinde mevcut yöntemlerden daha başarılı olduğu gösterilmiştir [18].

2022 yılında yapılan çalışmada, ağ saldırılarını erken tespit etmek için Çekişmeli Üretken Ağ (ÇÜA) tabanlı tekli bir sınıflandırıcı geliştirilmiştir. Çalışmada, ağ güvenliğinde erken saldırı tespitinin önemine vurgu yapılarak, geleneksel yöntemlerin oturum sonuna kadar beklemesi gerektiği için saldırıları zamanında tespit edemediği belirtilmiştir. Bu sorunu çözmek için önerilen yöntem paket verilerini kullanarak paketlerin kötü niyetli olup olmadığını belirlemeye çalışmıştır. Ancak, bu yaklaşım normal paketlerin yanlışlıkla saldırı olarak algılanma olasılığını artırmıştır.

Bu sorunu aşmak için, LSTM-DSA modeli ile eğitilmiş orijinal bir eğitim veri setinden yanlış sınıflandırılmış veriler kullanılarak ÇÜA için yeni bir eğitim veri seti oluşturulmuştur. ÇÜA, alınan paketin LSTM-DSA tarafından doğru bir şekilde sınıflandırılıp sınıflandırılmayacağını belirleme yeteneğine sahip olmuştur. ÇÜA, paketi doğru sınıflandırılmadığında, tespit işlemi iptal edilmiş ve bir sonraki paket alındığında tekrar denenmiştir. Çeşitli deneyler, önerilen yöntemin oturum sonlanmadan önce

saldırıları çok erken tespit edebildiğini ve mevcut yöntemlerle benzer bir tespit performansı sağladığını göstermiştir [19].

2024 yılında yapılan çalışmada, ağ saldırılarını tespit etmek için iki aşamalı bir derin öğrenme çerçevesi geliştirilmiştir. Çalışma, geleneksel imza tabanlı tespit mekanizmalarının yeni ve karmaşık saldırıları tanımlamada yetersiz kaldığını belirterek, derin öğrenme yöntemlerinin ağ güvenliğini güçlendirmedeki potansiyelini vurgulamıştır. Önerilen çerçeve, AE ve LSTM ağlarını birleştirerek, CICIDS2017 ve CSE-CICIDS2018 veri setleri üzerinde test edilmiştir. İlk aşamada, derin sinir ağları kullanılarak ham ağ verileri işlenmiş ve potansiyel saldırı desenleri tanımlanmıştır. İkinci aşamada ise, dikkat mekanizmaları ve transfer öğrenme gibi teknikler kullanılarak ilk tespitler iyileştirilmiş ve sistemin doğruluğu artırılmıştır. İlgili çalışma, önerilen modelin, bilinen ve daha önce görülmemiş ağ saldırılarını tespit etmede üstün performans sergilediğini göstermiştir. Bu iki aşamalı derin öğrenme çerçevesi, ağ trafiğindeki aykırılık ve saldırıların daha doğru bir şekilde tespit edilmesini sağlamış ve yanlış pozitif oranlarını minimize etmiştir [20].

Truong ve Le tarafından 2024 yılında yapılan çalışmada, Metaverse için güvenlik çözümleri incelenmiş ve blockchain ile makine öğrenmesi teknikleri kullanılarak bir saldırı tespit sistemi geliştirilmiştir. Çalışma, Metaverse'ün geniş ölçekli ve merkezi olmayan yapısının getirdiği güvenlik zorluklarını ele almıştır. Yazarlar, Metaverse'ün cihaz, uç, bulut ve uygulama katmanlarından oluşan dört katmanlı bir mimarisini sunmuş ve her katmanın güvenlik mekanizmalarını tartışmıştır. Önerilen çözüm, MSecureChain adlı blockchain tabanlı bir federated learning (FL) çerçevesi olmuştur. Bu çerçeve, kullanıcıların Metaverse platformunu korumasına ve Metaverse tokenları kazanmasına olanak tanımıştır. Çalışma, MSecureChain'in zehirlenme saldırılarına karşı yüksek verimlilik gösterdiğini ve %99 doğruluk oranıyla saldırı tespiti yapabildiğini ortaya koymuştur. Ayrıca, çalışmanın merkezi olmayan yapısı sayesinde tek nokta hatası (SPoF) ve üçüncü taraf manipülasyonlarına karşı dirençli olduğu belirtilmiştir. Makale, Metaverse güvenliği için açık araştırma konularını ve gelecekteki araştırma yönlerini de tartışmıştır. Yazarlar, Metaverse'ün henüz gelişim aşamasında olması nedeniyle güvenlik

verilerinin eksikliğine dikkat çekmiş ve bu alanda daha fazla araştırma yapılması gerektiğini vurgulamıştır [21].

Zhao ve arkadaşları, 2024 yılında yaptıkları çalışmada, derin öğrenme tabanlı bir STS geliştirmişlerdir. Araştırma, karmaşık ağ trafiğiyle başa çıkmada geleneksel STS teknolojilerinin sınırlamalarını ele almış ve ESA-Focal adlı yeni bir model önermiştir. Bu model, eşik konvolüsyon ve SoftMax çok sınıflı sınıflandırma teknolojisini kullanarak anormal trafik tespitinin doğruluğunu ve verimliliğini artırmayı hedeflemiştir. Çalışmada, ESA-Focal modelinin açık veri setleri üzerinde iyi performans gösterdiği ve doğal ağ ortamında uygulanabilirliğini kanıtladığı belirtilmiştir. Model, NSL-KDD veri seti kullanılarak test edilmiş ve geleneksel yöntemlerle karşılaştırıldığında daha yüksek doğruluk, kesinlik, geri çağırma ve F1 skoru elde etmiştir. Ayrıca, Focal Loss fonksiyonunun kullanımı, modelin dengesiz veri setleriyle başa çıkma yeteneğini önemli ölçüde artırmıştır. Sonuç olarak, bu çalışma, derin öğrenmenin ağ güvenliği alanındaki potansiyelini vurgulamış ve gelecekteki araştırmalar için yeni bir perspektif sunmuştur. Araştırmacılar, ESA mimarilerini geleneksel makine öğrenimi algoritmalarıyla birleştiren hibrit modellerin, saldırı tespitinde daha yüksek doğruluk ve verimlilik sağlayabileceğini öne sürmüştür [22].

Sanagana ve Tummalachervu, 2024 yılında yaptıkları çalışmada, bulut bilişim ortamını güvence altına almak için derin öğrenme tabanlı bir STS geliştirmiştir. Çalışma, bulut bilişimin işletmelerin çalışma şeklini devrim niteliğinde değiştirdiğini, ancak büyük miktarda verinin işlenmesi ve depolanması nedeniyle güvenlik endişelerinin arttığını belirtmiştir. Bu bağlamda, bulut altyapısını siber tehditlere karşı korumak için gelişmiş aykırılık tespit teknikleri ve makine öğrenimi algoritmalarını kullanan STS'lerin önemine vurgu yapılmıştır. Önerilen yöntem, Salp Sürü Algoritması (SSA) tabanlı özellik seçimi ile Derin Öğrenme tabanlı Saldırı Tespit (SSAFS-DLID) modelini içermektedir. Bu model, bulut altyapısındaki aykırılıkları ve potansiyel güvenlik ihlallerini etkili bir şekilde tespit etmek için LSTM sınıflandırmasını kullanmış ve Adam optimizasyon algoritması ile eğitim sürecinde etkili yakınsama sağlamıştır. Çalışma, SSA'nın büyük veri setlerinden önemli özellikleri seçerek hesaplama karmaşıklığını ve boyutunu

azalttığını göstermiştir. Deneysel çalışmalar, SSAFS-DLID yönteminin bulut altyapılarında saldırıları %99,71 doğrulukla tespit etmede etkili olduğunu ortaya koymuştur. Bu model, bulut bilişim sistemlerinin güvenlik ortamlarını güçlendirmede umut verici bir potansiyel sergilemiştir [23].

Liao ve arkadaşlarının 2024 yılında yaptıkları çalışmada, IoT için derin öğrenme tabanlı STS incelenmiştir. IoT'nin geniş uygulama alanları nedeniyle, bu cihazların topladığı ve ilettiği büyük miktarda kullanıcı verisinin güvenliğini sağlamak önemli bir sorun olarak ele alınmıştır. DÖ modelleri, büyük veri hacimlerini işleyebilme ve karmaşık desenleri çıkarabilme yetenekleri sayesinde, geleneksel kural tabanlı STS'lere göre daha etkili çözümler sunmuştur. Makale, derin öğrenme tabanlı STS'lerin IoT'de kullanımını özetlemiş, derin öğrenme modelleri, veri setleri, özellik çıkarma ve sınıflandırıcılar, veri ön işleme teknikleri ve modellerin deneysel tasarımı gibi konuları detaylı bir şekilde karşılaştırmış ve analiz etmiştir. Ayrıca, derin öğrenme modelleriyle ilgili zorluklar ve sorunlar ile bu alandaki araştırmacılara yardımcı olacak öneriler sunulmuştur. Bu öneriler arasında hibrit modellerin kullanımı, veri dengesizliği sorunlarının çözülmesi, etkili özellik seçimi ve çıkarımı, özelleştirilmiş veri setleri, çapraz ve çok modlu öğrenme bulunmaktadır [24].

Nabi ve Zhou'nun 2024 yılında yaptıkları çalışmada, siber güvenlik alanında STS geliştirmek amacıyla boyut indirgeme tekniklerinin etkisi incelenmiştir. Araştırmacılar, yüksek boyutluluk sorununu ele alarak sınıflandırıcıların performansını artırmayı hedeflemişlerdir. Çalışmada, NSL-KDD veri seti kullanılarak çeşitli denemeler yapılmış ve J48 algoritması ile %79,1 doğruluk oranı elde edilmiştir. Boyut indirgeme tekniklerinden Rastgele Projeksiyon (RP) ve Temel Bileşen Analizi (TBA) incelenmiş, RP'nin daha hızlı ve etkili olduğu görülmüştür. PART algoritması, RP ile %82,0 doğruluk oranına ulaşarak en iyi performansı göstermiştir. Bu bulgular, siber güvenlik alanında daha etkili ve verimli saldırı tespit sistemleri geliştirilmesine katkı sağlamıştır. Özellikle, RP tekniği, sınıflandırıcıların doğruluğunu artırırken eğitim süresini de azaltmıştır. Makalede, RP'nin, TBA'ya kıyasla daha etkili olduğu ve daha düşük yanlış pozitif oranları sağladığı belirtilmiştir. Örneğin, PART algoritması, RP uygulandıktan sonra

%82,0 doğruluk oranına ulaşmış ve yanlış pozitif oranı da düşmüştür. Bu bulgular, RP'nin STS'lerin doğruluğunu artırırken yanlış pozitif oranını da düşürdüğünü göstermektedir [25].

Yaras ve Dener'in 2024 yılında yaptıkları çalışmada, IoT tabanlı ağlarda siber saldırıların, özellikle DDoS saldırılarının tespit edilmesi için yeni bir hibrit derin öğrenme algoritması geliştirilmiştir. Araştırmacılar, büyük veri ortamında ağ trafiğini analiz ederek saldırıları tespit etmeyi amaçlamışlardır. Çalışma, PySpark ve Apache Spark kullanılarak Google Colaboratory ortamında gerçekleştirilmiştir. Keras ve Scikit-Learn kütüphaneleri kullanılarak, 'CICIoT2023' ve 'TON_IoT' veri setleri üzerinde model eğitilmiş ve test edilmiştir. Veri setlerindeki özellikler, korelasyon yöntemiyle azaltılmış ve önemli özelliklerin teste dahil edilmesi sağlanmıştır. Bir boyutlu ESA ve LSTM kullanılarak hibrit bir derin öğrenme algoritması tasarlanmıştır. Geliştirilen yöntem, on farklı makine öğrenmesi ve derin öğrenme algoritması ile karşılaştırılmıştır. Çalışmanın sonucunda, 'CICIoT2023' veri setinde ikili sınıflandırma için %99,995 ve çoklu sınıflandırma için %99,96 doğruluk oranı elde edilmiştir. 'TON_IoT' veri setinde ise ikili sınıflandırma başarı oranı %98,75 olarak kaydedilmiştir. Bu sonuçlar, önerilen hibrit algoritmanın geleneksel yöntemlere göre daha yüksek doğruluk sağladığını göstermiştir [26].

Shankar ve arkadaşlarının 2024 yılında yaptıkları çalışmada, ağ sistemlerinde siber saldırıları tespit etmek için yapay zekâ tabanlı yeni bir DÖ optimizasyonu yaklaşımı geliştirilmiştir. Araştırmacılar, ağ trafiğini izleyerek saldırıları daha etkili bir şekilde tanımlamayı amaçlamışlardır. İlk olarak, veri kalitesini artırmak için normalizasyon ve standardizasyon kullanılarak ön işleme yapılmıştır. Ardından, Corporate Hierarchy Optimization (CHO) tekniği ile veri tabanlarından önemli özellikler seçilmiştir. Önerilen yöntem, altın kartal optimizasyonuna dayalı kendini yapılandıran çok katmanlı algılayıcı ile bulanık sistem (GEO-SMPIF) kullanarak ağ saldırılarını sınıflandırmıştır. NSL-KDD ve UNSW-NB15 veri setleri üzerinde yapılan deneylerde, önerilen yöntemin mevcut yaklaşımlara kıyasla daha yüksek doğruluk ve daha düşük yanlış alarm oranları sağladığı gösterilmiştir. NSL-KDD veri setinde %99,78 tespit oranı, %99,99 doğruluk ve 0,04 yanlış alarm oranı elde edilmiştir. UNSW-NB15 veri setinde ise %99,70 tespit oranı,

%99,97 doğruluk ve 0,065 yanlış alarm oranı kaydedilmiştir. Bu sonuçlar, önerilen yöntemin ağ saldırılarını tespit etmede daha etkili olduğunu göstermiştir [27].

Turukmane ve Devendiran'ın 2024 yılında yaptıkları çalışmada, ağ tabanlı saldırıların tespit edilmesi için makine öğrenimi tabanlı bir sistem olan M-MultiSVM geliştirilmiştir. Araştırmacılar, ağ trafiğindeki saldırıları daha etkili bir şekilde tespit etmek amacıyla CSE-CIC-IDS-2018 ve UNSW-NB15 veri setlerinden elde edilen verileri kullanmışlardır. İlk olarak, veriler eksik değerlerin giderilmesi ve Min-Max normalizasyonu ile ön işleme tabi tutulmuştur. Sınıf dengesizliği sorununu çözmek için Gelişmiş Sentetik Azınlık Aşırı Örnekleme Tekniği (ASmoT) kullanılmıştır. Özellik çıkarımı aşamasında, Modifiye Tekil Değer Ayrışımı (M-SvD) ile temel, içerik ve trafik özellikleri elde edilmiştir. Bu özellikler, Karşıt Tabanlı Kuzey Atmaca Optimizasyonu (ONgO) algoritması ile optimize edilmiştir. Son olarak, farklı saldırı türleri, Mud Ring destekli çok katmanlı destek vektör makinesi (M-MultiSVM) ile sınıflandırılmış ve hiperparametreler Mud Ring optimizasyon algoritması ile ayarlanmıştır. Önerilen sistem, CSE-CIC-IDS-2018 veri seti ile %99,89 doğruluk oranı ve UNSW-NB15 veri seti ile %97,535 doğruluk oranı elde etmiştir. Bu sonuçlar, önerilen modelin ağ saldırılarını tespit etmede etkili olduğunu göstermiştir [28].

Roshan ve arkadaşları tarafından 2024 yılında yapılan çalışmada, DÖ tabanlı ASTS'de karşılaşılan adversarial saldırılara karşı savunma yöntemleri incelenmiştir. Araştırmacılar, ASTS'nin kendisinin saldırıya uğraması durumunda nasıl savunulabileceğini araştırmışlardır. Çalışmada, Fast Gradient Sign Method (FGSM), Jacobian Saliency Map Attack (JSMA), Projected Gradient Descent (PGD) ve Carlini & Wagner (C&W) gibi dört güçlü adversarial saldırı tekniği uygulanmıştır. Bu saldırıların ASTS üzerindeki etkileri çeşitli performans metrikleri kullanılarak analiz edilmiştir. Ayrıca, ASTS'nin dayanıklılığını artırmak için üç savunma stratejisi, yani Adversarial Eğitim (AT), Gaussian Veri Artırma (GDA) ve Yüksek Güven (HC) stratejileri uygulanmıştır. Çalışma, gerçek zamanlı ağ trafiği üzerinde bu savunma yöntemlerinin etkinliğini göstermiştir. Sonuç olarak, önerilen savunma stratejilerinin, ASTS'nin adversarial saldırılara karşı dayanıklılığını artırdığı ve modelin güven skorlarını

iyileştirdiği bulunmuştur. Bu araştırma, siber güvenlik alanında adversarial makine öğrenimi ve savunma stratejileri üzerine çalışan araştırmacılar için kapsamlı bir arka plan sağlamıştır [29].

Aljehane ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ güvenliği için derin öğrenme destekli bir STS geliştirmiştir. Araştırmacılar, Golden Jackal Optimizasyon Algoritması (GJOA) ile derin öğrenme tabanlı bir yaklaşım olan GJOADL-IDSNS tekniğini tanıtmışlardır. Bu sistem, ağdaki saldırıları etkili bir şekilde tanımlamak ve sınıflandırmak amacıyla tasarlanmıştır. İlk olarak, veri normalizasyonu yapılarak veriler uygun bir formata dönüştürülmüştür. GJOA tabanlı özellik seçimi (GJOA-FS) yöntemi kullanılarak en uygun özellik alt seti seçilmiştir. Daha sonra, dikkat tabanlı çift yönlü uzun kısa süreli bellek (A-BiLSTM) modeli uygulanmıştır. A-BiLSTM modelinin hiperparametre ayarlamaları için salp sürü algoritması (SSA) kullanılmıştır. Geliştirilen yöntem, çeşitli veri setleri üzerinde test edilmiş ve diğer modellere kıyasla daha iyi performans gösterdiği bulunmuştur. Bu çalışma, ağ güvenliğini sağlamak için etkili bir STS sunarak, siber güvenlik alanında önemli bir katkı sağlamıştır [30].

Osa ve arkadaşları, 2024 yılında yaptıkları çalışmada, bilgisayar ağlarında saldırı tespit etmek için derin sinir ağı tabanlı bir yaklaşımın tasarımını ve uygulanmasını ele almıştır. Araştırmacılar, siber altyapılara olan bağımlılığın artmasıyla birlikte, mevcut saldırı tespit sistemlerinden daha iyi performans gösteren modeller geliştirme ihtiyacını vurgulamışlardır. Çalışmada, CICIDS 2017 veri setindeki veri dengesizliğini ele almak için SMOTE ve Rastgele Örneklemme teknikleri uygulanmıştır. Deneyler, Google Colaboratory ortamında tek bir Jupyter defteri üzerinde gerçekleştirilmiş ve gerekli yazılım kütüphaneleri (seaborn, pandas, matplotlib, keras, TensorFlow) kullanılmıştır. Modelin eğitim ve doğrulama aşamalarında doğruluk ve kayıp performans metrikleri değerlendirilmiştir. Sonuçlar, derin öğrenme modelinin CICIDS 2017 veri seti ile saldırıları %99,68 doğruluk oranı ve 0,0102 kayıp değeri ile mükemmel bir şekilde tahmin ettiğini göstermiştir. Bu çalışma, bilgisayar ağlarında saldırı tespiti için derin sinir ağı tabanlı bir modelin etkinliğini kanıtlamıştır [31].

Saleh ve arkadaşları, 2024 yılında yaptıkları çalışmada, kablosuz sensör ağları (WSN) için saldırı tespit sistemlerinde makine öğrenimi tekniklerini kullanarak bir girişim tespit modeli geliştirmeyi amaçlamışlardır. Çalışma, özellikle Gaussian Naive Bayes (GNB) ve Stochastic Gradient Descent (SGD) algoritmalarını kullanarak WSN'lerdeki siber saldırıları tespit etmeyi hedeflemiştir. Veri boyutunu azaltmak ve model doğruluğunu artırmak için ana bileşen analizi (PCA) ve tekil değer ayrışımı (SVD) gibi özellik seçimi yöntemleri uygulanmıştır. Önerilen SG-IDS modeli, WSN-DS veri setinde %96 doğruluk oranı elde etmiş ve diğer modern algoritmalarından daha iyi performans göstermiştir. IoMT veri seti üzerinde yapılan değerlendirmede, SG-IDS modeli %87 doğruluk ve %100 kesinlik oranı ile başarılı bir performans sergilemiştir. Çalışma, WSN'lerdeki saldırı tespit performansını artırmak için özellik seçimi ve makine öğrenimi algoritmalarının entegrasyonunun önemini vurgulamıştır. Gelecekteki çalışmalar için, modelin daha geniş veri setleri ve farklı saldırı türleri üzerinde test edilmesi önerilmiştir. Bu çalışma, WSN'lerdeki güvenlik açıklarını tespit etmek için makine öğrenimi tekniklerinin nasıl kullanılabileceğine dair kapsamlı bir yaklaşım sunmuştur. Özellikle, veri boyutunu azaltma ve model doğruluğunu artırma konularında önemli katkılar sağlamıştır [32].

Spiekermann ve arkadaşları, 2024 yılında yaptıkları çalışmada, sanal ağlarda ağ saldırı tespiti için DÖ tekniklerinin kullanımını ele almışlardır. Sanal ağlar, esneklik ve ölçeklenebilirlik sağlarken, güvenlik açısından önemli zorluklar yaratmaktadır. Fiziksel ağlarda kullanılan paket analizi yöntemleri, sanal ağlarda doğrudan uygulanamaz çünkü sanal ağlar kapsülleme kullanmaktadır. Bu kapsülleme yöntemleri arasında VXLAN, EVPN ve NVGRE gibi protokoller yer alır. Çalışma, sanal ağlarda saldırı tespitinin performansını ve etkinliğini analiz etmiş ve DÖ tekniklerinin bu alandaki zorlukları nasıl ele alabileceğini incelemiştir. Deneyler, sanal ağlarda saldırı tespitinin fiziksel ağlara göre daha düşük doğruluk oranlarına sahip olduğunu göstermiştir. Bu durum, sanal ağların dinamik yapısı ve kapsülleme protokollerinin getirdiği karmaşıklıklarla ilişkilendirilmiştir. Çalışma, sanal ağlarda saldırı tespiti için daha fazla araştırma yapılması gerektiğini vurgulamış ve DÖ modellerinin sanal ağ trafiği üzerinde nasıl daha iyi performans gösterebileceğine dair önerilerde bulunmuştur. Özellikle, sanal ağ protokollerinin getirdiği ek yük ve değişkenliğin, saldırı tespit sistemlerinin etkinliğini

nasıl etkilediği üzerinde durulmuştur. Makale, sanal ağlarda saldırı tespiti için derin öğrenme modellerinin adaptasyonunun önemine dikkat çekmiş ve bu alanda daha fazla araştırma yapılmasının gerekliliğini ortaya koymuştur [33].

Ravi 2024 yılında yaptığı çalışmada, akıllı sağlık hizmetleri işletmelerinde ağ tabanlı saldırı tespiti için DÖ tabanlı bir yaklaşımı ele almıştır. Çalışma, ağ saldırılarını önlemek amacıyla ASTS'nin önemini vurgulamıştır. Son yıllarda, derin öğrenme yöntemlerinin ASTS için başarılı bir şekilde kullanıldığı belirtilmiştir. Ancak, ağ bağlantılarından doğru özellikleri bulmanın zorlu bir görev olduğu ifade edilmiştir. Bu çalışmada, ağ yükünü kullanarak saldırı tespiti için optimal özellikleri çıkaran çok boyutlu dikkat tabanlı bir DÖ yaklaşımı önerilmiştir. Önerilen yaklaşım, yükteki her kelimeyi 100 boyutlu bir özellik vektörüne dönüştüren bir gömme işlemi içermekte ve bu gömme, saldırı sınıflandırması için optimal özellikleri çıkarmak amacıyla dikkat mekanizması ile bir ESA ve LSTM katmanlarını takip etmektedir. ESA ve LSTM katmanlarının özellikleri birleştirilmiş ve saldırı tespiti için tam bağlantılı katmanlara aktarılmıştır. Önerilen yaklaşım, KISTI kurumsal ağ yükü veri setinde %99 doğruluk göstermiştir. Ayrıca, KDDCup-99, CICIDS-2017, WSN-DS ve UNSW-NB15 gibi ağ tabanlı veri setlerinde de yüksek doğruluk oranları elde edilmiştir. Çalışma, önerilen ASTS'nin farklı ağ ortamlarından gelen saldırıları tespit etmede sağlam ve genelleştirilebilir olduğunu göstermiştir. Önerilen model, diğer derin öğrenme tabanlı yöntemlere göre tüm deneylerde daha iyi performans sergilemiş ve KISTI veri seti kullanılarak yapılan mevcut çalışmaya göre %5 doğruluk artışı sağlamıştır [34].

Maddu ve Rao, 2024 yılında yaptıkları çalışmada, Yazılım Tanımlı Ağlar (SDN) için derin öğrenme tabanlı bir ağ saldırı tespit ve önleme sistemi geliştirmiştir. SDN, geleneksel ağ yapılarının yerine kullanılan modern bir ağ stratejisi olup, merkezi kontrol yapısı nedeniyle tek nokta arızası riskini artırmaktadır. Bu durum, sistemleri Dağıtılmış Hizmet Reddi (DDoS), DoS, sahtecilik ve API istismarı gibi çeşitli ağ saldırılarına karşı savunmasız hale getirmektedir. Çalışmada, veri dengesizliği sorununu aşmak için Derin Evrişimsel Çekişmeli Üretken Ağlar (DCGAN) kullanılarak veri artırımı yapılmıştır. Ardından, CenterNet tabanlı bir yaklaşımla özellikler çıkarılmış ve ResNet152V2 ile

Slime Mold Algoritması (SMA) kullanılarak saldırılar sınıflandırılmıştır. Saldırı tespit edildikten sonra, önerilen savunma modülü etkinleştirilerek ağ bağlantısı hızla eski haline getirilmiştir. Çeşitli deneyler, önerilen sistemin ağ saldırılarını başarıyla tespit edip önleyebildiğini göstermiştir. Bu çalışma, SDN ve IoT tabanlı ağlarda güvenliği artırmak için DÖ tekniklerinin etkinliğini vurgulamıştır. Makale, SDN'nin IoT cihazlarıyla birlikte kullanıldığında karşılaştığı güvenlik tehditlerini ele almıştır. Mirai botnet gibi kötü amaçlı yazılımlar, IoT cihazlarını hedef alarak SDN kontrolcüsünü zararlı ağ trafiğiyle aşırı yükleyebilir. Bu tür saldırılar, ağın tamamen kapanmasına neden olabilir. Çalışma, SDN'nin bu tür tehditlere karşı savunmasızlığını azaltmak için derin öğrenme tabanlı bir yaklaşım önermiştir. Önerilen sistem, DCGAN ile veri artırımı yaparak veri dengesizliği sorununu çözmüş ve CenterNet tabanlı bir yöntemle özellik çıkarımı yapmıştır. ResNet152V2 ve SMA kullanılarak saldırılar sınıflandırılmış ve tespit edilen saldırılar için savunma modülü devreye sokulmuştur. Deney sonuçları, önerilen sistemin yüksek doğruluk oranlarıyla saldırıları tespit edebildiğini ve etkili bir şekilde önleyebildiğini göstermiştir [35].

Kumar ve arkadaşları, 2024 yılında yaptıkları çalışmada, akıllı şehirlerde ağ güvenliğini artırmak amacıyla Derin Artık Konvolüsyonel Sinir Ağı (DCRNN) tabanlı bir STS önermiştir. Geleneksel STS'ler, kullanıcı aktivitelerinin ayırt edici bilgilerini yeterince çıkaramadıkları için yüksek yanlış alarm oranı, sınırlı genelleme kapasitesi ve yavaşlık gibi sorunlarla karşılaşmaktadır. Bu çalışmada, DCRNN modeli, İyileştirilmiş Gazelle Optimizasyon Algoritması (IGOA) ile optimize edilmiştir. Ayrıca, gereksiz özellikleri veri setinden çıkarmak için Yeni İkili Çekirge Optimizasyon Algoritması (NBGOA) kullanılmıştır. UNSW-NB15, Ciccddos2019 ve CIC-IDS-2017 veri setleri üzerinde yapılan deneyler, önerilen sistemin sınıflandırma doğruluğu ve işlem süresi açısından mevcut modellerden daha iyi performans gösterdiğini ortaya koymuştur. Sonuçlar, önerilen yaklaşımın çeşitli saldırıları etkili ve doğru bir şekilde tanımladığını göstermiştir. Bu çalışma, ağ güvenliğini artırmak için derin öğrenme ve optimizasyon algoritmalarının etkin bir şekilde kullanılabileceğini göstermiştir. Gelecekteki çalışmaların, önerilen modellerin aşırı öğrenme ve veri seyrekliği sorunlarına odaklanarak saldırı tespit

performansını daha da artırmak için yeni kümeleme tekniklerini içerebileceği belirtilmiştir [36].

Ali ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ güvenliğini güçlendirmek amacıyla, BERT tabanlı bir modelin ve ÇKA kullanılarak sınıflandırma görevlerini geliştirmeyi hedefleyen bir yaklaşımı tanıtmıştır. Dijital ortamın sürekli evrim geçirmesiyle birlikte, güçlü ve etkili STS mekanizmalarına duyulan ihtiyaç artmaktadır. Bu çalışmada, BERT'in dil işleme yetenekleri ve ÇKA'nın sınıflandırma gücü birleştirilerek, ağ trafiğindeki aykırılıkların ve saldırıların tespit edilmesi amaçlanmıştır. Çalışma, CIC-IDS 2017, UNSW-NB 2015 ve NSL-KDD 2009 gibi yaygın olarak kabul gören veri setleri üzerinde test edilmiştir. Sonuçlar, önerilen yöntemin yüksek doğruluk, hassasiyet, geri çağırma ve F1-skoru ile üstün performans sergilediğini göstermiştir. Bu yaklaşım, özellikle sınıf dengesizliği gibi zorlukların üstesinden gelmede etkili olup, ağ güvenliği alanında önemli bir katkı sağlamıştır. Gelecekteki çalışmaların, bu yöntemin daha geniş veri setleri üzerinde test edilmesi ve gerçek dünya uygulamalarında ölçeklenebilirliğinin artırılması üzerine odaklanabileceği belirtilmiştir [37].

Sharma ve arkadaşları, 2024 yılında yaptıkları çalışmada, IoT ağlarında saldırıların tespit edilmesi için DÖ tabanlı bir yaklaşımı önermiştir. IoT ağlarının güvenliği, cihaz sayısındaki artış ve büyük veri üretimi nedeniyle giderek daha fazla önem kazanmaktadır. Çalışmada, NSL-KDD ve UNSW-NB15 veri setleri kullanılarak çeşitli saldırı türlerini sınıflandırmak için bir DÖ modeli geliştirilmiştir. Model, özellik sayısını sınırlamak ve önemli özellikleri seçmek için filtre tabanlı bir yaklaşım kullanmıştır. DSA ve ESA modelleri uygulanmış ve her iki veri setinde de DÖ modellerinin daha yüksek doğruluk oranına sahip olduğu gözlemlenmiştir. DÖ modellerinin anlaşılması zor olduğu için, model açıklaması sağlamak amacıyla Açıklanabilir Yapay Zeka (XAI) teknikleri uygulanmıştır. DSA modeline olan güveni artırmak için Yerel Yorumlanabilir Modelden Bağımsız Açıklamalar (LIME) yöntemi ve daha iyi bir anlayış için Shapley Ek Açıklamaları (SHAP) kullanılmıştır. Çalışma, IoT ağlarında normal ve saldırı kategorilerini sınıflandırmak için bir DÖ modeli tasarlamış, özellik azaltma ile hesaplama hızını artırmış ve modelin açıklanabilirliğini sağlamıştır. Gelecekteki çalışmaların,

modelin sınıf dengesizliđi sorununu çözmeyi ve daha fazla veri seti üzerinde test etmeyi hedeflemiştir [38].

Devendiran ve Turukmane, 2024 yılında yaptıkları çalışmada, ağ saldırılarını tespit etmek için kaotik optimizasyon stratejisi kullanan derin öğrenme tabanlı bir ağ saldırı tespit sistemi olan Dugat-LSTM modelini tanıtmışlardır. Model, veri temizleme ve M-kare normalizasyonu ile ön işleme yaparak başlamaktadır. Dengelenmemiş veri setleri, Genişletilmiş Sentetik Örnekleme (ExSyn) yaklaşımı ile dengelenmiştir. Özellik çıkarımı, çekirdek destekli ana bileşen analizi (KerPCA) ile gerçekleştirilmiş ve en uygun özellikler Kaotik Bal Porsuđu optimizasyon algoritması (CHbO) ile seçilmiştir. Saldırıları, Gated Attention Dual Long Short Term Memory (Dugat-LSTM) modeli ile sınıflandırılmıştır. Model, TON-IOT ve NSL-KDD veri setleri üzerinde değerlendirilmiş ve yüksek doğruluk oranları elde etmiştir: TON-IOT veri setinde %98,76 ve NSL-KDD veri setinde %99,65 doğruluk oranları yakalanmıştır. Bu sonuçlar, önerilen modelin ağ saldırı tespitinde mevcut diğer modellerden daha üstün olduğunu göstermiştir. Model, özellikle kaotik optimizasyon ve çift kapılı dikkat mekanizmaları sayesinde yüksek doğruluk, hassasiyet ve genelleme yeteneđi sergilemiştir. Gelecekteki çalışmalar, özellik seçimi yöntemini daha da geliştirerek yeni saldırıların tespit oranını artırmayı hedeflemiştir [39].

Nandanwar ve Katarya, 2024 yılında yaptıkları çalışmada, Endüstriyel Nesnelerin İnterneti (IIoT) ortamında botnet saldırılarını tespit etmek ve sınıflandırmak için DÖ tabanlı bir model olan AttackNet'i tanıtmaktadır. Araştırma, IIoT sistemlerinin güvenliğini sağlamak için DÖ tekniklerinin nasıl kullanılabileceğini incelemiştir. AttackNet, adaptif bir ESA-GRU modeli kullanarak botnet saldırılarını tespit etmede yüksek doğruluk oranları elde etmiştir. Model, N_BaIoT veri seti üzerinde test edilmiş ve %99,75 doğruluk, %99,75 hassasiyet ve %99,74 geri çağırma oranları ile mevcut en iyi teknikleri geride bırakmıştır. Çalışma, IIoT sistemlerinde güvenliđi artırmak için DÖ tabanlı çözümlerin etkinliğini vurgulamış ve gelecekteki araştırmalar için potansiyel geliştirme alanlarını önermiştir [40].

Rani ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ saldırılarını tespit etmek için Archimedes Fire Hawk Optimizasyonu (AFHO) ile desteklenen Derin Maxout Ağı (DMN) tabanlı bir sistem geliştirmişlerdir. İlk olarak, kablosuz ağ simüle edilmiş ve kaydedilen günlük dosyası, eksik veri tamamlama ve kantil normalizasyonu kullanılarak ön işleme tabi tutulmuştur. Daha sonra, AFHO algoritması kullanılarak özellik seçimi gerçekleştirilmiştir. Son olarak, AFHO tarafından optimal şekilde eğitilen DMN ile saldırı tespiti yapılmıştır. AFHO, Archimedes Optimizasyon Algoritması (AOA) ve Fire Hawk Optimizasyonu (FHO) kombinasyonu ile elde edilmiştir. Önerilen yöntemin performansı değerlendirilmiş ve %93,70 doğruluk, %97,70 geri çağırma ve %95,60 F-ölçütü ile iyi bir performans sunduğu gösterilmiştir. Gelecekte, DMN'yi daha da geliştirmek için diğer hibrit optimizasyon algoritmalarının geliştirilmesinin planlanmakta olduğu bildirilmiştir [41].

Wang ve arkadaşları, 2024 yılında yaptıkları çalışmada, günümüz dijital çağında artan siber tehditler ve karmaşık saldırı teknikleri karşısında ağ güvenliğinin önemini vurgulamıştır. Çalışma, ASTS geliştirilmesi ve değerlendirilmesine odaklanarak, ağ altyapılarını kötü niyetli faaliyetlerden korumak için etkili yöntemler geliştirmeyi amaçlamıştır. Araştırmanın temeli, ABD Hava Kuvvetleri ağını simüle eden bir askeri ağ ortamından elde edilen kapsamlı bir veri setinin analizine dayanmaktadır. Bu veri seti, siber savaş senaryolarında karşılaşılan çeşitli saldırı türlerini içermektedir. Makale, mevcut literatürü inceleyerek, aykırılık tabanlı ve derin öğrenme tabanlı yaklaşımları içeren geniş bir yöntem yelpazesini ortaya koymuştur. Mevcut yöntemleri geliştirmek amacıyla, ağ saldırı tespiti için TabTransformer adlı bir transformer tabanlı mimari önerilmiştir. TabTransformer, tabular verilerdeki karmaşık desenleri ve bağımlılıkları etkili bir şekilde yakalamak için kendine dikkat mekanizmasını kullanmaktadır. Çalışma, veri ön işleme, model mimarisi ve değerlendirme metriklerini içeren detaylı bir metodoloji sunmuş ve önerilen yaklaşımın siber tehditleri hafifletme ve ağ güvenliğini artırma konusundaki etkinliğini göstermiştir. Sonuç olarak, çalışma, TabTransformer'ın ağ saldırı tespitinde üstün performans sergilediğini ve geleneksel modelleri geride bıraktığını vurgulamıştır. Bu bulgular, siber tehditlerin giderek daha karmaşık hale

geldiği günümüz dijital ortamında, yenilikçi makine öğrenme tekniklerinin benimsenmesinin önemini ortaya koymuştur [42].

Ghadermazi ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ saldırılarını gerçek zamanlı olarak tespit etmek için yeni bir yapay zekâ destekli metodolojik çerçeve önermiştir. Mevcut paket tabanlı ASTS'lerin sınırlamalarını ele alarak hem başlık hem de yük verilerini analiz eden ve aynı akıştaki paketler arasındaki zamansal bağlantıları dikkate alan bir yaklaşım geliştirmişlerdir. Önerilen çerçeve, ardışık paketleri iki boyutlu görüntülere dönüştürmüş ve bu görüntüleri işlemek için bir ESA tabanlı saldırı tespit modeli geliştirmiştir. Çalışma, bu çerçevenin farklı saldırı türlerinde %97,70 ile %99 arasında yüksek tespit oranlarına ulaştığını ve düşmanca örneklerle karşı dayanıklılık gösterdiğini deneylerle kanıtlamıştır. Ayrıca, modelin yeni bir hedef ağ ortamında yeniden eğitilmeden etkili bir şekilde çalışabileceği ve siber güvenlik ekipleri için esneklik ve verimlilik sağladığı belirtilmiştir [43].

Djaidj ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ tabanlı saldırıları erken aşamada tespit edebilen bir ASTS geliştirmeyi amaçlamıştır. Mevcut akış tabanlı ASTS'lerin, akış sona erdikten sonra saldırıları tespit etme dezavantajına sahip olduğunu ve bu durumun saldırı tespitinde gecikmelere yol açarak daha fazla kötü niyetli paketin ağa sızmasına neden olduğunu belirtmişlerdir. Bu sorunu çözmek için, DÖ modelleri ve özellikle Dikkat Mekanizmaları ve Yinelemeli Sinir Ağları (RNN) kullanılarak erken akış sınıflandırması ele alınmıştır. Bu stratejik kombinasyon, ağ akışlarındaki paketlerin ardışık doğasını kullanarak erken akış sınıflandırmasının verimliliğini artırmıştır. Çalışma, CIC-IDS2017 ve 5G-NIDD gibi güncel ağ saldırı veri setleri üzerinde deneyler yapmış ve önerilen ASTS'lerin ağ akışlarını sınıflandırmadaki etkinliğini ve doğruluğunu göstermiştir. Ayrıca, önerilen yaklaşımın, akışın sona ermesini beklemeden saldırıları erken aşamada tespit edebilme yeteneğini sergilediği belirtilmiştir. Bu, hem sınıflandırma için gereken ilk paket sayısında hem de tespit için gereken sürede azalmaya yol açmıştır. Makale, önerilen modelin, ağ akışlarının ardışık doğasını dikkate alarak, erken saldırı tespitinde önemli bir potansiyele sahip olduğunu vurgulamıştır [44].

Hnamte ve arkadaşları, 2024 yılında yaptıkları çalışmada, yazılım tanımlı ağ SDN ortamlarında DDoS saldırılarının tespiti ve hafifletilmesi için DSA tabanlı bir yaklaşım sunmuştur. Çalışma, DDoS saldırılarını tespit etmek için DÖ ilkelerine dayanan bir DSA mimarisi kullanarak yenilikçi bir yöntem tanıtmıştır. Önerilen model, ağ trafiği verilerini analiz ederek DDoS saldırılarına işaret eden karmaşık desenleri belirleme yeteneğine sahiptir. Modelin etkinliğini doğrulamak için gerçek dünya trafiği verileri kullanılarak kapsamlı değerlendirmeler yapılmıştır. Sonuçlar, DSA tabanlı yaklaşımın geleneksel DDoS tespit tekniklerine göre üstünlüğünü ortaya koymuştur. Çalışma, SDN ortamlarında ağ güvenliğini güçlendirme potansiyeline sahiptir ve DDoS tehditlerini hafifletmede etkili olduğunu göstermiştir. Model, InSDN, CICIDS2018 ve Kaggle DDoS veri setlerinde sırasıyla %99,98, %100 ve %99,99 tespit doğruluğu elde etmiştir. Bu çalışma, SDN altyapılarında DDoS tespiti için yeni bir yaklaşım sunmuş ve DSN'lerin gerçek dünya SDN ortamlarında uygulanmasıyla ilgili pratik çıkarımlar ve zorluklar hakkında içgörüler sağlamıştır [45].

Abdulganiyu ve arkadaşları, 2024 yılında yaptıkları araştırmada, ağ tabanlı saldırılara karşı etkili bir ASTS modeli geliştirmeyi amaçlayan sistematik bir literatür incelemesi sunmuştur. İnceleme, Aykırılık, İmza ve Hibrit STS yaklaşımlarını kapsamaktadır. Çalışma, mevcut STS yöntemlerini, veri setlerini, tespit edilen saldırı türlerini ve performans değerlendirme metriklerini karşılaştırarak analiz etmiştir. Aykırılık tabanlı STS'ler genellikle DÖ ve makine öğrenme tekniklerini kullanırken, imza tabanlı STS'ler kural tabanlı ve desen eşleştirme algoritmalarına dayanmaktadır. Hibrit STS'ler ise her iki yaklaşımı birleştirerek daha geniş bir saldırı tespit kapasitesi sunmayı hedeflemektedir. Çalışma, STS'lerin geliştirilmesinde karşılaşılan zorlukları ve gelecekteki araştırma yönlerini de tartışmıştır. Özellikle, gerçek zamanlı ve çevrimiçi STS'lerin geliştirilmesi, veri setlerinin güncellenmesi ve derin öğrenme tekniklerinin daha verimli kullanılması gibi konulara dikkat çekilmiştir. Makale, araştırmacılara ağ güvenliği alanında daha etkili çözümler geliştirmeleri için kapsamlı bir bakış açısı sunmayı amaçlamıştır [46].

He ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ güvenliği ve trafik sınıflandırmasında önemli bir rol oynayan aykırılık tespitine odaklanmışlardır.

Geleneksel makine öğrenimi ve DÖ yöntemlerinin esneklik ve transfer edilebilirlik konularında sınırlamaları olduğunu belirten yazarlar, bu sorunları çözmek için derin pekiştirmeli öğrenmeye dayalı transfer edilebilir ve uyarlanabilir bir ağ saldırı tespit sistemi (TA-ASTS) önermiştir. TA-ASTS, ajan ve çevre arasındaki etkileşim sürecini kullanarak, az sayıda örnekle bile sağlamlık sağlamış ve tüm veri setini sınıflandırmadan önce aykırı değerleri seçmeyi öğrenmiştir. Bu sistemin, özellik boyutları gerektirmeden, genel bir veri seti durumunu kullanarak diğer veri setlerine transfer edilebileceği gösterilmiştir. IDS2017, IDS2018, NSL-KDD, UNSW-NB15 ve CIC-IoT2023 veri setleri üzerinde yapılan deneyler, önerilen çerçevenin aykırı değerleri önceliklendirirken iyi bir doğruluk ve transfer edilebilirlik sağladığını göstermiştir [47].

Zhang ve arkadaşları, 2024 yılında yaptıkları çalışmada, çevrimiçi müzik eğitimi ortamlarında etkili saldırı tespiti için kamu bulut ağlarına yönelik derin sinir ağları önermiştir. Çalışma, bulanık mantık tabanlı özellik seçimi, kronolojik SSA ile optimize edilmiş derin inanç ağları ve kapılı tekrarlayan birim entegreli konvolüsyonel sinir ağlarından oluşan yenilikçi bir saldırı tespit çerçevesi geliştirmiştir. NSL-KDD ve CICIDS2017 veri setleri üzerinde kapsamlı deneyler yapılarak önerilen modellerin diğer yöntemlere göre üstün performans gösterdiği kanıtlanmıştır. Önerilen DÖ çerçeveleri, çevrimiçi müzik eğitimi bulut ağlarında saldırı tespiti için etkili bir çözüm sunmuştur. Makale, bulut tabanlı müzik eğitimi platformlarının güvenlik ihtiyaçlarına özel olarak uyarlanmış derin öğrenme tabanlı saldırı tespit tekniklerinin geliştirilmesinin önemini vurgulamıştır [48].

Yuan ve arkadaşları, 2024 yılında yaptıkları çalışmada, DÖ tabanlı STS'lerin düşman saldırılarına karşı dayanıklılığını artırmak için yeni bir çerçeve önermiştir. DÖ-STs'ler, ağ saldırılarına karşı etkili güvenlik çözümleri sunarken, düşman DÖ teknolojilerinin gelişimi nedeniyle bu sistemlerin güvenilirliği tehdit altındadır. Bu çalışmada, geleneksel makine öğrenimi modelleri ve DÖ modellerini birleştirerek, düşman saldırılarına karşı daha dayanıklı bir STS mimarisi önerilmiştir. Önerilen sistem (DLL-STs) üç ana bileşenden oluşur: DÖ tabanlı STs, düşman örnek (AE) dedektörü ve makine öğrenimi tabanlı STs. İlk olarak, yerel içsel boyutluluk (LID) yöntemine dayanan yeni bir AE

dedektörü geliştirilmiştir. Bu dedektör, DÖ modelleri ve ML modelleri arasındaki düşük saldırı aktarılabilirliğinden yararlanarak, AE'lerin kötü niyetini belirlemede yardımcı olacak sağlam bir ML modeli bulur. Eğer gelen trafik bir AE olarak tespit edilirse, ML tabanlı STS, trafiğin kötü niyetini tahmin eder; aksi takdirde, DÖ tabanlı STS tahmin yapar. Bu birleşim mekanizması, DÖ modellerinin yüksek tahmin doğruluğunu ve DÖ ile ML modelleri arasındaki düşük saldırı aktarılabilirliğini kullanarak sistemin genel dayanıklılığını artırır. Deneyler, DLL-STS çerçevesinin düşman saldırıları altında STS'nin performansını önemli ölçüde artırdığını ve düşük kaynak tüketimi ile yüksek doğruluk sağladığını göstermiştir. Örneğin, Carlini ve Wagner (CW) saldırısı altında doğruluk oranı %17,9'dan %71,7'ye yükselmiştir. Bu çerçeve, örneklerin hem içsel özelliklerine hem de düşman doğasına odaklanılması gereken senaryolara geniş bir uygulama alanı sunmuştur. Teorik olarak, bu çerçeve, benzer senaryolarda herhangi bir veri formuna uyarlanabilir. Gelecekteki araştırmaların, diğer alanlarda derin öğrenme modellerinin getirdiği güvenlik sorunlarına daha fazla odaklanılmasının beklendiği belirtilmiştir [49].

Arjunan, 2024 yılında yaptığı çalışmada, büyük veri ortamlarında ağ trafiği aykırılıklarının gerçek zamanlı tespiti için DÖ modellerinin kullanımını önermiştir. Geleneksel yöntemlerin yetersiz kaldığı bu alanda, LSTM ve ESA modelleri kullanılarak bir çerçeve geliştirilmiştir. Bu modeller, paket yakalamalarından elde edilen verilerle eğitilmiş ve hem standart izinsiz giriş veri setleri hem de büyük ölçekli gerçek ağ trafiği veri setleri üzerinde değerlendirilmiştir. Sonuçlar, DÖ modellerinin, geleneksel sığ öğrenme yöntemlerine kıyasla aykırılıkları daha etkili bir şekilde tespit edebildiğini göstermiştir. Modeller, yüksek hacimli akış verilerini düşük gecikme ile gerçek zamanlı olarak işleyebilmiştir. Ayrıca, model sıkıştırma ve transfer öğrenimi gibi optimizasyon yöntemleri önerilmiştir. Bu çalışma, büyük veri ortamlarında gerçek zamanlı aykırılık tespiti için DÖ'nün etkinliğini ortaya koymuştur. Çalışmada, ESA-LSTM modeli, NSL-KDD, ISCX-IDS ve CTU-13 veri setlerinde diğer sığ öğrenme modellerine kıyasla daha yüksek doğruluk, kesinlik, duyarlılık ve F1-score değerleri elde etmiştir. Özellikle CTU-13 veri setinde, ESA-LSTM modeli %97,2 doğruluk ile düşük gecikme süresiyle sınıflandırma yapabilmıştır. Bu sonuçlar, derin öğrenme modellerinin karmaşık ağ trafiği

verilerinden faydalı özellikler öğrenme kapasitesini ve aykırılık tespitindeki üstünlüğünü göstermiştir [50].

Li ve arkadaşları, 2024 yaptıkları çalışmada, ağ güvenliğini artırmak amacıyla yenilikçi bir ağ saldırı tespit modeli olan TDBO-ACBLT'yi tanıtmışlardır. Model, Attention-CNN-BiLSTM (ACBL) ve Temporal Convolutional Network (TCN) mimarilerini birleştirerek, ağ trafiği verilerindeki mekânsal ve zamansal özellikleri etkili bir şekilde işlemektedir. Dung böceklerinin doğal davranışlarından esinlenilen Tent Dung Beetle Optimization (TDBO) algoritması, özellik seçimi ve model hiperparametrelerinin optimizasyonu için kullanılmıştır. TDBO, özellik seçimi aşamasında RO algoritması ile entegre edilerek, model performansını artırmak için en uygun özelliklerin seçilmesini sağlamıştır. UNSW-NB15 veri seti üzerinde test edilen model, yaygın makine öğrenimi modellerine kıyasla daha yüksek doğruluk oranı ve daha düşük yanlış pozitif oranı elde etmiştir. Bu çalışma, ağ saldırı tespitinde makine öğrenimi ve DÖ yöntemlerinin etkinliğini artırmak için yeni bir yaklaşım sunmuştur. Önerilen TDBO-ACBLT modeli, UNSW-NB15 veri seti üzerinde test edilmiştir ve elde edilen performans değerleri oldukça etkileyicidir. Model, %97,32 doğruluk oranı ile diğer makine öğrenimi modellerine kıyasla daha yüksek bir doğruluk sergilemiştir. Yanlış pozitif oranı (FPR) sadece %2,19 olarak ölçülmüş, bu da modelin normal trafiği yanlışlıkla aykırılık olarak sınıflandırma olasılığının düşük olduğunu göstermektedir. Doğru pozitif oranı (TPR) %96,82 olarak belirlenmiş ve bu da modelin anormal davranışları doğru bir şekilde tespit etme yeteneğini ortaya koymuştur. Ayrıca, F1 skoru %97,27 olarak hesaplanmış, bu da modelin hem hassasiyet hem de geri çağırma açısından dengeli bir performans sergilediğini göstermiştir. Bu sonuçlar, TDBO-ACBLT modelinin ağ trafiği verilerindeki anormal davranışları ve saldırıları yüksek doğrulukla tespit edebildiğini ve genel performansının üstün olduğunu ortaya koymuştur [51].

Ullah ve arkadaşları, 2024 yılında yaptıkları çalışmada, dengesiz ağ trafiği için transformer tabanlı transfer öğrenimi kullanan bir saldırı tespit sistemi (IDS-INT) önermişlerdir. Önerilen sistem, ağ trafiğindeki özellik etkileşimlerini öğrenmek için transformer tabanlı bir yaklaşım kullanmış ve dengesiz veri sorunlarını ele almıştır. İlk

olarak, ağ etkileşim açıklamalarından saldırı türü, referans ve ana bilgisayar bilgileri gibi detaylı bilgiler toplanmıştır. Ardından, özelliklerin semantik bağlantılarını kullanarak detaylı özellik temsili öğrenilmiştir. Dengesiz trafik sorununu çözmek için SMOTE yöntemi uygulanarak anormal trafik dengelenmiş ve azınlık saldırıları tespit edilmiştir. Derin özellikleri çıkarmak için bir ESA modeli tasarlanmış ve farklı saldırı türlerini tespit etmek için ESA-LSTM modeli geliştirilmiştir. Üç standart veri seti (UNSW-NB15, CIC-IDS2017 ve NSL-KDD) kullanılarak yapılan deneyler, önerilen yöntemin etkililiğini göstermiştir. Ayrıca, açıklanabilir yapay zekâ yaklaşımı kullanılarak modelin güvenilirliği artırılmıştır. Bu çalışma, ağ tabanlı saldırıların tespitinde daha yüksek doğruluk ve güvenilirlik sağlamayı amaçlamıştır. Önerilen IDS-INT modeli, üç standart veri seti (UNSW-NB15, CIC-IDS2017 ve NSL-KDD) üzerinde kapsamlı bir şekilde test edilmiştir. Bu testler sonucunda, modelin performans ölçütleri oldukça yüksek bulunmuştur. Özellikle, UNSW-NB15 veri seti kullanılarak yapılan deneylerde, ESA-LSTM modeli ile elde edilen sonuçlar dikkat çekici olmuştur. Bu model, temel özellikler kullanılarak %99 hassasiyet, %100 geri çağırma, %99 F1 skoru ve %99,21 doğruluk oranı sağlamıştır. Diğer yandan, ESA-YSA ve ESA-GRU modelleri de test edilmiş, ancak ESA-LSTM modeli en yüksek performansı göstermiştir. CIC-IDS2017 veri seti üzerinde yapılan testlerde, web saldırıları için %99 hassasiyet, %100 geri çağırma, %99 F1 skoru ve %99,32 doğruluk oranı elde edilmiştir. NSL-KDD veri seti üzerinde yapılan testlerde ise, ESA-LSTM modeli ile KDDTest+ alt seti kullanılarak %98 hassasiyet, %99 geri çağırma, %98 F1 skoru ve %98,45 doğruluk oranı elde edilmiştir. Bu sonuçlar, önerilen STS-INT modelinin, özellikle ESA-LSTM kombinasyonu ile ağ tabanlı saldırıların tespitinde yüksek doğruluk ve güvenilirlik sağladığını göstermiştir [52].

Eljialy ve arkadaşları, 2024 yılında yaptıkları çalışmada, SDN için çoklu özellik seçimi yöntemlerine dayalı yeni bir STS çerçevesi önermiştir. Çalışma, makine öğrenimi (ML) tekniklerini kullanarak, yüksek doğruluk ve düşük yanlış pozitif oranları ile saldırıları tespit edebilen etkili bir STS geliştirmeyi amaçlamıştır. Özellik seçimi, ML modellerinin aşırı uyumunu önlemek için kritik bir adım olmuştur. Bu çalışmada, SDN veri seti kullanılarak yüksek puanlı özellikler seçilmiş ve aday veri seti oluşturulmuştur. Ardından, bu veri seti üzerinde çeşitli sınıflandırma algoritmaları uygulanarak modeller

geliştirilmiştir. Önerilen model, az sayıda özellik seçilmesine rağmen saldırı tespitinde önemli bir iyileşme göstermiştir. Çalışma, özellikle IoT ağlarındaki güvenlik tehditlerini ele alarak, ağ güvenliğini artırmayı hedeflemiştir [53].

Wong ve Arjunan, 2024 yılında yaptıkları çalışmada, büyük veri ortamlarında ağ trafiği aykırılıklarının gerçek zamanlı tespiti için DÖ yöntemlerini kullanmayı önermiştir. Ağ trafiği verilerinin hacmi, hızı ve çeşitliliği, geleneksel analiz yöntemleri için ölçeklenebilirlik sorunları yaratmaktadır. Bu nedenle, DÖ öngörü gücünden yararlanarak, akışkan ağ verilerini düşük gecikmeyle işleyebilen yüksek doğrulukta modeller geliştirmeyi amaçlamışlardır. Önerilen çerçeve, ESA ve LSTM modellerini birleştirerek, büyük veri ortamlarına uygun bir uçtan uca aykırılık tespit sistemi sunmuştur. Modeller, ağ trafiği verilerinden çıkarılan akış verileri üzerinde eğitilmiş ve gerçek dünya koşullarını temsil eden büyük ölçekli ağ trafiği verileri üzerinde değerlendirilmiştir. Sonuçlar, DÖ modellerinin aykırılıkları etkili bir şekilde tespit edebildiğini ve geleneksel sıg öğrenme modellerini geride bıraktığını göstermiştir. Çalışma, transfer öğrenme ve model sıkıştırma gibi optimizasyon tekniklerini önererek tespit verimliliğini artırmayı hedeflemiştir. DÖ'nün, büyük veri ortamlarında gerçek zamanlı ağ trafiği aykırılık tespiti için etkinliğini göstermiştir. Bu bulgular, DÖ yöntemlerinin ağ güvenliği alanında büyük veri ve gelişen siber tehditlerle başa çıkmada önemli bir potansiyele sahip olduğunu vurgulamıştır [54].

Wang ve arkadaşları, 2024 yılında yaptıkları çalışmada, gelişmiş kalıcı tehditler (APT) ve kötü amaçlı yazılımlar, özellikle Android cihazlar üzerindeki tehditlerin artışını ele almış ve işletim sistemlerinde güvenlik tespiti ve savunma mekanizmalarını geliştirmek için derin öğrenme tabanlı bir yaklaşım önermişlerdir. Mobil cihazların ve Android işletim sisteminin yaygınlaşması, kötü amaçlı yazılım saldırılarının riskini artırmıştır. Geleneksel makine öğrenimi yöntemleri, özellik çıkarımında uzman bilgisine bağımlılık ve düşük doğruluk gibi sınırlamalara sahiptir. DÖ modelleri, büyük veri setlerinden öğrenerek daha önce bilinmeyen tehditleri tespit edebilir. Yanlış pozitifleri azaltır ve sık güncellemeler gerektirmeden gelişen tehditlere uyum sağlar. APT'ler ve sofistike saldırıların tespitinde etkilidir. Makale, işletim sistemi güvenliği için çok katmanlı

koruma ve gerçek zamanlı tehdit yanıtı sağlayan dinamik heterojen yedekli (DHR) bir mimari tanıtmıştır. YSA'lar ve LSTM ağları, ardışık verileri işleme ve zamansal bağımlılıkları yakalama yetenekleri nedeniyle güvenlik tespiti görevleri için vurgulanmıştır. Biyolojik mimikriden esinlenerek, Android kötü amaçlı yazılım tespiti için benzer olmayan yedekli bir mimari kullanarak bir mimikri savunma stratejisi önerilmiştir. LSTM, GRU ve kapsül ağları gibi geliştirilmiş DÖ algoritmaları, kötü amaçlı yazılım tespitinin doğruluğunu ve verimliliğini artırmak için kullanılmaktadır. DÖ dinamik güvenlik mimarileri ile entegrasyonu, işletim sistemi güvenliğini artırmak için umut verici bir yaklaşım sunmaktadır. Önerilen yöntemler, çok katmanlı koruma, gerçek zamanlı tehdit yanıtı ve verimli kaynak kullanımı sağlayarak sağlam bir güvenlik çerçevesine katkıda bulunmaktadır. Makale, derin öğrenmenin siber güvenlik savunmalarını geliştirme ve özellikle Android kötü amaçlı yazılım tespitinde gelişen tehditlere karşı koruma sağlama potansiyelini vurgulamıştır [55].

Muneer ve arkadaşları, 2024 yılında yaptıkları çalışmada, bilgisayar ağlarında saldırı tespiti için yapay zekâ tabanlı yaklaşımları kapsamlı bir şekilde incelemişlerdir. Salman Muneer ve diğer yazarlar, makine öğrenimi, derin öğrenme, federe öğrenme (FL) ve açıklanabilir yapay zekâ (XAI) gibi yöntemlerin saldırı tespitinde nasıl kullanılabileceğini ele almıştır. DÖ modelleri, ağ trafiği verilerindeki karmaşık kalıpları öğrenerek yüksek doğrulukla saldırıları tespit edebilir, ancak büyük miktarda etiketlenmiş veri ve yüksek hesaplama gücü gerektirir. Makine öğrenimi yöntemleri daha az kaynak gerektirir ve bilinen saldırıları etkili bir şekilde tespit edebilir, ancak yeni verilerle genelleme yapma yetenekleri sınırlıdır. Federe öğrenme, birden fazla varlığın verilerini paylaşmadan ortak bir model eğitmesine olanak tanır, bu da gizlilik ve güvenlik avantajları sağlar. Açıklanabilir yapay zekâ, AI modellerinin karar verme süreçlerini daha anlaşılır hale getirir, bu da güven ve uyumluluk açısından önemlidir. Makale, bu yaklaşımların belirli kullanım durumları ve senaryolar için uygunluğunu kapsamlı bir şekilde analiz etme konusunda literatürdeki boşlukları belirlemiş ve bu boşlukları doldurmayı amaçlamıştır. Yazarlar, DÖ tabanlı yaklaşımların yüksek doğruluk sunduğunu ancak kaynak yoğun olduğunu, ML yaklaşımlarının daha basit olduğunu ancak bilinmeyen saldırıları tespit etmede yetersiz kalabileceğini belirtmişlerdir. FL,

gizlilik hassasiyeti olan ortamlarda umut verici bir seçenek olarak görülmekte, ancak daha fazla araştırmaya ihtiyaç duyulmaktadır. Gelecekteki araştırmalar için, blok zincir teknolojisi ve XAI'nin mevcut tekniklerle entegrasyonu önerilmiştir [56].

Biju ve arkadaşları, 2024 yılında yaptıkları çalışmada, IoT ağlarında saldırıları tespit etmek için Geliştirilmiş Kuş Sürüsü Optimizasyonu tabanlı Derin İnanç Ağı (EBSO-DBN) sınıflandırma tekniğini tanıtmışlardır. Çalışma, IoT cihazlarının artan kullanımıyla birlikte ağ güvenliğinin önemine dikkat çekmekte olup bu cihazların güvenliğini sağlamak için etkili bir STS geliştirmeyi amaçlamıştır. EBSO-DBN algoritması, ağ trafiğini analiz ederek kötü niyetli faaliyetleri tespit etmek için DÖ tekniklerini kullanmaktadır. Çalışma, NSL-KDD veri seti üzerinde yapılan deneylerle, önerilen yöntemin %98,7 doğruluk, %99,4 hassasiyet ve %98,8 geri çağırma oranı ile diğer yöntemlere göre üstün performans gösterdiğini ortaya koymuştur. Makale, IoT ağlarında saldırı tespitini iyileştirmek için DÖ ve kuş sürüsü optimizasyonu tekniklerinin entegrasyonunu vurgulamış ve gelecekteki araştırmalar için öneriler sunmuştur [57].

Lu ve arkadaşları, 2024 yılında yaptıkları çalışmada, IIoT için DÖ'ye dayalı bir STS geliştirmeyi amaçlamışlardır. Çalışmada IIoT ağlarının güvenliğini sağlamak için STS teknolojisinin önemine vurgu yapılmıştır. Mevcut STS'lerin, veri setlerindeki sınıf dengesizliği, gereksiz ve anlamsız özellikler gibi sorunlarla karşılaştığı belirtilmiştir. Bu sorunları çözmek için makalede, aşağıdaki yaklaşımları önerilmiştir:

Sınıf dengesizliği sorununu çözmek için, çoğunluk sınıf örneklerini azaltırken bilgi kaybını en aza indiren hiyerarşik kümeleme algoritmasına dayalı bir alt örnekleme yöntemi geliştirilmiştir. Bu yöntem, NSL-KDD ve CICIDS2017 veri setlerinde, özellikle azınlık sınıflarının tespit performansını artırmıştır. Örneğin, NSL-KDD veri setinde, VAGCUS-3 algoritması kullanılarak U2R sınıfı için F1 skoru %30'a kadar çıkmıştır. Gereksiz ve müdahaleci özellikleri ortadan kaldırmak için açgözlü stratejiye dayalı optimal özellik seçimi algoritması (GRFECV) önerilmiştir. Bu algoritma, NSL-KDD veri setinde, RFECV algoritmasına kıyasla daha iyi performans göstermiştir. Örneğin, GRFECV kullanılarak elde edilen özellik alt kümeleri, sınıflandırma doğruluğunu artırmıştır. Çalışmada küresel ve yerel alt ağların paralel bağlantısına dayalı bir derin sinir

ağı modeli geliştirilmiştir. Bu model, veri setinin genel tespitini sağlarken, her alt sınıfın tespit etkisini güçlendirmiştir. CGL-DNN modeli, NSL-KDD veri setinde genel doğruluk oranını %83'e çıkarmış ve diğer ML ve DÖ modellerine göre üstün performans göstermiştir. Deneysel sonuçlar, önerilen yöntemlerin IIoT için saldırı tespit performansını önemli ölçüde iyileştirdiğini göstermiştir. Makale, ayrıca gelecekteki çalışmalar için veri üretim algoritmaları ve anormal örneklerin işlenmesi gibi konulara da değinmiştir [58] .

Long ve arkadaşları, 2024 yaptıkları çalışmada, bulut ortamları için özel olarak tasarlanmış, dönüştürücü modeline dayalı bir ASTS algoritmasını tanıtmışlardır. Bulut bilişimin dağıtık yapısının, çeşitli ve dinamik tehditlere karşı güçlü savunma mekanizmaları gerektirdiğini belirtmişlerdir. Geleneksel güvenlik duvarları, karmaşık saldırıları tespit etmekte yetersiz kalabildiğini, bu nedenle daha gelişmiş STS'lere ihtiyaç duyulduğu belirtilmiştir. Önerilen yöntem, dönüştürücü modelinin dikkat mekanizmasını kullanarak, giriş özellikleri ile çeşitli saldırı türleri arasındaki ilişkileri daha iyi analiz eder ve tespit doğruluğunu artırmıştır. Bu model, CIC-IDS 2018 veri seti kullanılarak test edilmiştir ve %93'ün üzerinde bir doğruluk oranı elde etmiştir. Bu sonuçlar, modelin bulut güvenliğini artırmada etkili olduğunu göstermiştir. Makale, dönüştürücü modelinin mimarisini, veri ön işleme, model eğitimi ve değerlendirme süreçlerini detaylandırmıştır. Ayrıca, modelin performansı farklı kodlayıcı katman sayıları ile test edilmiştir ve daha fazla katmanla doğruluğun arttığı gözlemlenmiştir. Sonuç olarak, dönüştürücü tabanlı ASTS, bulut ortamlarında ağ güvenliğini artırmak için uygulanabilir bir çözüm olarak sunulmuştur. Gelecekte, modelin daha karmaşık saldırı kalıplarını tespit etme yeteneğini artırmak için Grafik Sinir Ağları ile entegrasyon planlanmıştır [59].

Angelin ve Priyadharsini, 2024 yılında yaptıkları çalışmada, IIoT ortamlarında çeşitli siber saldırıları tespit etmek amacıyla derin öğrenme tabanlı bir ASTS geliştirilmesini ele almıştır. Çalışma, ESA ve AE tekniklerini birleştirerek, ağ trafiğinden karmaşık özellikler ve kalıplar çıkarmayı hedefleyen bir model önermiştir. Bu hibrit model, Edge_IIoT veri seti üzerinde test edilmiş ve %92,34 doğruluk, %91,69 kesinlik, %90,28 geri çağırma ve %89,08 F1 skoru elde etmiştir. IIoT sistemleri, üretim, tedarik zinciri yönetimi, enerji

hizmetleri gibi birçok endüstride kullanılmakta ve siber saldırılara karşı savunmasız durumdadır. Mevcut izinsiz giriş tespit sistemleri, farklı saldırı türlerini ele almakta yetersiz kalmakta ve dengesiz veri setleriyle başa çıkmakta zorlanmaktadır. Önerilen model, ESA ve AE tekniklerini birleştirerek veri özelliklerini azaltmakta ve karmaşık verilerden otomatik olarak özellikler çıkarmaktadır. Çalışma, IIoT ağlarında izinsiz girişleri etkili bir şekilde tespit etmek ve azaltmak için ESA ve AE'nin entegrasyonunun önemini vurgulamıştır. Ancak, modelin eğitimi sırasında hassas ağ verilerinin potansiyel olarak açığa çıkması gibi gizlilik endişeleri ve kötü niyetli aktörlerin sistemi aldatmak için girdi verilerini manipüle edebileceği güvenlik zorlukların da ele alınması gereken konular arasında yer almakta olduğu belirtilmiştir [60].

Ali ve arkadaşları 2024 yılında yaptıkları çalışmada, IIoT sistemlerinde siber güvenlik tehditlerini ele almak için Blok Zinciri ve Federe Öğrenme (FL) tabanlı bir STS yaklaşımını incelemiştir. Çalışma, IIoT ortamlarındaki çeşitli saldırı türlerini ve bunların sistem üzerindeki etkilerini analiz etmiştir. Blok Zincirinin merkezi olmayan ve değiştirilemez yapısı ile FL'nin gizlilik koruyan işbirlikçi öğrenme yeteneklerinin entegrasyonu, IIoT ağlarının güvenliğini artırmada önemli bir rol oynamaktadır. Araştırma, mevcut STS tekniklerini karşılaştırarak, FL ve Blok Zinciri ile entegre edilmiş yöntemlerin IIoT ağlarında güvenliği nasıl artırdığını göstermiştir. Ancak, mevcut ML tabanlı STS'lerin yeni ve ortaya çıkan saldırı türlerini tespit etmede sınırlı kaldığı belirtilmiştir. Bu bağlamda, dinamik ve merkezi olmayan veri etkileşimi sağlayan yeni nesil STS'lerin geliştirilmesi gerektiği vurgulanmıştır. Çalışma, STS'lerin değerlendirilmesinde kullanılan veri setlerini de ele almış ve her birinin güçlü ve zayıf yönlerini tartışmıştır. Özellikle, NSL-KDD, ToN_IoT, UNSW-NB15 ve X-IIoTID gibi veri setleri, STS algoritmalarının eğitimi ve değerlendirilmesi için kritik öneme sahiptir. Sonuç olarak, Blok Zinciri ve FL'nin entegrasyonunun, IIoT sistemlerinde siber güvenliği artırmak için umut verici bir yaklaşım olduğu sonucuna varılmıştır. Ancak, bu teknolojilerin uygulanmasında karşılaşılan güvenlik riskleri ve veri sızıntısı gibi zorlukların da ele alınması gerektiği belirtilmiştir [61].

Kethineni ve Pradeepini 2024 yılında yaptıkları çalışmada, IoT tabanlı akıllı tarım sistemlerinde saldırı tespiti için geliştirilen hibrit bir DÖ çerçevesini ele almıştır. Çalışma, üç katmanlı bir mimari önerir: sensör katmanı, sis bilişim katmanı ve bulut bilişim katmanı. Sensör katmanı, tarım alanlarına yerleştirilen sensörlerden oluşurken, sis bilişim katmanı, her sis düğümünde uygulanan bir STS içerir. Bulut katmanı ise veri depolama ve uçtan uca hizmetler sunar. Önerilen model, birleştirilmiş bir ESA modeli ile çift yönlü kapılı tekrarlayan birim (Bi-GRU) modelini kullanarak saldırıları tespit eder ve sınıflandırır. BiGRU modeline eklenen dikkat mekanizması, DDoS saldırısını tanımlayan anahtar özellikleri belirler. Modelin sınıflandırma doğruluğu, Doğal Esinli Meta-Sezgisel Optimizasyon Algoritması olan Vahşi At Optimizasyonu (WHO) algoritması ile artırılmıştır. Çalışmada, ToN-IoT ve APA-DDoS saldırı veri setleri kullanılarak değerlendirilmiş ve mevcut yöntemlere kıyasla daha yüksek doğruluk, tespit oranı, kesinlik ve F-Skoru elde edilmiştir. Bu sistem, akıllı tarımda siber güvenlik tehditlerini etkili bir şekilde tespit etmeyi amaçlamaktadır [62].

Alzubi ve arkadaşları 2024 yılında yaptıkları çalışmada, tüketilebilir kenar merkezli Medikal İnternetin Nesneleri (IoMT) endüstrisinde güvenlik ve gizlilik sorunlarını ele alan bir derin öğrenme tabanlı saldırı tespit çerçevesi önermiştir. Özellikle, sağlık verilerinin iletimi sırasında ortaya çıkan tehditleri ve ağ güvenlik açıklarını tespit etmek için ESA ve LSTM modellerini birleştiren bir çerçeve geliştirilmiştir. Bu hibrit model, CSE-CIC-IDS 2018 veri seti üzerinde test edilmiş ve mevcut yöntemlere kıyasla daha yüksek doğruluk oranı elde etmiştir. Çalışma, IoMT cihazlarının topladığı verilerin güvenliğini sağlamak amacıyla gerçek zamanlı ve yüksek doğrulukta saldırı tespiti yapabilen bir sistem geliştirmeyi hedeflemektedir. Makale, önerilen çerçevenin hem bilinen hem de bilinmeyen saldırıları minimal sürede tespit edebildiğini ve sağlık hizmetleri ağını korumada önemli bir rol oynadığını vurgulamıştır [63].

Lilhore ve arkadaşları 2024 yılında yaptıkları çalışmada, IoT ve 5G ağlarında saldırı tespiti için DÖ tabanlı bir güvenlik çerçevesi önermiştir. IoT cihazlarının ve 5G ağlarının hızlı büyümesi, bağlantı ve erişilebilirliği artırırken, bu ortamlar için yeni tehdit seviyeleri de ortaya çıkarmıştır. Bu nedenle, saldırı tespiti kritik hale gelmiştir. Önerilen güvenlik

çerçevesi, IoT kanalları ve 5G ağlarının özel risklerini desteklemek üzere tasarlanmış DÖ'ye odaklanmıştır. Derin sinir ağları, ağ etkinlik kalıplarını etkili bir şekilde analiz etmek ve gerçek zamanlı iletişimde olası ihlalleri tanımak için kullanılmaktadır. Araştırma, 5G iletişimde saldırı tespiti için geliştirilmiş hafif ESA mimarisi (MobileNetV3-SVM) ve Transfer Öğrenimi (TL) kullanan hibrit bir model önermiştir. Model, ham ağ bilgisinden hiyerarşik olarak bilgi edinmeyi sağlayan çok katmanlı bir yapı avantajını kullanmaktadır. IoT ve yüksek hızlı 5G ağları gibi kaynakların sınırlı olduğu ortamlarda saldırı tespitinin etkinliğini en üst düzeye çıkarmak için çeşitli stratejiler uygulanmıştır. Model, ağ paketlerini gerçek zamanlı olarak işleyerek IoT ve 5G uç cihazları için uygun hale getirmiştir. Ayrıca, dinamik ve sürekli değişen sistemlerde sınırlı etiketli veri sorununu ele almak için transfer öğrenimi stratejisi kullanılmıştır. Önerilen hibrit model, mevcut ESA mimarileri (VGG-16, VGG-19, Efficient-Net ve Inception-Net) ile CICIDS-2017, 2018 ve UNSW-NB15 IoT 5G güvenlik veri setlerinde test edilmiştir. Deneysel sonuçlar, önerilen hibrit modelin doğruluk, kesinlik, yanlış pozitif oranlar, Matthew's Korelasyon Katsayısı (MCC) ve AUC-ROC açısından mevcut yaklaşımlara göre önemli iyileştirmeler sağladığını göstermiştir [64].

Li ve arkadaşları 2024 yılında yaptıkları çalışmada, ASTS'lerde anormal trafiği tespit etmek için FlowGANAnomaly adlı bir aykırılık tespit modeli önermiştir. Model, farklı veri setlerinden gelen trafik özelliklerini tek bir özellik uzayına haritalayarak, ağ trafiği verilerinin normallliğini daha doğru bir şekilde yakalamayı amaçlamaktadır. Bu durum, veri etiketlemesine olan yüksek bağımlılığı azaltmak için adversarial bir yaklaşımla gerçekleştirilir. FlowGANAnomaly, iki jeneratörün (G) evrimsel kodlayıcılarının çıktıları arasındaki sapmayı ve bir ayırt edicinin (D) çıktısını ağırlıklı skorlar olarak entegre eden yeni bir aykırılık puanlama yöntemi önerir. Bu yöntem, aykırılık tespitinin düşük hatırlama oranını iyileştirmeyi hedefler. Model, NSL-KDD, CIC-IDS2017, CIC-DDoS2019 ve UNSW-NB15 gibi dört kamu veri seti üzerinde test edilmiştir. Değerlendirme sonuçları, FlowGANAnomaly'nin aykırılık tabanlı ASTS performansını önemli ölçüde artırabileceğini göstermiştir. Makale, derin öğrenme ve generatif

adversarial ağlar (GAN) kullanarak aykırılık tespitinde yeni bir yaklaşım sunmuş ve bu alandaki zorluklara çözüm getirmeyi amaçlamıştır [65].

Bukhari ve arkadaşları 2024 yılında yaptıkları çalışmada, WSN'lerde güvenliği ve gizliliği koruyan bir saldırı tespit sistemi geliştirmek amacıyla FL tabanlı bir DÖ modeli olan SCNN-Bi-LSTM'yi önermişlerdir. Geleneksel saldırı tespit sistemleri, veri gizliliğini yeterince koruyamamakta ve karmaşık saldırıları tespit etmekte yetersiz kalmaktadır. Bu çalışmada, Stacked Convolutional Neural Network (SCNN) ve Bidirectional Long Short-Term Memory (Bi-LSTM) modelleri birleştirilerek, FL ile desteklenen bir yaklaşım geliştirilmiştir. Bu model, sensör düğümlerinin özel verilerini paylaşmadan merkezi bir model eğitmelerine olanak tanıyarak gizlilik endişelerini hafifletir. Model, DoS saldırılarını tespit etmek ve sınıflandırmak için WSN-DS ve CIC-IDS-2017 veri setlerini kullanmıştır. Önerilen model, geleneksel yapay derin sinir ağı (ADNN) modellerine kıyasla daha yüksek tespit oranları sunarak, yaklaşık %99,9 doğruluk ve geri çağırma oranlarına ulaşmıştır. Bu araştırma, FL ve DÖ'nün WSN'lerin güvenliğini ve gizliliğini artırmadaki potansiyelini vurgulamıştır. Model, karmaşık siber tehditleri tespit etmenin yanı sıra, kullanıcı verilerinin gizliliğini koruyarak saldırı tespit sistemlerini güçlendirmek için DÖ tekniklerinin nasıl kullanılabileceğini göstermiştir [66].

Sina Ahmadi 2024 yılında yaptığı çalışmada, bulut ortamlarında STS'lerin çeşitli yaklaşımlarını kapsamlı bir şekilde analiz etmiştir. Çalışma, aykırılık tabanlı, imza tabanlı ve davranış tabanlı ASTS yaklaşımlarının güçlü ve zayıf yönlerini sistematik bir şekilde incelemiş ve her bir yaklaşım için uygun siber tehdit senaryolarını belirlemiştir. Ayrıca, bulut sistemlerindeki tehditlerin gelecekteki yönünü tahmin etmek için ortaya çıkan eğilimler dikkatle incelenmiştir. Makale, bulut ortamında bu sistemin uygulanması ve optimize edilmesi için pratik bir yön sunmayı amaçlamıştır. Gerçek dünya vaka araştırmaları ve en iyi uygulamalarla entegre edilen bu analiz, okuyuculara bulut mimarilerine ve güvenlik ihtiyaçlarına göre özelleştirilmiş etkili ihlal tespit stratejileri uygulama konusunda pratik bilgiler sunmuştur. Çalışma, ölçeklenebilirlik, kaynak optimizasyonu ve mevcut güvenlik sistemleriyle entegrasyon kavramlarını araştırmıştır.

Bu, bulut hizmetlerini kullanan bireylerin yeni tehditlerden korunmasına ve sistemlerinin gelişen siber risklere karşı dayanıklılığını sağlamasına yardımcı olacaktır. ASTS'ler, bulut ortamlarında yaygın olarak kullanılmaktadır ve bu sistemler, yetkisiz erişim veya olağandışı etkinlikleri tespit etmek için ağ trafiğini analiz eder ve izler. Geleneksel yöntemler bilinen tehditleri tespit etmede etkili olsa da yeni saldırıları tanımlamada zorlanmakta ve her iki yöntemin güçlü yönlerini entegre eden hibrit yaklaşımlara ihtiyaç duyulmaktadır. Çalışma, gizlilik uyumu, performans ölçeklenebilirliği ve yanlış pozitifler gibi zorlukları ele almış ve sürekli izleme, gizlilik koruyucu teknolojiler ve gerçek zamanlı tehdit istihbaratı entegrasyonunun önemini vurgulamıştır. Ayrıca, ASTS'nin başarılı bir şekilde uygulanması için paydaş katılımı ve personel eğitiminin önemine dikkat çekilmiştir. Geleneksel ASTS teknikleri, bulut sistemlerinde değişen etkinlikler göstermektedir. İmza tabanlı tespit, bilinen saldırıları tespit etmede etkili olsa da sıfırıncı gün tehditlerini bulmada sınırlamalar yaşamaktadır. Aykırılık tabanlı tespit ise normal davranıştan sapmaları tanımlamada umut vaat etmekte, ancak dinamik bulut ortamlarında yüksek yanlış pozitiflerle karşılaşmaktadır. Hibrit tespit yaklaşımları, her iki yöntemin avantajlarını birleştirerek daha geniş bir kapsama alanı sunmakta ve yanlış pozitifleri azaltmaktadır. Çalışma, hibrit tespit sistemlerinin %95 veya daha yüksek doğru pozitif oranlarına ulaşabileceğini göstermiştir. Bulut ortamlarında ASTS'nin gelecekteki kapsamı, ortaya çıkan zorlukları hızlı ve etkili bir şekilde ele almak için daha fazla yenilik ve gelişme potansiyelini içermektedir. Makine öğrenimi ve yapay zekânın ASTS çerçevelerine entegrasyonu, tehditleri gerçek zamanlı olarak tespit etme ve yanıt verme yeteneklerini artırarak ağın genel güvenliğini iyileştirebilir. Ayrıca, AI destekli aykırılık tespit mekanizmaları, organizasyonların bulut ağlarına yönelik görünürlüğünü artırabilir. Gelecekte, gizlilik koruma teknolojileri ve gelişmiş tehdit istihbaratı entegrasyonu gibi yenilikçi yaklaşımlar keşfedilecektir [67].

Selvan ve arkadaşları 2024 yılında yaptıkları çalışmada, ağ güvenliğini artırmak amacıyla geliştirilen yeni bir ASTS ve ASES modelini tanıtmıştır. Geleneksel saldırı tespit yöntemlerinin yetersiz kaldığı durumlarda, önerilen model olan "Spider Monkey Social Optimization Algorithm (SMSOA) tabanlı Derin Q Ağı" (Deep Q Network) kullanılarak ağdaki saldırıların tespit edilmesi hedeflenmiştir. Bu model, sosyal optimizasyon

algoritması (SOA) ve örümcek maymun optimizasyonu (SMO) tekniklerinin birleştirilmesiyle geliştirilmiştir. Makale, önerilen modelin üç ana aşamadan oluştuğunu belirtmektedir: ön işleme, özellik birleştirme ve tespit. Ön işleme aşamasında, eksik veriler tahmin edilen değerlerle doldurulmaktadır. Özellik birleştirme aşamasında, Jaccard indeksi ve derin inanç ağı (DBN) kullanılarak özellikler birleştirilmiştir. Son olarak, saldırı tespiti aşamasında, SMSOA yöntemi ile eğitilen Derin Q Ağı kullanılmaktadır. Model, saldırı tespitinde f-measure, geri çağırma ve kesinlik değerleri açısından yüksek performans göstermiştir. Çalışma, önerilen modelin NSL-KDD veri seti üzerinde test edildiğini ve diğer mevcut yöntemlerle karşılaştırıldığında daha iyi sonuçlar elde ettiğini göstermiştir. Ancak, veri dengesizliği sorunlarının ele alınmasının zor olduğu belirtilmiş ve gelecekteki çalışmalarda bu konunun ele alınacağı ifade edilmiştir. Ayrıca, modelin karmaşık veri setleri üzerinde performansının analiz edileceği belirtilmiştir [68].

Soltani ve arkadaşları 2024 yılında yaptıkları çalışmada, çevrimiçi saldırı tespiti için çok ajanlı uyarlanabilir DÖ tabanlı bir çerçeve önermiştir. DÖ tabanlı STS'ler, yüksek seviyeli özellikleri otomatik olarak çıkararak ve zaman alıcı imza çıkarma sürecini ortadan kaldırarak kötü niyetli trafiği ayırt etmede kullanılır. Ancak, bu sistemlerin pratik ortamlarda kullanılabilmesi için trafik kavram kayması gibi zorlukların üstesinden gelmesi gerekmektedir. Bu makale, sürekli derin aykırılık dedektörleri ve FL yaklaşımını kullanarak bu zorlukları ele alan yenilikçi birçok ajanlı ağ saldırı tespit çerçevesi önermiştir. Çerçeve, her bir ajanın yerel trafiğindeki değişen saldırı/normal desenlere uyum sağlamasına olanak tanır ve farklı ajanlar arasında yerel bilgilerin paylaşılmasını sağlar. Önerilen çerçeve, ESA ve LSTM tabanlı modeller kullanılarak CIC-IDS2017 ve CSE-CIC-IDS2018 veri setleri üzerinde değerlendirilmiştir. Sonuçlar, önerilen dağıtık çerçevenin trafik kavram kaymasına iyi adapte olduğunu göstermiştir. ESA tabanlı modeller, trafik kavram kaymasına sürekli uyum sağlamak için uygunken, LSTM tabanlı modeller pratik çevrimiçi STS'lerde sıralı paket etiketleme için iyi bir aday olduğu belirtilmiştir [69].

Alazab ve arkadaşları, 2024 yılında yaptıkları çalışmada, Harris Hawks Optimizasyon (HHO) algoritması ile optimize edilen ÇKA tabanlı bir ASTS önermişlerdir. HHO-ÇKA,

ağlarda saldırı tespit hatalarını en aza indirmek için öğrenme sürecinde optimal parametreleri seçmeyi amaçlamışlardır. Çalışmalarında, HHO-ÇKA'nın KDD veri setleri üzerinde diğer evrimsel algoritmalarla karşılaştırıldığında daha üstün performans gösterdiğini ve %93,17 doğruluk, %89,25 duyarlılık ve %95,41 özgüllük oranlarına ulaştığını göstermiştir. HHO-ÇKA, ağ trafiğindeki kötü niyetli desenleri tanımlamada etkili olup, özellikle HHO algoritmasının keşif ve sömürü aşamalarını dengeleme yeteneği sayesinde sınıflandırma performansını artırmıştır. Çalışma, gelecekteki araştırmalar için çok amaçlı sürü zekâsı algoritmalarının ve DÖ metodolojilerinin ağ güvenliğini artırma potansiyelini vurgulamıştır [70].

Sun ve arkadaşları, 2024 yılında yaptıkları çalışmada, IoMT için optimize edilmiş bir makine öğrenimi tabanlı STS geliştirmeyi amaçlamışlardır. Çalışma, parçacık sürü optimizasyonu (PSO) ve AdaBoost algoritmalarını birleştirerek yenilikçi sağlık uygulama platformlarındaki kötü amaçlı yazılım kayıtlarını sınıflandırmak ve tespit etmek için bir sistem önermiştir. Araştırma, 125.973 örnek ve 41 özellik içeren NSL KDD veri setini kullanarak gerçekleştirilmiştir. Veri seti, eğitim (%20) ve test (%80) olarak ikiye ayrılmıştır. PSO, saldırı tespiti için en önemli 12 özelliği belirlemek amacıyla kullanılmıştır. AdaBoost algoritması, en yüksek geri çağırma değerine (0,966667) ulaşarak, saldırı tespitinde üstün performans sergilemiştir. Makalede, IoMT'nin artan bağlantılı dünyasında güvenlik tehditlerini proaktif bir şekilde tespit etmenin önemi vurgulanmıştır. DÖ teknikleri, özellikle DSA, ağ saldırılarını tespit etmek için kullanılmıştır. Kim ve diğerlerinin KDD Cup 99 veri setini kullanarak geliştirdikleri DSA tabanlı STS modeli, ağ saldırılarını tespit etmede DÖ'nün sağladığı avantajları göstermiştir. Bu model, veri hazırlama, model oluşturma ve doğrulama aşamalarını içermektedir. Çalışma sonucunda, makine öğrenimi tabanlı saldırı tespit sistemlerinin IoMT cihazlarının güvenlik altyapısını güçlendirmede ve hasta sonuçlarını iyileştirmede önemli bir potansiyele sahip olduğu belirtilmiştir. Sağlık hizmeti sağlayıcılarının, bu tür sistemleri bütünleştirerek hasta bakımını iyileştirebileceği, maliyetleri azaltabileceği ve hassas tıbbi bilgilerin gizliliğini sağlayabileceği belirtilmiştir. Makale, IoMT'nin güvenliğini artırmak için makine öğrenimi ve DÖ tekniklerinin nasıl kullanılabileceğine dair önemli bilgiler sunmuştur [71].

Doriguzzi-Corin ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ güvenliği alanında ağ trafiği analizi için programlanabilir veri düzlemlerinin kullanımını incelemişler ve özellikle, P4DDLe adlı bir çerçeve önermişlerdir. Bu çerçeve, P4 tabanlı programlanabilir veri düzlemlerinin esnekliğinden yararlanarak paket düzeyinde özellik çıkarımı ve ön işleme yapmaktadır. P4DDLe, ağ trafiğinden ham paket özelliklerini, kategorik özellikler dâhil, çıkarmakta ve trafik akışlarının semantiğini koruyacak şekilde organize etmektedir. Bu yaklaşım, ağ saldırılarını tespit etmek için kullanılan ML algoritmalarının ihtiyaç duyduğu özelliklerin seçici olarak işlenmesini ve filtrelenmesini sağlamıştır. Çalışma, DDoS saldırı verileriyle yapılan deneysel değerlendirmelerle desteklenmiştir ve önerilen yaklaşımın ağ akışlarının kompakt ve yüksek kaliteli temsillerini toplamada oldukça etkili olduğunu göstermiştir. Bu, DDoS saldırılarının hassas bir şekilde tespit edilmesini sağlamaktadır. Makale, P4DDLe'nin mevcut yöntemlerden farklı olarak, paket düzeyinde özelliklerin esnekliğini ve merkezi SDN kontrol düzlemi tarafından sağlanan ağ genelindeki görünümü birleştirdiğini vurgulamıştır. Bu özelliklerin birleşimi, P4DDLe'yi programlanabilir veri düzlemleriyle ağ saldırı tespitine yönelik mevcut en iyi yaklaşımlardan ayırmaktadır [72].

Kim ve arkadaşları, 2024 yılında yaptıkları çalışmada, IoT cihazlarının yaygınlaşmasıyla birlikte bu cihazlara yönelik saldırıların arttığı ve geleneksel ağ tabanlı saldırı tespit sistemlerinin IoT ekosistemlerinin heterojen yapısı nedeniyle etkinliğini kaybettiği belirtilmiştir. Bu sorunu ele almak için, araştırmacılar ML tabanlı ağ seviyesinde saldırı tespit tekniklerini kullanmaktadır. Özellikle, transfer öğrenme teknikleri, IoT ortamlarında beklenmedik kötü niyetli trafiği tanımlamak için kullanılmaktadır. Çoğu IoT cihazı küçük ölçekli ortamlarda çalıştığından, öğrenme için uygun kaynak alanlarının seçimi zordur. Bu makale, bu sorunu ele almak için bir çerçeve sunmuştur. Çerçeve, transfer öğrenme için uygun bir kaynak alan veri seti seçimini önermiştir. Değerlendirmeler, önerilen çerçevenin uygun bir kaynak alan veri seti seçerek en yüksek doğruluğu sağladığını göstermiştir. Çalışma, IoT ortamlarında saldırı tespit doğruluğunu artırmak için uygun kaynak alan veri setlerinin seçilmesinin önemini vurgulamıştır. Önerilen çerçeve, transfer öğrenme sürecini daha verimli hale getirmiş ve hedef alanın

performansını artırmak için en uygun kaynak alanı seçmiştir. Bu, IoT güvenliği alanında çalışan araştırmacılar ve uygulayıcılar için değerli bir rehber sunmuştur [73].

Shaheed ve arkadaşları, 2024 yılında yaptıkları çalışmada, biyometrik güvenlik sistemlerinde sunum saldırılarını tespit etmek için DÖ tekniklerinin kullanımını sistematik bir şekilde incelemiştir. Biyometrik teknolojiler, parmak damarı, parmak izi, iris ve yüz tanıma gibi modalitelerle güvenliği artırmak için yaygın olarak kullanılmaktadır. Ancak, bu sistemler, özellikle sunum saldırıları (PAS) gibi çeşitli saldırılara karşı savunmasızdır. Sunum saldırıları, biyometrik sistemleri kandırmak ve yetkisiz erişim sağlamak amacıyla video, resim veya tam yüz maskeleri kullanmayı içerir. Makale, DÖ tabanlı sunum saldırı tespit (PAD) sistemlerini kapsamlı bir şekilde incelemiş ve parmak damarı, parmak izi, iris ve yüz tanıma sistemlerinde kullanılan son literatürü analiz etmiştir. DÖ yöntemlerinin, diğer tekniklere kıyasla üstün performans gösterdiği vurgulanmıştır. Çalışma, bu alandaki sorunları, ilerleme fırsatlarını ve derin öğrenme tabanlı PAD yöntemleriyle ilgili potansiyel çözümleri tartışmıştır. Belgede, derin öğrenme tabanlı PAD sistemlerinin performans analizi yapılmış ve en umut verici araştırma bulguları vurgulanmıştır. Ayrıca, DÖ modellerinin çapraz modalite veri setleri üzerinde değerlendirilmesi gerektiği belirtilmiştir, çünkü tek bir veri seti üzerinde eğitilen modellerin, farklı veri setleri üzerinde test edildiğinde daha düşük tespit oranlarına sahip olduğu gözlemlenmiştir. Gelecekteki araştırmaların, veri setine özgü özellikler yerine sahtecilik özelliklerini öğrenmeye odaklanarak PAD tespit oranlarını artırması gerektiği önerilmiştir [74].

Akhlat ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ tabanlı saldırıların tespiti için bir STS geliştirmeyi amaçlamıştır. Özellikle KDDCup-99 veri seti kullanılarak, ağ verilerinden en uygun özelliklerini seçmek için bir topluluk özellik seçimi yöntemi önerilmiştir. Ağ trafiğinin hızla artmasıyla birlikte, kötü niyetli kullanıcılar yeni saldırı yöntemleri geliştirmiştir. Bu nedenle, ağ güvenliğini sağlamak için etkili STS'lere ihtiyaç duyulmaktadır. Ancak, ağ verilerinin yüksek boyutluluğu, makine öğrenimi modelleri için zorluklar yaratmış ve bu da aşırı öğrenme ve yüksek hesaplama maliyetlerine yol açmıştır. Özellik seçimi, modelin yorumlanabilirliğini artırmak, kaynak gereksinimlerini

azaltmak ve genelleme yeteneğini artırmak için kritik bir adım olarak görülmüştür. Önerilen IDS-EFS yöntemi, ağ saldırılarını tespit etmek için en iyi performans gösteren özellik alt setini seçmeyi amaçlamıştır. Bu yöntem, her biri tek bir özellik üzerinde eğitilmiş modellerden oluşan bir kütüphane oluşturarak en uygun özellik alt setini belirlemeye çalışmıştır. Bu yaklaşım, özellikler arasındaki etkileşimleri dikkate alarak aşırı öğrenmeyi azaltmayı hedeflemiştir. KDDCup-99 veri seti, STS'lerin değerlendirilmesi için yaygın olarak kullanılan bir benchmark veri seti olarak kullanılmıştır. Bu veri seti, çeşitli ağ saldırı türlerini ve normal trafiği içermektedir. IDS-EFS algoritması, kütüphane oluşturma, topluluk özellik seçimi ve IDS inşası olmak üzere üç ana adımdan oluşmuştur. Seçilen özellikler, sağlamlığı ve doğruluğu ile bilinen bir RO sınıflandırıcısı eğitmek için kullanılmıştır. Yapılan deneyler, önerilen yöntemin diğer özellik seçimi yöntemlerine göre daha iyi performans gösterdiğini ortaya koymuştur. IDS-EFS, doğruluk, kesinlik, geri çağırma, F1 skoru ve AUC skoru gibi metriklerde üstün sonuçlar elde etmiştir. Ayrıca, hesaplama süresi de azalmış ve tespit oranları iyileştirilmiştir. Çalışma sonucunda, IDS-EFS, ağ saldırılarını tespit etmede etkili bir yöntem olarak öne çıkmıştır. Gelecekte, derin öğrenme modelleri kullanılarak özellik etkileşimlerinin daha derinlemesine incelenmesi ve tespit yeteneklerinin artırılması planlanmıştır [75].

Gong ve arkadaşları, 2024 yılında yaptıkları çalışmada, finans sektöründe ağ güvenliğini artırmak için DÖ tekniklerinin kullanımını ele almışlardır. Geleneksel makine öğrenimi yöntemlerinin yetersiz kaldığı durumlarda, DÖ tabanlı sistemlerin üstün genelleme yetenekleri sayesinde bilinmeyen tehditlerin daha etkili bir şekilde tespit edilebileceği vurgulanmıştır. Çalışma, özellikle Gelişmiş Kalıcı Tehditler gibi karmaşık saldırıların tespitinde DÖ modellerinin nasıl kullanılabileceğini incelemiştir. Deneysel sonuçlar, DÖ modellerinin yüksek doğruluk, hassasiyet ve geri çağırma oranları ile geleneksel yöntemlere kıyasla daha başarılı olduğunu göstermiştir. Bu modellerin, finansal ağların dijital tehditlere karşı dayanıklılığını artırmada önemli bir rol oynayabileceği belirtilmiştir. Makale, finansal kurumların dijital savunma stratejilerini geliştirmeleri ve potansiyel tehditlere karşı daha hızlı yanıt verebilmeleri için derin öğrenme teknolojilerini benimsemeleri gerektiğini önermiştir [76].

Silva ve arkadaşları, 2024 yılında yaptıkları çalışmada, IoT'nin gelişimiyle birlikte ağ güvenliğini sağlamak için ASTS'nin önemini vurgulamıştır. DSA, ASTS'lerde tehditleri doğru bir şekilde sınıflandırma ve yanıt verme yetenekleri nedeniyle yaygın olarak kullanılmaktadır. Ancak, DSA'ların gerçek zamanlı performansını değerlendirme konusunda literatürde yeterli tartışma bulunmamaktadır. Bu boşluğu doldurmak için, makale, bir DSA saldırı sınıflandırıcısının F1-skorunu tahmin etmek amacıyla çoklu doğrusal regresyon modelleri uygulamıştır. Bu modeller, gerçek zamanlı örnekler ile bilinen saldırı desenleri arasındaki üç farklı mesafe metriğini model değişkenleri olarak kullanarak değerlendirilmiştir. Sonuçlar, değişkenler arasındaki etkileşimleri içeren çoklu doğrusal regresyon modelinin, gelecekteki gözlemleri %94,4'lük bir ampirik kapsama oranıyla tahmin edebildiğini göstermiştir. Bu çalışma, ASTS araştırmacılarına ve uygulayıcılarına, sistemlerin performansını etkili bir şekilde izlemelerine olanak tanıyan önemli içgörüler sunmaktadır. Gelecekteki araştırmalar, zaman serisi analizi gibi gelişmiş istatistiksel tekniklere odaklanarak, F1-skoru tahminlerini karar verme süreçlerine entegre etmeyi ve sınıflandırıcıların etkinliğini artırmayı hedeflemektedir [77].

Wu ve arkadaşları, 2024 yılında yaptıkları çalışmada, araştırmalarda sıkça kullanılan veri setlerini ve veri ön işleme yöntemlerini incelemiş, ardından yedi DÖ tabanlı saldırı tespit modelini (derin otomatik kodlayıcılar, derin inanç ağları, derin sinir ağları, konvolüsyonel sinir ağları, tekrarlayan sinir ağları, generatif adversarial ağlar ve transformerlar) değerlendirmiştir. Ayrıca, BERT ve GPT serisi gibi büyük ölçekli öngörücü modellerin saldırı tespitindeki rolü ele alınmıştır. Makale, DÖ tabanlı saldırı tespit sistemlerinin daha doğru ve verimli hale gelmesi için dört ana araştırma alanı belirlemiştir: veri setlerinin güncellenmesi, düşük frekanslı saldırıların tespiti, gerçek dünya ortamlarında performansın artırılması ve kaynak verimliliği. Bu alanlarda ilerleme kaydedilerek, DÖ tabanlı saldırı tespit sistemlerinin değişen ağ tehditlerine ve uygulama senaryolarına daha iyi uyum sağlaması hedeflenmiştir. Sonuçta, DÖ tabanlı STS'ler, geleneksel yöntemlere göre daha yüksek doğruluk ve verimlilik sunmuştur. Ancak, bu sistemlerin gerçek dünya uygulamalarında daha iyi performans göstermesi için veri setlerinin güncellenmesi, model optimizasyonu ve kaynak verimliliği gibi alanlarda daha fazla araştırma yapılması

gerekmektedir. Gelecekteki çalışmalar, bu sistemlerin değişen ağ tehditlerine ve uygulama senaryolarına daha iyi uyum sağlamasına odaklanacaktır [78].

Baye ve arkadaşları tarafından 2024 yılında yapılan çalışma, DÖ tabanlı ASTS için Açık Set Tanıma (OSR) yöntemlerini kapsamlı bir şekilde incelemiştir. OSR, bilinenleri sınıflandırma ve bilinmeyenleri tanıma yeteneği sunarak, spam filtreleme ve saldırı tespit sistemleri gibi çeşitli makine öğrenimi destekli sistemlerin etkinliğini artırır. Çalışma, ASTS bağlamında beş OSR son katmanını (COOL, DOC, Energy tabanlı dağılım dışı, iiMod ve OpenMax) değerlendirerek, bu algoritmaların yapısı ile performansları arasındaki ilişkiyi keşfetmeyi amaçlamıştır. Sonuçlar, COOL ve Energy tabanlı algoritmaların, uygun eşik değerleri sağlandığında, bilinmeyen ağ aktivitelerini tespit etmede iyi performans gösterdiğini ortaya koymuştur. Ancak, OpenMax algoritmasının, bazı sınıfların seyrek elemanlar içerdiği ve dengesizliklerin yaygın olduğu veri setlerinde iyi performans göstermediği belirtilmiştir. Çalışma, OSR algoritmalarının, bilinen girdileri SoftMax kadar başarılı bir şekilde kategorize edemediğini ve bu durumun genel olarak daha düşük F1 skorlarına ve bilinmeyenlere karşı bir eğilime yol açtığını vurgulamıştır. Araştırma, ASTS içinde OSR algoritmalarının etkili bir şekilde dağıtılması için yapılandırılmış bir çerçeve sunmuş ve doğru hiperparametre ayarlamasının ve konfigürasyonun tespit yeteneklerini en üst düzeye çıkarmadaki kritik önemini vurgulamıştır. Gelecekteki araştırmalar, ASTS'nin uyarlanabilirliğini artırmak için gerçek zamanlı ağ koşullarına göre otomatik hiperparametre ayarlama ve dinamik algoritma seçimi üzerinde yoğunlaşacaktır. Ayrıca, yeni saldırıların davranış kalıplarına ve bilinen tehditlere benzerliklerine dayalı olarak ayrıntılı açıklamalar sağlamak için doğal dil işleme katmanı eklemeyi planlamaktadır. Bu bütüncül yaklaşımın, ağ güvenliği zorluklarının gelişen manzarasına karşı daha sofistike ve proaktif savunmalar sağlayacağı belirtilmiştir [79].

Arreche ve arkadaşları, 2024 yılında yaptıkları çalışmada, ağ saldırı tespiti için kara kutu açıklanabilir yapay zekâ (XAI) tekniklerini değerlendiren bir çerçeve sunmuşlardır. Çalışma, XAI yöntemlerinin ASTS'lerde uygulanabilirliğini değerlendirmek için altı farklı değerlendirme metriği kullanmıştır: tanımlayıcı doğruluk, seyrekleşme, kararlılık, verimlilik, sağlamlık ve bütünlük. Bu metrikler, XAI yöntemlerinin ağ güvenliği

analistlerine daha iyi açıklamalar sunarak ağ savunma görevlerinde daha etkili ve doğru olmalarına yardımcı olmayı amaçlamıştır. Çalışma, SHAP ve LIME gibi popüler XAI tekniklerini kullanarak üç farklı ağ saldırı veri seti (RoEduNet-SIMARGL2021, CICIDS-2017 ve NSL-KDD) üzerinde kapsamlı deneyler gerçekleştirmiştir. Yedi farklı yapay zekâ modeli (örneğin, RO, DSA vb.) kullanılarak XAI yöntemlerinin güçlü ve zayıf yönleri değerlendirilmiştir. Sonuçlar, SHAP'ın genel olarak LIME'dan daha iyi performans gösterdiğini, özellikle de açıklanabilirlik ve tanımlayıcı doğruluk metriklerinde daha iyi sonuçlar verdiğini göstermiştir. Ancak, her iki XAI yöntemi de gerçek dünya uygulamaları için bazı iyileştirmelere ihtiyaç duymaktadır, özellikle de sağlamlık ve bütünlük açısından. Çalışma, XAI yöntemlerinin ağ saldırı tespit sistemlerinde daha etkili bir şekilde kullanılabilmesi için gelecekteki araştırmalara yol göstermeyi amaçlamaktadır [80].

Cikambasi ve arkadaşları, 2024 yılında yaptıkları çalışmada, kurumsal ağ güvenliğini artırmak için derin öğrenme tekniklerinden yararlanan yenilikçi bir yapay zekâ tabanlı saldırı tespit modeli sunmuşlardır. Çalışmanın amacı, ağ trafiği verilerini analiz etmek için ESA ve YSA entegre eden bir Conv1d-LSTM Modeli önermektir. Model, modern ağ trafiğinin gerçekçi bir temsilini sağlayan CSE-CIC-IDS-2018 veri setini kullanarak karmaşık kalıpları ve zamansal bağımlılıkları etkili bir şekilde tespit etmiştir. Modelin performansı, geleneksel STS'ler ile karşılaştırıldığında üstün tespit yeteneklerini göstermek için doğruluk, kesinlik, geri çağırma ve F1 skoru kullanılarak değerlendirilmiştir. Ayrıca ESA ve YSA performanslarının karşılaştırmalı bir analizi yapılmış ve her yaklaşımın güçlü ve zayıf yönleri vurgulanmıştır. Araştırma, kurumsal ağları siber tehditlerden korumak için STS çerçevelerine gelişmiş yapay zekâ metodolojilerinin entegre edilmesinin önemini vurgulamıştır. Önerilen model, %99,97 doğruluk oranı ile üstün performans sergilemiştir [81].

Aslam ve arkadaşları, 2024 yılında yaptıkları çalışmada, SDN üzerinde DDoS saldırılarının tespiti için ML ve DÖ tabanlı çözümlerin etkinliğini vurgulamışlardır. Araştırma, ML ve DÖ algoritmalarının, DDoS saldırılarını tespit etmede geleneksel imza tabanlı yöntemlerden daha iyi performans gösterdiğini ortaya koymuştur. Çalışma,

mevcut kamuya açık DDoS veri setlerinin analizini yapmış ve SDN tabanlı veri setlerinin oluşturulmasının önemini vurgulamıştır. Ayrıca, en iyi ve en uygun özellikleri seçmek için kullanılan özellik seçimi algoritmalarının DDoS saldırılarını daha hızlı ve doğru bir şekilde tespit etmede kritik bir rol oynadığı belirtilmiştir. Çalışma, SDN güvenliğinde karşılaşılan araştırma zorluklarını ve gelecekteki araştırmalar için potansiyel alanları da ele alarak, bu alanda daha etkili tespit araçlarının geliştirilmesine yönelik önerilerde bulunmuştur [82].

Yadaw ve arkadaşları, 2024 yılında yaptıkları çalışmada, 6G ağlarının güvenliğini artırmak için, büyük ölçekli Çoklu Giriş Çoklu Çıkış (MIMO) sistemlerinde pilot kontaminasyon saldırılarını tespit etmek amacıyla Generative Adversarial Networks (GAN) kullanmayı önermişlerdir. Çalışma pilot kontaminasyon saldırılarının, kanal tahmininin verimliliğini düşürerek bilgi sızıntısı riskini artırabileceğini belirtmiştir. Çalışmada, GAN mimarisi kullanılarak, bu tür saldırıların tespit edilmesi hedeflenmiştir. GAN, iki modelden oluşur: sahte örnekler üreten bir jeneratör ve bu örnekleri gerçek olanlardan ayırt eden bir ayırt edici. Çalışmada, GAN'ın ayırt edici modeli olarak ResNet ve ters ResNet tabanlı ESA kullanılmıştır. Jeneratör modeli ise bir oto kodlayıcı olarak yapılandırılmıştır. Simülasyon sonuçları, önerilen modelin pilot kontaminasyon saldırılarını etkili bir şekilde tespit ettiğini göstermiştir. Modelin performansı, baz istasyonu anten sayısı ve pilot uzunlukları değiştirilerek değerlendirilmiştir. Çalışma, 6G ağlarının güvenliğini artırmak için DÖ tabanlı yaklaşımların potansiyelini vurgulamıştır [83].

Qazi ve arkadaşları, 2023 yılında yaptıkları çalışmada, modern toplumun karşı karşıya olduğu en acil sorunlardan biri olan ağ saldırılarına odaklanmıştır. Ağlar, küçükten büyüğe tüm ağları etkileyen tehditlerle karşı karşıyadır ve bu tehditleri tespit edip hafifletmek için bir STS'ye ihtiyaç duyulmaktadır. ML ve DÖ, etkili saldırı tespit sistemleri tasarlamak için kullanılmaktadır. Ancak, kötü niyetli tehditler sürekli olarak ortaya çıkıp evrildiği için, ağlar gelişmiş bir güvenlik çözümüne ihtiyaç duymaktadır. Bu nedenle, etkili ve akıllı bir saldırı tespit sistemi geliştirmek önemli bir araştırma konusudur. Bu çalışmada, ağ üzerindeki saldırıları tespit eden DÖ tabanlı hibrit bir saldırı

tespit sistemi (HDLNIDS) geliştirilmiştir. Önerilen sistem, yerel özellikleri toplamak için bir ESA ve özellikleri çıkarmak için derin katmanlı bir YSA kullanmıştır. Araştırma, önerilen sistemin etkinliğini belirlemek için CICIDS-2018 veri seti kullanılarak gerçekleştirilmiştir. Araştırmanın bulguları, önerilen HDLNIDS'nin mevcut saldırı tespit yaklaşımlarını %98,90 ortalama doğrulukla geride bıraktığını göstermiştir. Makale, DÖ tabanlı saldırı tespit sistemlerinin geliştirilmesi ve mevcut sistemlerin sınırlamalarını aşma potansiyelini vurgulamıştır. Gelecekteki çalışmalar, modelin sıfıncı gün saldırılarını ele alma kapasitesini artırmayı ve gerçek ağ trafiği üzerinde değerlendirmeler yapmayı hedeflemektedir [84].

Hnamte ve arkadaşları, 2023 yılında yaptıkları çalışmada, ağ saldırılarını tespit etmek için iki aşamalı yeni bir DÖ modeli olan LSTM-AE'yi tanıtmışlardır. Bu model, LSTM ve AE tekniklerini birleştirerek, modern ağ senaryolarında saldırıları etkili bir şekilde tespit etmeyi amaçlamıştır. Çalışmada, CICIDS2017 ve CSE-CICIDS2018 veri setleri kullanılarak modelin performansı test edilmiştir. Sonuçlar, önerilen modelin diğer popüler saldırı tespit modellerine göre daha yüksek bir tespit performansı sergilediğini göstermiştir. Makale ayrıca, DÖ tabanlı saldırı tespit sistemlerinin geliştirilmesi ve değerlendirilmesi için veri setlerinin düzenli olarak güncellenmesi gerektiğini vurgulamıştır [85].

Bakhsh ve arkadaşları, 2023 yılında yaptıkları çalışmada, IoT ağlarının güvenliğini artırmak için DÖ tabanlı bir STS geliştirilmesini ele almıştır. Araştırma, IoT ağlarındaki siber tehditleri azaltmak için DÖ tekniklerinin kullanılmasını önermiştir. Çalışmada, IoT ağlarını siber saldırılardan korumak için İleri Beslemeli Sinir Ağları (FFNN), LSTM ve Rastgele Sinir Ağları (RandNN) gibi DÖ modelleri kullanılmıştır. Bu modellerin her biri, IoT ağ trafiğindeki düzensizlikleri tespit etmede farklı avantajlar sunmaktadır. Örneğin, FFNN karmaşık IoT ağ trafiği modellerini işleyebilirken, LSTM uzun vadeli bağımlılıkları yakalamada etkilidir. RandNN modeli ise rastgele bağlantıları ve esnek dinamikleri ile ağ verilerinden öğrenme yeteneğine sahiptir. Araştırma, önerilen DÖ tabanlı STS'nin, CIC-IoT22 veri seti kullanılarak mevcut en iyi DÖ-STs'lerle karşılaştırıldığında üstün performans sergilediğini göstermiştir. FFNN modeli %99,93,

LSTM modeli %99,85 ve RandNN modeli %96,42 doğruluk oranı ile saldırıları tespit edilebilmiştir. Bu modeller, IoT ağlarındaki güvenlik sorunlarına hızlı yanıtlar üreterek saldırı tespitini artırma potansiyeline sahiptir. Makale, IoT güvenlik zorluklarını, DÖ uygulamalarını ve önerilen STS modellerinin matematiksel modellemesini detaylandırmıştır. Ayrıca, önerilen modellerin performansını değerlendirmek için çeşitli deneysel sonuçlar ve karşılaştırmalar sunulmuştur. Çalışma, IoT ağlarının güvenliğini artırmak için DÖ tabanlı STS'lerin potansiyelini vurgulamış ve gelecekteki araştırmalar için çeşitli önerilerde bulunmuştur [86].

Mohammadian ve arkadaşları tarafından 2023 yılında yapılan çalışmada, DÖ tabanlı ASTS'lere karşı bir adversarial saldırı yöntemi önerilmiştir. DÖ modelleri, ağ saldırılarını tespit etmede etkili olsa da adversarial saldırılara karşı savunmasızdır. Çalışma, Jacobian Saliency Map kullanılarak en iyi özellik grubunu belirleyip, bu özellikler üzerinde küçük değişiklikler yaparak adversarial örnekler üretmeyi hedeflemiştir. Önerilen yöntem, CIC-IDS2017, CIC-IDS2018 ve CIC-DDoS2019 veri setleri üzerinde test edilmiştir. Sonuçlar, önerilen yöntemin daha az sayıda özellik kullanarak diğer saldırı yöntemlerine göre daha etkili adversarial örnekler üretebildiğini göstermiştir. Örneğin, CIC-IDS2017 veri setinde sadece üç özellik ve 0,1 büyüklüğünde bir pertürbasyon kullanarak örneklerin %18'inden fazlası için adversarial örnekler üretilebilmiştir. Çalışma ayrıca saldırının parametreleri, mesafe metrikleri ve hedef model performansı üzerinde derinlemesine bir analiz sunmaktadır [87].

Sharma ve arkadaşları tarafından 2023 yılında yapılan çalışmada, IoT ağlarında siber saldırıları tespit etmek için DÖ tekniklerini kullanan bir aykırılık tabanlı ASTS önerilmiştir. IoT cihazlarının artan kullanımı, bu ağları çeşitli siber saldırılara karşı savunmasız hale getirmiştir. Bu nedenle, etkili bir STS, IoT ağlarını korumak için önemli bir çözüm olarak sunulmuştur. Önerilen sistem, DÖ tekniklerini kullanarak IoT ağlarındaki aykırılıkları tespit etmeyi amaçlamıştır. Özellikle, yüksek korelasyonlu özelliklerin çıkarıldığı bir filtre tabanlı özellik seçimi ve DSA modeli geliştirilmiştir. Model, UNSW-NB15 veri seti üzerinde test edilmiş ve dört saldırı sınıfı için %84 doğruluk elde edilmiştir. Sınıf dengesizliği sorununu çözmek için Azınlık saldırı

sınıflarının sentetik verilerini üretmek amacıyla Generative Adversarial Networks (GANs) kullanılmış ve dengeli sınıf veri seti ile %91 doğruluk sağlanmıştır. Makale, IoT ağlarındaki güvenlik tehditlerini ele alırken, veri ön işleme, veri artırma, özellik seçimi ve DSA modelinin eğitimi ve test edilmesi gibi adımları içeren bir çerçeve sunmaktadır. Sonuçlar, önerilen modelin IoT ağlarında saldırı tespitinde etkili olduğunu göstermiştir. Gelecekte, modelin gerçek zamanlı saldırı tespiti için daha da geliştirilmesi önerilmektedir [88].

Yi ve arkadaşları tarafından 2023 yılında yapılan çalışmada, DÖ'nün ağ saldırı tespitinde nasıl uygulandığını incelenmiştir. Makale, ağ saldırı teknolojilerinin evrimini ve bu teknolojilerin tespit edilmesinde karşılaşılan zorlukları ele almıştır. DÖ, karmaşık ve heterojen ağ trafiği verilerinin otomatik olarak temsil edilmesi, dengesiz ağ saldırı örnekleri ve saldırıların sürekli evrimi gibi sorunları çözmek için kullanılır. Çalışma, derin öğrenmenin ağ saldırı tespitinde trafik karakterizasyonu ve özellik çıkarımı, tehdit tespit modeli eğitimi ve modelin sağlamlığının artırılması gibi önemli yönlerini özetlemiştir. Makale, derin öğrenmenin ağ saldırı tespitinde karşılaştığı mevcut sorunları ve zorlukları da tartışmıştır. Bunlar arasında veri kategorilerinin dengesizliği, yüksek boyutlu büyük veri işleme, kavram dağılımı kayması, modelin gerçek zamanlı performansı ve yorumlanabilirliği ile model güvenliği yer almıştır. Çalışma, DÖ'nün ağ saldırı tespitinde nasıl kullanılabileceğine dair kapsamlı bir bakış açısı sunar ve gelecekteki araştırmalar için rehberlik eder [89].

Du ve arkadaşları tarafından 2023 yılında yapılan çalışma, IIoT için DÖ teknikleri kullanarak tasarlanmış bir ağ saldırı tespiti sınıflandırma modelini sunmaktadır. NIDS-CNNLSTM adlı model, ağ trafiği verilerini etkili bir şekilde tanımlamak ve sınıflandırmak için Zaman Serisi Verilerinde LSTM ağlarının güçlü öğrenme yeteneğini ve Özellik Seçimi için ESA kullanmaktadır. Model, KDD CUP99, NSL_KDD ve UNSW_NB15 gibi klasik veri setleri kullanılarak eğitilmiş ve değerlendirilmiştir. Bu veri setleri, ağ saldırı tespiti araştırmalarında yaygın olarak kullanılan kıyaslama ölçütleridir. Model hem ikili hem de çoklu sınıflandırma senaryolarında yüksek doğruluk ve düşük yanlış pozitif oranları göstermiştir. Önceki modellere kıyasla genel performansı önemli

ölçüde geliştirilmiş olup, IIoT'deki büyük ölçekli ve çok senaryolu ağ verileri için daha uygun hale getirilmiştir. Makale, modelin etkinliğini göstermek için doğrulama doğruluğu, eğitim kaybı ve karışıklık matrisleri gibi ayrıntılı deneysel sonuçlar sunmuştur. Ayrıca, aşırı uyumu azaltmak için tam bağlantılı katman yerine küresel ortalama havuzlama katmanını kullanılması ve daha iyi kararlılık ve güvenilirlik için iki katmanlı LSTM seçilmesi gibi iyileştirmeler vurgulanmıştır. Yazarlar, gelecekteki çalışmalarda veri seti dengesizliklerini ele alarak ve küçük örnek trafik için sınıflandırma doğruluğunu artırarak modeli daha da geliştirmeyi önermiştir. Genel olarak, makale, IIoT ortamında ağ güvenliğini artırmak için gelişmiş DÖ tekniklerinin kullanılmasının önemini vurgulamıştır [90].

Hnamte ve Hussain tarafından 2023 yılında yapılan çalışma, DÖ tabanlı bir ağ saldırı tespit sistemi olan DCNNBiLSTM modelini tanıtmıştır. Bu model, ağ trafiğini izleyerek şüpheli veya anormal aktiviteleri tespit eden ve önleyici tedbirler alan bir sistemdir. Çalışma, özellikle DDoS saldırılarını tespit etmek için geliştirilmiş olup, CICIDS2018 ve Edge_IIoT veri setleri kullanılarak test edilmiştir. Model, çok sınıflı sınıflandırma görevlerinde sırasıyla %100 ve %99,64 doğruluk oranlarına ulaşmıştır. Makale, DÖ modellerinin, özellikle ESA ve BiLSTM'nin, ağ saldırılarını tespit etmede nasıl etkili olduğunu göstermiştir. ESA, yerel özellikleri çıkarmada üstünken, BiLSTM uzun ve kısa vadeli ilişkileri yakalamada etkilidir. Bu iki modelin birleşimi, ağ saldırılarını daha doğru bir şekilde tespit etmeyi sağlamıştır. Çalışma, mevcut ASTS'lerin çoğunun imza tabanlı yaklaşımlara odaklandığını, ancak bu yaklaşımların yeni saldırı türlerini tespit etmede yetersiz kaldığını belirtmektedir. DCNNBiLSTM modeli, bu eksiklikleri gidermek için geliştirilmiş ve modern saldırı senaryolarını temsil eden daha yeni veri setleri ile test edilmiştir. Çalışma sonucunda, önerilen model, ağ güvenliği alanında daha etkili bir saldırı tespit sistemi geliştirilmesine katkıda bulunmakta ve gelecekteki derin öğrenme modelleri için önemli bilgiler sağlamaktadır [91].

Mohamed ve Ejbalı tarafından 2023 yılında yapılan çalışma, ağ güvenliği için aykırılık tabanlı bir ağ saldırı tespit sistemi geliştirmek amacıyla derin SARSA tabanlı bir pekiştirmeli öğrenme yaklaşımını tanıtmıştır. Çalışmanın ana hedefi, modern ve karmaşık

saldırıların tespit doğruluğunu artırmaktır. Bu amaçla, SARSA tabanlı bir pekiştirmeli öğrenme algoritması, DSA ile birleştirilmiştir. Model, NSL-KDD ve UNSW-NB15 veri setleri kullanılarak test edilmiştir ve diğer klasik ML ve DÖ yaklaşımlarına kıyasla daha iyi performans göstermiştir. Çalışma, özellikle dengesiz ve modern saldırıların tespitinde yüksek doğruluk, geri çağırma, kesinlik ve F1-skoru gibi metriklerde üstün sonuçlar elde etmiştir. Gelecekteki çalışmalar için, modelin diğer derin pekiştirmeli öğrenme algoritmaları ile karşılaştırılması ve öncelikli deneyim tabanlı bir derin SARSA algoritmasının geliştirilmesi önerilmiştir [92].

Rathee ve arkadaşları tarafından 2023 yılında yapılan çalışma, DÖ tekniklerini kullanarak siber saldırıların tespit edilmesi ve önlenmesi üzerine odaklanmıştır. Çalışma, çeşitli DÖ modellerini (sığ, derin, evrimsel ve dikkat mekanizması tabanlı ağlar) inceleyerek, bu modellerin siber saldırıları tespit etme yeteneklerini değerlendirmiştir. Araştırma, NSL-KDD, Kyoto2006 ve UNSW-NB15 gibi veri tabanları üzerinde test edilmiştir. Makale, siber saldırıların sınıflandırılması ve tespit edilmesi için kullanılan farklı DÖ modellerinin performansını karşılaştırmıştır. Sonuçlar, dikkat mekanizması tabanlı modellerin ve sığ ağların NSL-KDD veri setinde daha iyi performans gösterdiğini, Kyoto veri setinde ise dikkat modelinin daha iyi sonuçlar verdiğini göstermiştir. UNSW-NB15 veri setinde ise en iyi sonuçlar ESA modeli ile elde edilmiştir. Çalışma, siber güvenlikte derin öğrenme tekniklerinin potansiyelini vurgulamış ve bu tekniklerin siber saldırıların tespitinde nasıl etkili bir şekilde kullanılabileceğini göstermiştir. Ayrıca, farklı modellerin doğruluk, kesinlik, geri çağırma ve F1-skorumu gibi metriklerle performansları detaylı bir şekilde analiz edilmiştir [93].

Umair ve arkadaşları tarafından 2022 yılında yapılan çalışma, ağ trafiğini izleyerek şüpheli aktiviteleri tespit eden bir ASTS geliştirmeyi amaçlamıştır. Geleneksel yöntemlerin büyük veri setleriyle başa çıkamaması nedeniyle, bu çalışmada daha yüksek doğruluk elde etmek için istatistiksel bir yaklaşım önerilmiştir. Özellikler, çok katmanlı bir ESA kullanılarak çıkarılmış ve bir softmax sınıflandırıcı, ağ saldırılarını sınıflandırmak için kullanılmıştır. Ayrıca, ağ saldırılarını sınıflandırmak için çok katmanlı DSA da uygulanmıştır. Deneyler, NSL-KDD ve KDDCUP'99 gibi yaygın

olarak kullanılan iki veri seti üzerinde gerçekleştirilmiştir. Önerilen modelin performansı, doğruluk, geri çağırma, F1 skoru ve kesinlik gibi dört performans metriği kullanılarak değerlendirilmiştir. Deneysel sonuçlar, önerilen yaklaşımın diğer STS'lere kıyasla daha iyi doğruluk (99%) elde ettiğini göstermiştir. Bu çalışma, DÖ tekniklerinin siber güvenlik önlemlerini artırma potansiyelini vurgulamıştır [94].

Wei ve arkadaşları tarafından 2023 yılında yapılan çalışma, DÖ tabanlı ASTS (DÖ-ASTS) için açıklamalar sağlayarak aktif saldırı yanıtlarını kolaylaştıran XNIDS adlı yeni bir çerçeveyi tanıtmıştır. DÖ-ASTS, karmaşık desenleri ve küçük sapmaları yakalama yetenekleri sayesinde üstün performans göstermiştir, ancak tespit ettikleri saldırılara aktif olarak yanıt verememektedir. Bunun nedeni, tespit sonuçları ile eyleme geçirilebilir yorumlar arasındaki anlamsal boşluktur. XNIDS, DÖ-ASTS'nin tespit sonuçlarını açıklayarak bu boşluğu kapatmayı ve savunma kuralları oluşturmayı amaçlamıştır. Çalışma, XNIDS'in dört modern DÖ-ASTS üzerinde değerlendirildiğini ve önceki açıklama yöntemlerine göre daha yüksek sadakat, seyrek, tamlık ve kararlılık sağladığını göstermiştir. Ayrıca, XNIDS'in pratik savunma kuralları üretebildiği, DÖ-ASTS davranışlarını anlamaya yardımcı olduğu ve tespit hatalarını giderebildiği gösterilmiştir [95].

Chaganti ve arkadaşları tarafından 2023 yılında yapılan çalışma, IoT ağlarında SDN destekli bir saldırı tespit sistemi geliştirmek için DÖ tabanlı bir yaklaşım önermişlerdir. IoT cihazlarının internet bağlantılarının artmasıyla birlikte IoT tabanlı saldırıların sayısı da artmıştır. Geleneksel saldırı tespit sistemleri, IoT protokollerini destekleyen ve merkezi bir ağ mimarisi kullanan SDN gibi ağ ortamlarında etkili olamamaktadır. Bu çalışmada, IoT ağlarında SDN destekli saldırı tespit sistemi kullanılarak ağ saldırılarını tespit etmek için LSTM tabanlı bir yaklaşım önerilmiştir. Önerilen model, iki SDN-IoT odaklı veri setinde test edilmiş ve saldırıları %97,1 doğrulukla tespit edebilmiştir. Ayrıca, ML ve DÖ modellerinin performansları karşılaştırılmış ve LSTM tabanlı mimarinin ağ saldırılarının çok sınıflı sınıflandırmasında etkili olduğu gösterilmiştir. Makale, SDN ve IoT ağlarında saldırı tespiti için DÖ tekniklerinin kullanımını incelemiş ve önerilen

yöntemin genel olarak çeşitli SDN saldırılarını ele alabilecek kadar sağlam olduğunu göstermiştir [96].

Li ve arkadaşları tarafından 2023 yılında yapılan çalışma, ağ saldırı tespiti için verimli bir federe öğrenme sistemi olan Dinamik Ağırlıklı Toplama Federated Learning'i (DAFL) tanıtmışlardır. Yüksek kaliteli saldırı verilerinin eksikliği nedeniyle, tek bir işletmenin derinlemesine bir ASTS oluşturması zordur. Federe öğrenme, veri gizliliğini korurken tespit performansını artırmak için kullanılmıştır. DAFL, yerel modeller için dinamik filtreleme ve ağırlıklandırma stratejileri uygulayarak, daha az iletişim yükü ile ağ saldırılarını daha iyi tespit edebilir. DAFL'nin tasarımı detaylı bir şekilde açıklanmış ve deneysel sonuçlar, düşük iletişim yükü ile mükemmel tespit performansı elde edilebileceğini göstermiştir. Makale, federe öğrenme ve ağ saldırı tespiti konularındaki en son araştırmaları gözden geçirir ve DAFL'nin üstün tespit performansı ve verimliliği ile umut verici bir yaklaşım olduğunu ortaya koymuştur [97].

Shafieian ve Zulkarnine tarafından 2023 yılında yapılan çalışma, düşük ayak izi olan ağ saldırılarını tespit etmek için çok katmanlı yığma (stacking) topluluk öğrenme modellerinin kullanımını incelemiştir. Ağ saldırı tespiti alanında, özellikle yanlış pozitifler konusunda hata toleransı düşüktür. Bu çalışmada, katı kabul kriterleri tanımlanmış ve bu kriterleri karşılayan çok az sayıda topluluk öğrenme sınıflandırıcısının olduğu gösterilmiştir. Çalışma, bagging, boosting ve stacking tekniklerini karşılaştırmakta ve çok katmanlı yığma yöntemlerinin diğer topluluk tekniklerinden ve DÖ modellerinden daha iyi performans gösterdiğini ortaya koymuştur. Çalışmanın bulguları arasında, yedi farklı temel öğreniciye dayanan yüzlerce topluluk modelinden yalnızca üç çok katmanlı yığma modelinin katı kabul kriterlerini karşıladığı ve 0,99 F1 skoru ile 0,001 yanlış pozitif oranı elde ettiği belirtilmiştir. Bu modeller, basit sınıflandırma algoritmalarını kullanarak yüksek performanslı sınıflandırıcılar oluşturabilmiştir. Ayrıca, bu topluluk modellerinin, düşük ayak izi olan ağ saldırılarını sınıflandırmada farklı derin sinir ağı modellerinden daha iyi performans gösterdiği vurgulanmıştır [98].

Son beş yılda yapılan doksanın üzerinde çalışma incelenmiş ve ASTS'ler üzerine DÖ ve ML tekniklerinin kullanımı detaylı bir şekilde ele alınmıştır. Çalışmalar, geleneksel imza tabanlı yöntemlerin yetersiz kaldığı durumlarda DÖ ve ML tabanlı yaklaşımların daha etkili olduğunu göstermiştir. Özellikle, LSTM, ESA, AE, BiLSTM gibi DÖ modellerinin yanı sıra hibrit yaklaşımlar, transfer öğrenimi, dikkat mekanizmaları ve optimizasyon algoritmaları kullanılarak ağ trafiği analizi, sıfırıncı gün saldırıları, DDoS, SQL enjeksiyonu, IoT ve IIoT güvenliği gibi çeşitli alanlarda yüksek doğruluk oranları elde edilmiştir. Çalışmalarda, veri dengesizliği sorunlarını çözmek için SMOTE, GAN ve diğer veri artırma teknikleri kullanılmış, ayrıca boyut indirgeme ve özellik seçimi yöntemleriyle işlem yükü azaltılmıştır. Hibrit modeller hem bilinen hem de bilinmeyen saldırıları tespit etmede üstün performans sergilemiş, özellikle FL ve blockchain tabanlı yaklaşımlar, gizlilik ve güvenlik avantajları sağlamıştır. Adversarial saldırılara karşı savunma stratejileri, XAI teknikleri ve gerçek zamanlı tespit sistemleri de önemli araştırma konuları arasında yer almıştır. Çalışmalar, DÖ tabanlı ASTS'lerin yüksek doğruluk, hassasiyet ve F1 skorları ile geleneksel yöntemleri geride bıraktığını, ancak veri setlerinin güncellenmesi, model optimizasyonu ve gerçek dünya uygulamalarında ölçeklenebilirlik gibi zorlukların devam ettiğini vurgulamıştır. Çalışmaların çoğunluğu gelecekte, daha sofistike hibrit modeller, dinamik tehditlere uyum sağlayan sistemler ve açıklanabilir yapay zekâ tekniklerinin entegrasyonu ile ağ güvenliğinin daha da güçlendirilmesi hedefine vurgu yapmıştır.

Ancak incelenen makale ve tezlerin her biri belli yöntemlere ve veri setlerine odaklanmış olup genel durumu özetlememektedirler. Bu çalışma literatürdeki böyle bir eksiği kapatmaktadır. İncelenen yaklaşık 100 makale ve tezde 50 farklı sınıflayıcı ve 40 farklı veri setine odaklanılmıştır. Çalışma sonunda ortaya konan Çizelge 1 araştırmacılara yeni çalışmalarında yol haritası sunmak bakımından faydalı olacaktır. Özellikle STS/SES sistemlerinde yanlış negatif oranlarının düşürülmesinin önemi düşünüldüğünde bu konuya odaklanmış çalışmaların derlenerek tablollaştırılması değerlidir.

Çizelge 1 Yanlış Negatif Oranlarına Odaklanan Çalışmalar

Çalışma	Yıl	Sınıflayıcı	Veri seti	Metrikler	Avantajları	Dezavantajları
[8]	2021	LSTM, MLP, CNN, GNB, SVM, KNN, DT, RF	CSIC-2010, DRUPAL, PKDD2007, Vulnbank, SQL Payload Dataset (GitHub), XSS Payload Dataset (GitHub)	Doğruluk (Accuracy): %95 - %99,79 (model ve veri setine göre değişiklik göstermiştir) Hassasiyet (Precision): %97,4 - %99 Özgüllük (Recall): %92 - %99,7 F1-Skoru: %96,8 - %98,5 ROC Eğrisi Altındaki Alan (AUC): 0,946 (LightGBM)	Yanlış Alarm Oranlarının Azaltılması: Çalışma, yanlış pozitif (FP) ve yanlış negatif (FN) oranlarını düşürerek saldırı tespitinde daha güvenilir sonuçlar elde etmiştir. Çoklu Sınıflandırma: SQLi ve XSS saldırılarını alt türlerine ayırarak daha detaylı bir analiz yapılmıştır. Özellik Çıkarma Yöntemi: Kelimelerin öklitsel uzaklıklarının hesaplanması ve sembolize edilmesi, saldırı vektörlerinin daha net bir şekilde tanımlanmasını sağlamıştır. Geniş Algoritma Kullanımı: Hem makine öğrenmesi (GNB, SVM, KNN, DT, RF) hem de derin öğrenme (LSTM, MLP, CNN) algoritmaları kullanılarak kapsamlı bir karşılaştırma yapılmıştır. Gerçek Zamanlı Kullanım Potansiyeli: Test süreleri ve performans metrikleri, yöntemin gerçek zamanlı sistemlerde uygulanabilir olduğunu göstermektedir.	Veri Seti Dengesizliği: Veri setindeki dengesizlikler (normal ve zararlı isteklerin eşit olmaması) bazı sonuçları etkilemiştir. Saldırı Türlerinin Sınırlılığı: Çalışma yalnızca SQLi ve XSS saldırılarına odaklanmıştır. Diğer kod enjeksiyon türleri (ör. CSRF, RCE) ele alınmamıştır. Donanım Bağımlılığı: Performans, kullanılan donanımın kapasitesine doğrudan bağlıdır. Veri Seti Zenginleştirme Gereksinimi: Daha geniş ve çeşitli veri setleriyle çalışıldığında başarı oranının artabileceği belirtilmiştir.


Çalışma	Yıl	Sınıflayıcı	Veri seti	Metrikler	Avantajları	Dezavantajları
[21]	2024	MLP	CIC-IDS2017	Doğruluk (Accuracy): %99 Yanlış negatif oranı (False Negative Rate - FNR): Başlangıçta %1'den %30'a yükselmiş, ancak model adaptasyonu sonrası %1'e düşmüştür.	Sürekli eğitim ile sıfır-gün saldırılarına (zero-day attacks) karşı adaptasyon yeteneği. Kullanıcı gizliliği korunur ve veriler paylaşılmadan model eğitimi yapılır.	Metaverse için özel güvenlik veri setlerinin eksikliği. Veri etiketleme süreci karmaşık ve uzmanlık gerektiriyor. Blockchain depolama kapasitesi sınırlı cihazlar için sorun yaratabilir. Sosyal mühendislik saldırılarına karşı teknik çözümler sınırlı.
[27]	2024	GEO-SMPIF	NSL-KDD, UNSW-NB15	Doğruluk (Accuracy): NSL-KDD %99,99, UNSW-NB15 %99,97 Hassasiyet (Precision): NSL-KDD %99,75, UNSW-NB15 %99,86 Duyarlılık (Recall/Sensitivity): NSL-KDD %100, UNSW-NB15 %100 F-Ölçütü (F-Measure): NSL-KDD %99,58, UNSW-NB15 %98,05 Yanlış Pozitif Oranı (FPR):	Yüksek doğruluk ve düşük yanlış alarm oranı. Optimizasyon algoritmalarıyla hiperparametre ayarlarının otomatikleştirilmesi. NSL-KDD ve UNSW-NB15 veri setlerinde üstün performans.	Modelin karmaşıklığı nedeniyle eğitim süresi uzun olabilir. Diğer veri setleri ve gerçek zamanlı sistemlerde performansın test edilmesi gereklidir.

Çalışma	Yıl	Sınıflayıcı	Veri seti	Metrikler	Avantajları	Dezavantajları
				NSL-KDD %0,04, UNSW-NB15 %0,065 Yanlış Negatif Oranı (FNR): NSL-KDD %0, UNSW-NB15 %0		
[63]	2024	CNN, LSTM	CSE-CIC-IDS 2018	Doğruluk (Accuracy): 98,53%, Hassasiyet (Precision): 98,59%, Duyarlılık (Recall): 99,42%, F1-Skoru: 99,00%, Yanlış Pozitif Oranı (FPR): 0,0388%, Yanlış Negatif Oranı (FNR): 0,0058%	Gerçek zamanlı ve yüksek doğrulukta saldırı tespiti, hem bilinen hem de bilinmeyen saldırıları algılama, dinamik ve hassas sağlık verilerine uyum sağlama.	Sadece bir veri seti üzerinde test edilmiş, tespit süresi ölçülmemiştir.
[71]	2024	AdaBoost, KNN, Naive Bayes	NSL KDD	Accuracy: 0,966667, Recall: 0,966667	Yüksek doğruluk, hızlı adaptasyon, düşük yanlış negatif oranı.	Veri dengesizliği, parametre ayarına duyarlılık, yeni tehditlere karşı sınırlı performans.
[72]	2024	Lucid	CIC-DDoS2019, ISCX2012, CIC2017,	Accuracy=0,93, F1 Score=0,93, False Positive Rate=0,0154, Precision=0,99, Recall=0,9	Paket seviyesinde özellik çıkarımı, Bellek ve kontrol kanalı optimizasyonu, DDoS saldırılarında düşük yanlış negatif oranı,	Yüksek paket oranlarında çarpışma riski, Özellik azaltımı nedeniyle sınıflandırıcı performansında hafif düşüş.

Çalışma	Yıl	Sınıflayıcı	Veri seti	Metrikler	Avantajları	Dezavantajları
			CSECIC2018			


3. SALDIRI VE SALDIRI T RLER 

D nyamız  nemli bir dijital d n    m ge ermektedir. G nl k hayatın rutini olan bir ok i  artık dijital ortama ge mektedir. Bankacılık i lemleri, devletle olan ili kiler, e itim ve   retim faaliyetleri, yayıncılık faaliyetleri, e lence sekt r  ve di er ismini saymadığımız bir ok alan i lemlerin  o unlu unun dijital olarak yapıldığı ortamlar haline gelmi  durumdadır. Faaliyetlerin dijital ortamda yapılması durumu s z konusu oldu unda b t nl k, gizlilik ve eri ilebilirlik kavramları bir denge i erisinde olmak zorundadır. Bu durum  ekil 2’de g rsel olarak da sunulmu tur. Bilginin, kaynakların ve servislerin b t nl    bozulmadan yetkili ki ilerce yetkisiz ki ilerin kullanımından korunarak eri ilebilirli in s rekli halde tutulması  ok  nemlidir.



 ekil 2 Bilgi G venli inin Unsurları

Bilgi g venli i, bilgiye s rekli eri ilebilen bir ortamda, bilginin g ndericisinden ba layarak alıcısına kadar gizlilik i erisinde, bozulmadan, de i ikli e u ramadan ve ba kaları tarafından ele ge irilmeden g venli bir  ekilde iletilmesi olarak tanımlanabilir [99]. Bilgi g venli inin sa lanması i in uygun g venlik politikalarının belirlenmesi ve uygulanması gereklidir. Bilgi g venli ini sa lamak katmanlı bir yapı i erisinde ger ekle tirilir. Bu yapı  ekil 3’te g rsel olarak sunulmu tur.



Şekil 3 Bilgi Güvenliğini Sağlama Katmanları

Güvenlik politikaları, gerçekleştirilen faaliyetlerin sorgulanması, yapılan erişimlerin izlenmesi, gerçekleştirilen değişikliklerin kayıtlarının tutulup değerlendirilmesi, veri silme işlemlerinin sınırlandırılması gibi bazı kullanım şekillerine indirgenebilmektedir [100].

Bilgi güvenliği farklı alanlar ve katmanlarda güvenlik sağlamak adına geniş bir yelpazeye sahiptir. Ağ güvenliği, veri güvenliği, uygulama güvenliği, kimlik ve erişim güvenliği gibi kategorilere ve bu kategorilerin alt kategorilerine ayrılabilir.

Ağ kaynaklarına yetkisiz erişim çabasına, kaynakların kötüye kullanımı ya da kullanım dışı bırakılmasına saldırı denilmektedir. Saldırıları çok değişik şekillerde ortaya çıkmaktadır. Yaygın saldırı türleri aşağıda sıralanmıştır:

- Aktif Ataklar (Active Attacks)
- Dağıtık Ataklar (Distributed Attacks)
- Dışsal Ataklar (External Attacks)
- Fraud Atak
- İçsel Ataklar (Insider Attacks)
- Keşif Atakları (Discovery Attacks)
- Kod Atakları (Code Attacks)
- Pasif Ataklar (Passive Attacks)

- Şifre Atakları (Password Attacks)
- Yakın Atak (Close-in Attacks)

Teknik olarak çok yaygın bir biçimde kullanılan ve bu çalışmada incelenen veri setlerinde geçen atak Türleri ise, DoS, Probe, U2R, R2L, Brute Force, Infiltration, SQL Injection ve Botnet ataklarıdır.

- DoS Atakları; aktif ataklardır. Bu saldırılar genellikle, TCP / IP protokolü yapısındaki güvenlik zafiyetini kullanarak bir sunucuya birden fazla bağlantı isteği göndermek suretiyle sunucunun hizmet vermesini engellemek için kullanılan saldırılardır.
- Probe Atakları; Bu saldırılar bir sunucunun veya herhangi bir makinenin izinsiz giriş için yararlı olabilecek belirli bilgilerini öğrenmek için yapılır. Örneğin, kullandığı mevcut IP adresi veya etkin port ya da sunucunun çalıştırdığı işletim sistemi vs.
- R2L Atakları; Kullanıcı yetkileri olmasa bile, misafir veya başka bir kullanıcı olarak yetkisiz erişim için yapılan saldırılardır.
- U2R Atakları; İçsel ataklardır. Sisteme giriş izni olan ancak yönetici ayrıcalıkları olmayan bir kullanıcının çeşitli tekniklerle yönetici gibi davranarak izinsiz işlemler yaptığı saldırılardır.
- Brute Force Atakları; Şifre ataklarıdır. Temel olarak bir saldırgan kombinasyonu doğru tahmin etmeyi umarak çeşitli kullanıcı adı ve şifre çiftlerini denemek suretiyle sunucuya erişmeyi amaçlamaktadır.
- Infiltration Atakları; Bir ağı doğrudan ihlal ederek veya daha sonra özel bir ağa katılan bir ana bilgisayar enfekte ederek gerçekleştirilebilir. Saldırgan e-posta gibi basit bir yolla mağdura kötü amaçlı bir dosya göndererek uygulama güvenlik açığından yararlanabilir ve bir arka kapı açarak daha sonra bilgisayardan ve ağdan yararlanmak için kullanabilir.
- SQL Injection Atakları; SQL ifadelerine müdahale ederek veriye dayalı uygulamalarda saldırı gerçekleştirmek için yapılan bir kod enjeksiyon tekniğidir. Genellikle denetlenmeden giriş kabul eden metin kutuları ya da URL adresleri kullanılır.
- Bot / Botnet Atakları; aktif ataklardır. Saldırganlar tarafından zararlı bir yazılımla virüs bilgisayarlara bulaştırılarak buradaki yetkilere sahip olmayı amaçlar. Bot virüsü


sisteminize bulaştıktan sonra bilgisayar “zombiye” dönüşerek saldırganın istediği tüm işlemleri gerçekleştirir. Kullanıcı tarafından fark edilmesi oldukça zordur ve zaman alır.



4. SALDIRI TESPİT VE ENGELLEME SİSTEMLERİ

STS ve SES sistemleriyle ilgili daha önce verilen özet bilgilere ek olarak aşağıda ayrıntılı bilgiler verilmiştir. STS'ler zararlı hareketi tanımlama ve günlük bilgileri tutma amacıyla kullanılır. SES'ler ise ağ trafiği içerisindeki zararlı hareketlerin veya zararlı bağlantıların tespiti ile beraber önlenmesi için de kullanılan güvenlik sistemleridir. Genellikle STS ve SES ile Firewall Cihazları birlikte kullanılır. STS ve SES teknolojilerinin saldırıyı tespit etme yöntemi bakımından aşağıdaki türleri bulunmaktadır:


- İmza tabanlı türler
- Aykırılık tabanlı türler
- Hibrit türler



Şekil 4 Çeşitli STS/SES Tipleri

Şekil 4 farklı açılardan STS ve SES türlerini görselleştirmektedir. Şekil 4'ten anlaşılabacağı gibi DÖ ve ML Aykırılık Tabanlı STS'lerde kullanılmaktadır. Yeni tür saldırılar için de aykırılık tabanlı STS ve SES ürünleri daha yüksek başarımlar sağlamaktadır. Aykırılık türleri Şekil 5'te görsel olarak sunulmuştur. Artık saldırganlar da imza tabanlı saldırıların

yüksek başarımla engellendiğini bilmektedirler. Bu nedenle sofistike saldırı yöntemleri tercih edilmektedir.



Şekil 5 Aykırılık Türleri

STS ve SES teknolojileri aşağıdaki özelliklere sahip olmalıdır:

- Güvenlik yöneticilerine saldırı anında uyarı gönderebilmeli
- Kötü amaçlı kodları tespit edebilmeli
- Kötü amaçlı bağlantı kaynaklarını kesebilmeli
- Zararlı paketleri bırakabilmeli veya sıfırlayabilmeli
- CRC hatalarını düzeltebilmeli
- Bir yazılım veya kullanıcıdan kaynaklanan saldırıları tespit edebilmeli
- Savunmayı güçlendirmek ve iyileştirmek için saldırı kalıplarını kaydedebilmeli
- Adli bilişim uzmanları için adli kayıtları tutabilmeli
- Veri bütünlüğünü ve erişilebilirliğini sağlayabilmeli
- Güvenlikle beraber gizliliği sağlayabilmeli

5. SALDIRI TESPİT VE ENGELLEME SİSTEMLERİNDE MAKİNE ÖĞRENMESİ VE DERİN ÖĞRENME ALGORİTMALARININ KİYASLANMASI

Makine öğrenmesi zaman içinde daha fazla veri ile eğitildikçe öğrenme ve uyum sağlamada performans artışı sağlayan algoritmalar. Derin öğrenme ise çok daha büyük miktarda veriler ile öğrenen çok katmanlı bir yapay sinir ağı algoritmasıdır. Derin öğrenme için makine öğrenmesinin özellik çıkarma süreçlerinin de otomatikleştirilmiş halidir denebilir.

STS ve SES sistemlerinin doğası gereği derin öğrenme algoritmalarının kullanımının makine öğrenmesi algoritmalarına kıyasla daha uygun bir çözüm olarak karşımıza çıktığı görülmüştür. Şekil 6'da yapay zekâ, makine öğrenmesi ve derin öğrenme ilişkisini açıklayan bir görsel yer almaktadır.



Şekil 6 Yapay Zekâ, Makine Öğrenimi ve Derin Öğrenme İlişkisi


5.1 STS / SES Sistemlerinde Kullanılan Derin Öğrenme Algoritmaları

Aşağıda sıralanan derin öğrenme algoritmaları STS/SES sistemleri için güncel ağ verisi (CSE-CIC-IDS2018: New Brunswick Üniversitesi sunucularına ait veri seti) üzerinde çalışılmış ve sonuçlar elde edilmiştir.

1. BiRNN (Bidirectional Recurrent Neural Network): Çift Yönlü Tekrarlayan Sinir Ağları
2. BiLSTM (Bidirectional Long Short-Term Memory Networks): Çift Yönlü Uzun Kısa Vadeli Hafıza Ağları
3. CNN (Convolutional Neural Network): Konvolüsyonel (Evrışimsel) Sinir Ağları (ESA)
4. CNN-LSTM: Konvolüsyonel Uzun Kısa Vadeli Hafıza Ağları
5. DAE (Deep Autoencoder): Derin Oto-Kodlayıcı
6. GRU (Gated Recurrent Unit): Geçitli Tekrarlayan Sinir Ağları
7. LSTM (Long Short-Term Memory Networks): Uzun Kısa Süreli Bellek derin öğrenme algoritması
8. RNN (Recurrent Neural Network): Yinelemeli Sinir Ağı (YSA)
9. GAN (Generative Adversarial Network): Çekişmeli Üretken Ağ

5.1.1 BiRNN Algoritmaları


Tekrarlayan Sinir Ağları (Recurrent Neural Networks - RNN), sıralı verileri işlemek için kullanılan bir sinir ağı ailesidir [101]. Çift Yönlü Tekrarlayan Sinir Ağları (Bidirectional Recurrent Neural Networks - BiRNN), zaman t anında hem önceki hem de sonraki zaman adımlarından alınan bilgilerle mevcut bilginin belirlendiği bir RNN türüdür. Şekil 7’de BiRNN yapısı şematize edilmiştir.



Şekil 7 BiRNN'in Şematik Yapısı

5.1.2 BiLSTM Algoritmaları


Çift Yönlü Uzun Kısa Vadeli Hafıza Ağları (Bidirectional Long Short-Term Memory - BiLSTM), LSTM yapısını kullanarak bir model oluşturur. Bu ağlar, girişleri hem geçmişten geleceğe hem de gelecekte geçmişe doğru çalıştırır [102]. Bu yaklaşımla, BiLSTM geriye doğru giderek bilgileri gelecekle ilgili durumlardan da muhafaza eder. Ayrıca, BiLSTM, birbiriyle birleştirilmiş iki gizli durumu kullanarak, modeli geçmişten ve gelecekte gelen bilgileri koruyacak şekilde muhafaza eder. BiLSTM'in yapısı Şekil 8'de gösterilmiştir.



Şekil 8 BiLSTM Ağının Yapısı

5.1.3 ESA Algoritmaları


Evrişimsel Sinir Ağları (Convolutional Neural Networks - CNN), genellikle resim tabanlı nesnelerin analizinde kullanılan, ancak doğal dil işleme alanında da sıkça tercih edilen çok katmanlı algılayıcıların bir çeşididir. İleri beslemeli bir sinir ağı olan CNN algoritması, hayvanların görme özelliklerinden esinlenilerek geliştirilmiştir. CNN, görüntü ve ses işleme alanı başta olmak üzere doğal dil işleme ve biyomedikal gibi birçok farklı alanda uygulanmaktadır. CNN'in yapısı Şekil 9'da gösterilmiştir.



Şekil 9 Evrişimsel Sinir Ağı'nın Yapısı

5.1.4 CNN-LSTM Algoritmaları


CNN-LSTM modelleri, Evrimsel Sinir Ağları (Convolutional Neural Networks - CNN) ve Uzun Kısa Vadeli Bellek (Long Short-Term Memory - LSTM) ağlarının güçlü yönlerini birleştirir. Bu hibrid modeller, özellikle sıralı ve zaman serisi verilerin yanı sıra görüntü ve video analizinde de etkili bir şekilde kullanılır. CNN: Özellik çıkarımı için kullanılır. Görüntülerdeki veya diğer çok boyutlu verilerdeki önemli özellikleri belirler. LSTM: Bu çıkarılan özellikleri sıralı veri bağlamında işler ve uzun vadeli bağımlılıkları öğrenir. CNN-LSTM modelleri, sıralı verilerin özelliklerini çıkarmak ve öğrenmek için kullanılır ve bu sayede doğal dil işleme, video analizi ve zaman serisi tahmini gibi çeşitli alanlarda yüksek performans sergiler. Şekil 10'da CNN-LSTM'in ağ yapısı görülmektedir.



Şekil 10 CNN-LSTM Ağ Yapısı

5.1.5 DAE Algoritmaları

Oto-Kodlayıcılar (Autoencoders - AE), denetimsiz öğrenme için kullanılan ileri beslemeli özel bir Yapay Sinir Ağıdır. AE'ler, veri seti için boyut indirgeme amacıyla öğrenmeyi hedefler. AE'ler, girdi olarak gelen verinin sıkıştırılmış gösteriminden en iyi özellikleri öğrenmeyi amaçlar. Hedefe ulaşıldığında, gizli katmandaki düğüm sayısı ile girdi verisi temsil edilmiş olur. Derin Oto-Kodlayıcılar (Deep/Stacked Autoencoders - DAE), her bir katmandaki çıktıların ardışık katmanın girişlerine bağlandığı çok katmanlı sinir ağlarından oluşur. DAE'nin yapısı Şekil 11'de gösterilmiştir.




Şekil 11 DAE Algoritması'nın Yapısı

5.1.6 GRU Ağları

Geçitli Tekrarlayan Sinir Ağları (Gated Recurrent Unit - GRU), 2014 yılında K. Cho tarafından, RNN'in Gradyan Kaybolması problemini çözmek için geliştirilmiştir. GRU, tasarım ve doğruluk hesaplama açısından LSTM'nin bir varyantıdır. Bazı durumlarda


GRU, LSTM'den ayrılır. Örneğin, LSTM'nin üç kapısı varken GRU'nun iki kapısı vardır: sıfırlama kapısı ve güncelleme kapısı. Güncelleme kapısı, LSTM modelinde bir unutma ve giriş kapısı görevi görür; hangi bilgilerin saklanacağına ve hangi verilerin atılacağına karar verir. Sıfırlama kapısı, geçmiş verilerin ne kadarının unutulacağını belirlemek için kullanılır. GRU'nun yapısı Şekil 12'de gösterilmiştir.



Şekil 12 Geçitli Tekrarlayan Sinir Ağı'nın Yapısı

5.1.7 LSTM Algoritmaları


Bağlamlar arası boşluklar arttığında, RNN modelinin geçmişten gelen bilgileri yani uzun vadeli bağımlılıkları kullanmakta zorlandığı (hafıza bakımından) görülmüştür. Bu problemi çözmek için, uzun vadeli bağımlılıkları öğrenebilen yeni bir RNN türü olan Uzun Kısa Süreli Bellek (Long Short-Term Memory - LSTM) ağları, 1997 yılında Hochreiter ve Schmidhuber tarafından geliştirilmiştir. LSTM'nin yapısı Şekil 13'te gösterilmiştir.



Şekil 13 Uzun Kısa Süreli Bellek Algoritmasının Yapısı

5.1.8 RNN Algoritmaları

İlk Basit Tekrarlayan Ağ (Simple Recurrent Network - SRN) yapısı, Jeff Elman tarafından geliştirilmiştir [103]. Elman'ın cümle yapısı simülasyonunda kullanılan her bir kelime için gerçekleştirilen kümeleme sonucunda, isim ve fiil kategorileri düzgün bir şekilde ayrılmıştır. Tekrarlayan Sinir Ağları (Recurrent Neural Network - RNN), birimler arasındaki bağlantıların yönlendirilmiş bir döngü oluşturduğu yapay sinir ağı (YSA) sınıfıdır. RNN'in yapısı Şekil 14'te gösterilmiştir.



Şekil 14 Tekrarlayan Sinir Ağı'nın yapısı

5.2 Derin Öğrenme Algoritmalarının Karmaşıklık Matrisi Değerlendirmeleri

Modelin eğitimi sırasında elde edilen doğruluk ve hata değerlerinin gerçek değerler ile ne derece örtüştüğünü tespit etmek, sadece eğitim sonuçlarına bakılarak anlaşılamaz. Bu nedenle, eğitim setinde yer almayan gerçek veriler kullanılarak ikili karşılaştırma yapılır ve doğru-yanlış sınıflandırma tahmin değerlerinin karmaşıklık matrisi oranları hesaplanır. Bu işlemde, eğitilen modelin tahmin durumları gerçek pozitif, hatalı pozitif, gerçek negatif ve hatalı negatif olarak sınıflandırılır.

Modelin sınıflandırmasında atak_var ve atak_yok olarak iki sınıf belirlendiğinden sınıflandırma değerleri Şekil 15'te görselleştirilmiş ve aşağıdaki tanımlamalara göre tespit edilmiştir;

- DP (doğru pozitif): Veri setindeki atak etiketli ve atak_var olarak sınıflandırılan verileri ifade eder.
- YN (yanlış negatif): Veri setindeki atak etiketli ancak atak_yok olarak sınıflandırılan verileri ifade eder.
- YP (yanlış pozitif): Veri setindeki atak etiketli olmayan ancak atak_var olarak sınıflandırılan verileri ifade eder.
- DN (doğru negatif): Veri setindeki atak etiketli olmayan ve atak_yok olarak sınıflandırılan verileri ifade eder.

		Gerçek Değerler	
		Pozitif	Negatif
Tahmini Değerler	Pozitif	DP (Doğru Pozitif)	YN (Yanlış Negatif)
	Negatif	YP (Yanlış Pozitif)	DN (Doğru Negatif)

Şekil 15 Karmaşıklık matrisi ikili sınıflandırma tablosu

Bu veriler doğrultusunda hesaplama metrikleri doğruluk, kesinlik, geri çağırma, özgüllük ve f1 skoru başlıkları ile değerlendirilmiştir.

Doğruluk değeri, modelin genel doğruluk performansını gösterir. Kesinlik değeri, modelin doğru sınıflandırılan verilerinin oranını verir ve tahminlerin ne kadar kesin olduğunu gösterir. Negatif olduğu halde pozitif olarak sınıflandırılan veri, kesinlik değerinin hesaplanan oranını düşürmektedir. Geri çağırma değerleri, gerçek pozitif örneklerin oranını belirtir. Pozitif olduğu halde negatif sınıflandırılan veri, hesaplanan oranın geri çağırma değerini düşürmektedir. Özgüllük, gerçek negatif olan verilerin tahmin edilen negatif değerlere oranını gösterir. Negatif olduğu halde pozitif olarak sınıflandırılan veri hesaplanan özgüllük değerinin ortalama değerini düşürmektedir. F1 skoru, doğruluk ve geri çağırma değerlerinin harmonik ortalaması alınarak hesaplanır. Karmaşıklık matrisi değerlendirme metrik ve formülleri Çizelge 2’de gösterilmiştir.

Çizelge 2 Karmaşıklık matrisi değerlendirme metrik ve formülleri

Metrik	Formül
Doğruluk	$(DP + DN) / (DP + DN + YP + YN)$
Kesinlik	$DP / (DP + YP)$
Geri Çağırma	$DP / (DP + YN)$
Özgüllük	$DN / (DN + YP)$
F1 skoru	$2 \times \text{Kesinlik} \times \text{Geri Çağırma} / (\text{Kesinlik} + \text{Geri Çağırma})$

5.2.1 Dengesiz Veri Seti Üzerinde Bir, İki ve Üç Katmanlı DÖA’ların Doğruluk Oranlarının Saldırı Ataklarına Göre Karşılaştırılması

DÖ algoritmaları dengesiz veri seti üzerinde farklı saldırı ataklarına göre tablo halinde özetlenmiştir. Çalışmalar bir, iki ve üç katman olacak şekilde gerçekleştirilmiştir [104].

Çizelge 3 Ham (Dengesiz) Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA’nın Saldırı Ataklarına Karşı Doğruluk Oranları

Algoritma	Katman Sayısı	Doğruluk (%)						
		Benign	Bot	Brute Force	DoS	Infil.	Sql. Inj.	Ort. Doğr.
BiLSTM	1	99,73	99,93	99,78	25,92	19,78	0	57,52
	2	98,49	99,96	92,4	99,37	33,21	100	87,24

	3	98,44	99,95	92,59	99,51	36,88	100	87,9
	1	99,74	99,93	99,77	30,01	19,06	0	58,09
BiRNN	2	99,61	99,96	94,93	99,87	19,57	26,42	73,39
	3	98,24	99,92	92,98	97,46	14,91	3,77	67,88
CNN	1	99,89	99,88	99,82	0	18,57	0	53,02
CNN-LSTM	1	99,84	99,97	34,5	99,95	24,63	13,21	62,02
DAE	1	99,54	90,88	82,21	0	13,87	0	47,75
	1	99,69	99,89	99,74	25,73	18,84	0	57,31
GRU	2	99,65	99,94	94,93	99,84	19,39	1,89	69,27
	3	99,41	99,92	93,37	99,78	17,38	0	68,31
	1	99,73	99,9	99,79	25,73	18,37	0	57,25
LSTM	2	98,92	99,93	95,13	99,9	34,73	100	88,1
	3	98,77	99,8	86,94	92,5	25,55	100	83,93
	1	99,7	99,87	99,81	23,97	18,09	0	56,91
RNN	2	99,65	99,92	95,32	99,78	17,65	0	68,72
	3	98,93	85,9	91,23	98,78	12,48	0	64,55

Çizelge 3’de görüldüğü gibi tüm derin öğrenme algoritmaları tek katmanda Benign, Bot ve Brute Force ataklarına karşı yüksek doğruluk oranlarına sahiptir. Ancak DoS, Infiltration ve SQLi ataklarına karşı tüm derin öğrenme algoritmaları yine tek katmanda çok düşük doğruluk oranlarına sahiptir. Çift katmanlı BiLSTM ve LSTM derin öğrenme algoritmaları Infiltration saldırı türü hariç diğer saldırı türlerinde oldukça yüksek doğruluk oranlarına sahiptirler. Infiltration ve SQLi saldırı türü hariç tutulduğunda çift katmanlı derin öğrenme algoritmaları yüksek doğruluk oranlarına sahiptir. Üç Katmanlı DÖA’ların Saldırı Ataklarına Karşı Doğruluk Oranlarına bakıldığında Infiltration ve SQLi saldırı türlerine ait veri örneklerinin dengesiz dağılımlı olduğu anlaşılmaktadır. Çizelge 3’e göre dengesiz veri seti üzerinde elde edilen ortalama doğruluk oranlarının genel ortalaması yaklaşık yüzde 67,18 olarak gerçekleşmiştir.

5.2.2 Dengeli Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA’ların Doğruluk Oranlarının Saldırı Ataklarına Göre Karşılaştırılması

DÖ algoritmaları dengeli veri seti üzerinde farklı saldırı ataklarına göre tablo halinde özetlenmiştir. Çalışmalar bir, iki ve üç katman olacak şekilde gerçekleştirilmiştir [104].

Çizelge 4 Dengeli Veri Seti Üzerinde Tek, Çift ve Üç Katmanlı DÖA’ların Saldırı Ataklarına Karşı Doğruluk Oranları

Doğruluk (%)
77

Algoritma	Katman Sayısı	Benign	Bot	Brute Force	DoS	Infil.	SQL. Inj.	Ort. Doğr.
BiLSTM	1	77,82	99,93	99,61	99,94	87,45	100	87,79
	2	80,75	99,94	99,61	99,91	95,43	100	95,94
	3	76,42	99,96	99,81	99,87	86,94	100	93,83
BiRNN	1	76,4	99,93	99,61	99,91	87,16	100	93,84
	2	79,03	99,94	100	99,85	95,97	100	95,8
	3	67,43	99,94	99,42	99,04	90,98	100	92,8
CNN	1	70,26	99,89	98,25	99,06	91,27	100	70,19
CNN-LSTM	1	74,05	99,86	99,42	99,25	86,24	100	93,14
DAE	1	57,12	89,46	81,68	81,45	79,9	75,47	77,51
GRU	1	74,07	99,92	99,22	99,86	80,47	100	92,25
	2	77,56	99,9	99,42	99,8	95,58	100	95,37
	3	72,07	99,9	99,42	97,82	90,86	100	93,35
LSTM	1	73,83	99,92	99,22	99,9	81,95	100	92,47
	2	78,83	99,92	99,81	99,93	94,78	100	95,54
	3	73,4	99,91	99,03	99,65	87,07	100	93,18
RNN	1	69,34	99,91	99,42	99,45	86,56	100	92,44
	2	76,69	99,93	98,64	99,94	95,1	100	95,05
	3	61,55	99,9	97,66	99,86	88,3	100	91,21

Çizelge 4'e bakıldığında dengeli veri seti üzerinde yapılan çalışma sonuçlarındaki ortalama doğruluk oranlarının genel ortalaması yaklaşık 91,21 olarak gerçekleşmiştir. Dengeli (Çizelge 4) ve dengesiz (Çizelge 3) veri setlerinin genel ortalamaları arasında (91,21 – 67,18) %24,03 oranında bir iyileşme olduğu görülmektedir. Veri setinin niteliğinin (dengeli dağılımlı olması) derin öğrenme algoritmalarını ne denli etkilediği açık bir şekilde görülmektedir. Çizelge 4'ten çıkarılacak diğer bir sonuç da katman sayısı üçe çıkarıldığında iki katmana kıyasla doğruluk oranlarında bir miktar düşme olduğunun görülmesidir. Beklenenin aksine katman sayısı arttıkça doğruluk oranı artmamaktadır.

6. VERİ SETLERİ/KÜMELERİ

Saldırı tespit sistemlerinde çok farklı veri setleri söz konusu olmakla birlikte aşağıdaki veri setleri yaygın bir şekilde kullanılmaktadır. Bunlar:

- KDD Cup 1999
- NSL-KDD
- UNSW-NB15
- CIC-IDS2017
- CSE-CIC-IDS2018

Veri setleridir. CSE-CIC-IDS2018, hâlihazırda en güncel ve bilimsel çalışmalarda en çok tercih edilen veri setlerinden birisidir. Bunun nedeni içerdiği veriler bakımından güncel ağ trafiğini diğerlerine göre daha fazla temsil etmesidir. Bu çalışmada da her ne kadar saldırı tespit sistemlerinde kullanılmakta olan veri setlerinin önemli olanları tanıtılmış olsa da CSE-CIC-IDS2018 veri seti üzerinde yapılmış olan çalışmalar ağırlıklı olarak değerlendirilmiştir. Bu çalışmada anılmayan çok sayıda daha az öneme sahip veri seti de mevcuttur.

6.1 KDD Cup 1999

KDD (Knowledge Discovery and Data Mining: Bilgi Keşfi ve Veri Madenciliği) Cup99 özellikle veri madenciliği ve makine öğrenmesi alanlarında kullanılmaktadır. Veri seti, TCP bağlantıları hakkında temel özelliklerle birlikte başarısız oturum açma sayısı, sayfaya erişim sayısı gibi ileri seviye özellikler de içerir. Temelde standart KDD Cup99 veri setinde yaklaşık beş milyon kayıt bulunmaktadır. Bu veri seti hem eğitim hem de test verilerini içerir. Verilerin yaklaşık %20'si normal, %80'i ise saldırı türündedir.

Veri setinde; temel özellikler, trafik özellikleri, içerik özellikleri ve sunucu tabanlı özellikler olarak kategori altında sınıflandırılabilen 41 özellik vardır.

- Temel Özellikler; ayrı TCP bağlantılarının özellikleridir.
- Trafik Özellikleri; belirli bir sürelik (iki saniye) bir zaman penceresini kullanarak hesaplanan özelliklerdir.
- İçerik Özellikleri; alan bilgisi tarafından önerilen bağlantı içindeki niteliklerdir.

- Sunucu Tabanlı Özellikler; iki saniyeden uzun süren saldırıları değerlendirmek için tasarlanmış özelliklerdir.

Bu veri setindeki veriler, 4'ü saldırı, 1'i normal olmak üzere 5 ana kategoride sınıflandırılmıştır. Bu kategoriler;

- Normal
- DoS Saldırıları
- Probe Saldırıları
- R2L Saldırıları
- U2R Saldırıları şeklindedir.

Çizelge 5 KDD Cup 1999 veri setindeki kategorilere göre örnek sayıları

Tür	Sayı
Normal	553.301
DoS	4.113.223
U2R	112
R2L	18.599
Probe	45.268

Çizelge 5'den de anlaşılacağı gibi sayılar oldukça dengesiz bir dağılım göstermekte ve tüm saldırı türlerine ait örnek bulunmamaktadır. Ancak geçmiş yıllarda bu veri setinde örnekleri bulunan atak türlerinin çok yaygın olduğunu da unutmamak gerekir. Yaklaşık dört milyon DoS atak örnek verisine karşın sadece 112 adet U2R atak verisi mevcuttur. Bu durum derin öğrenme algoritmalarının yüksek başarımlar gösterememesine neden olmaktadır.

6.2 NSL-KDD

NSL-KDD, KDD Cup99 veri setinin içerdiği dengesizlik problemlerini çözmek için oluşturulmuş bir veri setidir. NSL-KDD veri seti, orijinal KDD Cup99 veri setine göre;

- Eğitim verilerindeki gereksiz kayıtları içermez, bu sayede sınıflandırma işlemi daha homojen gerçekleşir.
- Test setlerinde tekrar eden veriler bulunmaz.

iii. Eğitim ve test verilerindeki kayıtların sayısı orantılı ve makuldür. Bu da küçük bir bölümü rastgele seçmeye gerek kalmadan tüm veri seti üzerinde işlem yapmaya olanak tanır.

Veri seti yukarıda belirtilen iyileştirmelere sahiptir ve KDD Cup99 veri setinin önemli kayıtlarını içerir. NSL-KDD veri setinde, 9 temel ve 32 türetilmiş olmak üzere toplam 41 özellikten oluşan bir özellik haritası bulunmaktadır. Örnek etiketleri de KDD Cup99'da olduğu gibi beş adettir.

6.3 UNSW-NB15

UNSW-NB15 bilgisayar güvenlik veri seti 2015 yılında yayınlanmıştır [105]. Bu veri seti 2.540.044 kayıttan oluşmaktadır. Veri seti UNSW web sayfasında mevcuttur ve gerçekçi modern normal ve anormal ağ aktivitelerini içerir. Bu veri setinin yapısı, KDDCUP 99 gibi diğer veri setleriyle karşılaştırıldığında daha karmaşıktır. Bu, UNSW-NB15'i mevcut ağ izinsiz giriş tespit sistemlerini daha güvenilir bir şekilde değerlendirmek için daha kapsamlı hale getirir. Bu kayıtlar, üç sanal sunucu ile IXIA trafik oluşturucu tarafından toplanmıştır. Normal trafik paketlerini yönlendirmek üzere iki sunucu, anormal trafik paketlerini işlemek için ise üçüncü bir sunucu yapılandırılmıştır. Argus ve Bro-IDS araçlarıyla, paket tabanlı ve akış tabanlı özellikler dâhil olmak üzere toplam 49 özellik kayıtlardan çıkarılmıştır. Paket tabanlı özellikler, bir paket başlığından ve yükünden (paket verileri olarak da adlandırılır) çıkarılır. Buna karşılık, akış tabanlı özellikler, ağda bir kaynaktan bir hedefe doğru ilerleyen paket dizisinden türetilir. Paket incelemesi sırasında yön, paketler arası uzunluk ve varışlar arası süreler çok önemlidir. Kayıt toplam süresi(dur) ve hedeften kaynağa-yaşam süresi (dttl), akışa dayalı özelliklerin iki örneğidir. Özellikler Temel (6 - 18), İçerik (19 - 26) ve Zaman (27 - 35) olarak kategorilere ayrılmıştır. 36 - 40 arası özellikler ve 41 - 47 arası özellikler, sırasıyla genel amaçlı özellikler ve bağlantı özellikleri olarak etiketlenir. Genel amaçlı özellikler kategorisi, tek bir kaydın amacını açıklamaya yönelik özellikleri içerirken, bağlantı özellikleri sıralı olarak sıralanmış yüz kayıt arasındaki bağlantının karakteristiğini gösterir. Son iki özellik, saldırı kategorilerini ve etiketleri içerir. Saldırıları; Analysis, Backdoor, DoS, Exploits, Fuzzers, Generic, Reconnaissance, Shellcode ve Worms olarak kategorize edilir. Normal saldırılar 2.218.761 kayıt kullanılarak temsil edilirken Fuzzers, Analysis,

Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode ve Worms imzaları sırasıyla 24246, 2677, 2329, 16535, 44525, 215481, 13987, 1511 ve 174 kayıt içerir. Sonuç olarak, veri setinin %87'si Normal kayıtlardan oluşurken, veri setinin yalnızca %0,007'si Worms kayıtlarından oluştuğundan, veri seti için önemli bir denge problemi vardır. Veri setinin geliştiricileri, Çizelge 6'da gösterildiği üzere, veri setini sınıflara göre eğitim ve test alt setlerine ayırarak diğer araştırmacılar tarafından kullanılmasını sağlamıştır. Bu veri seti, izinsiz giriş tespiti için veriye dayalı bir model geliştirmede anlamlı bir şekilde kullanılmadan önce önemli ve temel bir ön işleme gerektirir.

Çizelge 6 Her Sınıf İçin Eğitim ve Test Alt Veri Setlerindeki Kayıt Sayısı

Sınıflar	Eğitim Alt Veri Seti	Test Alt Veri Seti
Normal	56.000	37.000
Analysis	2.000	677
Backdoor	1.746	583
DoS	12.264	4.089
Exploits	33.393	11.132
Fuzzers	18.184	6.062
Generic	40.000	18.871
Reconnaissance	10.491	3.496
Shellcode	1.133	378
Worms	130	44
Toplam Kayıtlar	175.341	82.332

6.4 CIC-IDS2017

Kanada Siber Güvenlik Enstitüsü tarafından sağlanan bu veri seti, çoğu güncel saldırı senaryosunu da içermektedir. Bu son teknoloji veri seti, yalnızca güncel ağ saldırılarını içermekle kalmaz, aynı zamanda gerçek dünya saldırılarının tüm kriterlerini de karşılar. Ancak bu veri setinin birkaç eksik yanı da mevcuttur. Eksikliklerden ve oldukça görünür olanlardan biri, veri setinin çok büyük olması ve Kanada Siber Güvenlik Enstitüsü'nün beş günlük trafik bilgisi olarak sekiz dosyaya yayılmış olmasıdır. Bir STS tasarlamak için tek bir veri seti uygun olacaktır. Ayrıca veri seti, herhangi bir STS eğitimi için çok sayıda

gereksiz kayıt içerir. Veri seti son saldırı senaryosunu içermesine rağmen, aynı zamanda veri setinin doğası gereği yüksek sınıf dengesizliği olduğu da ortadadır. Bir sınıf dengesizliğine sahip veri seti, sınıflandırıcıyı yanıltabilir ve çoğunluk sınıfına yöneltebilir.

CIC-IDS2017 veri setinin oluşturulmasından bu yana, yeni modellerin ve algoritmaların analizi ve geliştirilmesi için araştırmacıları çekmeye başlamıştır. CIC-IDS2017'nin yazarına göre, veri seti, beş günlük normal ve Kanada Siber Güvenlik Enstitüsü'nün trafik verilerini içeren sekizden fazla farklı dosyayı kapsıyordu. Tüm bu dosyaların kısa bir açıklaması Çizelge 7'de sunulmaktadır.

Çizelge 7 CIC-IDS2017'ye Ait Dosya Tanımları

Dosya Adı	Etkinlik Günü	Bulunan Saldırıları
Monday-WorkingHours.pcap_ISCX.csv	Pazartesi	Benign (Normalhuman activities)
Tuesday-WorkingHours.pcap_ISCX.csv	Salı	Benign, FTP-Patator, SSH-Patator
Wednesday-workingHours.pcap_ISCX.csv	Çarşamba	Benign, DoS GoldenEye, DoS Hulk, DoS Slowhttptest, DoS slowloris, Heartbleed
Thursday-WorkingHours-Morning-WebAttacks.pcap_ISCX.csv	Perşembe	Benign, Web Attack – BruteForce, Web Attack – SqlInjection, Web Attack – XSS
Thursday-WorkingHours-Afternoon-Infiltration.pcap_ISCX.csv	Perşembe	Benign, Infiltration
Friday-WorkingHours-Morning.pcap_ISCX.csv	Cuma	Benign, Bot
Friday-WorkingHours-Afternoon-PortScan.pcap_ISCX.csv	Cuma	Benign, PortScan

Friday-WorkingHours- Afternoon- DDos.pcap_ISCX.csv	Cuma	Benign, DDoS
--	------	--------------

Çizelge 7'de veri setinin beş günlük trafik verisi olarak saldırı bilgisi içerdiği görülmektedir. Perşembe çalışma saati öğleden sonra ve Cuma verileri ikili sınıflandırma için çok uygundur. Benzer şekilde, Salı, Çarşamba ve Perşembe sabahı verileri, çok sınıflı algılama modeli tasarlamak için en iyisidir. Ancak, en iyi algılama modelinin her türden saldırıyı algılayabilmesi gerektiği unutulmamalıdır. Bu nedenle, böyle tipik bir STS tasarlamak için, tüm günün trafik verileri, STS tarafından kullanılacak tek bir veri seti oluşturmak üzere birleştirilmelidir [104].

Çizelge 7'de sunulan dosyalar birleştirildiğinde 3.119.345 örnek ve 15 sınıf etiketi (1 normal + 14 saldırı etiketi) ve 83 özellik içeren bir veri seti elde edilir. Ayrıca birleştirilen dosyaların örnekleri incelendiğinde veri setinin sınıf etiketi eksik olan 288.602 örnek ve eksik bilgiye sahip 203 örnek içerdiği görülecektir. Bu tür eksik örnekleri kaldırıldığında 2.830.540 örneğe sahip birleşik bir CIC-IDS2017 veri seti elde edilir. Birleşik veri setinin özellikleri ve ayrıntılı sınıfsal oluşumları sırasıyla Çizelge 8 ve Çizelge 9'da sunulmuştur.

Çizelge 8 CIC-IDS2017 Veri Setinin Genel Özellikleri

Veri Seti Adı	CIC-IDS2017
Veri Seti Tipi	Çok Etiketli
Yayın Tarihi	2017
Toplam Benzersiz Örnek Sayısı	2.830.540
Özellik Sayısı	83
Benzersiz Sınıf Etiketi Sayısı	15

Çizelge 9 CIC-IDS2017 Veri Setinin Sınıf Açısından Örnek Sayıları

Sınıf Etiketleri	Örnek Sayısı
BENIGN	2.359.087
DoS Hulk	231.072

PortScan	158.930
DDoS	41.835
DoS GoldenEye	10.293
FTP-Patator	7.938
SSH-Patator	5.897
DoS slowloris	5.796
DoS Slowhttptest	5.499
Bot	1.966
Infiltration	36
Web Attack – Sql Injection	21
Heartbleed	11

6.5 CSE-CIC-IDS2018

İletişim Güvenliği Kuruluşu (CSE) katkısıyla 2018'de izinsiz giriş tespit veri setinin en son yinelemesi olan CSE-CIC-IDS2018 yayınlanmıştır. Güncellenmiş sürüm ayrıca bir sınıf dengesizliğine sahiptir ve yapısal olarak CICIDS2017'ye benzer. Bununla birlikte, CSE-CIC-IDS2018, simüle edilmiş istemci hedefleri ve saldırı makinelerinden oluşan çok daha geniş bir ağdan hazırlanmıştır [106], bu da 10 günlük ağ trafiğinden toplanan 16.233.002 örneği içeren bir veri setiyle sonuçlanmıştır. Örneklerin yaklaşık %17'si saldırı trafiğidir. Çizelge 10, CSE-CIC-IDS2018 tarafından temsil edilen yedi ağ trafiği türü için yüzde dağılımını gösterir. Bundan sonra metin boyunca “CSE-CIC-IDS2018” ve “CICIDS2018” birbirinin yerine kullanılacaktır. Veri seti, buluttan indirilebilen 10 CSV dosyası üzerinden dağıtılır. Dokuz dosya 79 bağımsız özellikten oluşur ve geri kalan dosya 83 bağımsız özellikten oluşur.

Çizelge 10 CSE-CIC-IDS2018 Veri Setindeki Trafik Türüne Göre Dağılım Oranları

Trafik Türü	Dağılım (%)
Tehlikesiz (Benign)	83.070
Dağıtık Hizmet Reddi (DDoS)	7.786

Hizmet Reddi (DoS)	4.031
Kaba Kuvvet (Brute Force)	2.347
Botnet	1.763
Sızma (Infiltration)	0.997
Web Saldırısı (Web Attack)	0.006

Veri seti geliştirilirken “profil kavramı” üzerine gidilmiştir. Buradaki profil kavramı; uygulamalar, protokoller veya düşük seviye ağ varlıkları için izinsiz girişlerin ayrıntılı açıklamalarını içerecek şekilde tasarlanması anlamına gelmektedir. Bu profiller, ağ üzerinde olay oluşturmak için araçlar veya insanlar tarafından kullanılabilir ve profiller farklı topolojilere sahip çeşitli ağ protokollerine uygulanabilir. Ayrıca veri setinin geliştirilmesi yine CIC-IDS2017’de kullanılan standartlar göz önüne alınarak yapılmıştır.

Temel kriterlere ek olarak aşağıdaki avantajları da sunar;

- i. Tekrarlayan veri sayısı oldukça azdır.
- ii. Belirsiz (NaN) veri sayısı neredeyse yok gibidir.
- iii. CSV formatında kullanıma hazır olacak şekilde sunulmuştur.

En güncel olan veri setlerinde birisidir.

Veri setini oluşturmak için 2 adet profil geliştirilmiştir; bunlar B ve M profilleridir.

- B-profil; farklı makine öğrenmesi ve istatistiksel algoritmaları kullanarak kullanıcıların özel davranışlarını kapsüller. Özel davranışlar, kullanıcıların paket büyüklüklerinin dağılımları, akış başına paketlerin sayısı, yükteki belirli modeller, yükün büyüklüğü ve bir protokolün talep süresi dağılımıdır.
- M-profil; bir saldırı senaryosunu açıkça belirler. Bu sayede sonrasında diğer kullanıcıların yorumlayabilmesine yardımcı olur.

7. TARTIŞMA, SONUÇ VE ÖNERİLER

İnternet'in daha da yaygınlaşmasıyla beraber, veri üreten ve tüketen cihazlar küresel bir ağa her zaman ve her yerden bağlanabilir hale gelmiştir. Bununla birlikte, anonim bağlantılar ağda çok fazla güvenlik ihlaline neden olmaya başlamış ve bu da ağı saldırılara karşı savunmasız hale getirmiştir. Ayrıca, saldırganlar da daha sofistike ve otomatik üretim araçlarının yardımıyla saldırılar yapmaya başlamıştır. Saldırganlar Saldırı Tespit Sistemlerinin zayıf algılama yeteneğine bağlı olarak yeni kötü amaçlı yazılımlarla başarıya ulaşabilirler. STS'ler genellikle önceden hazırlanmış / toplanmış veri setleri kullanılarak eğitilir. Veriye dayalı STS'lerin başarısı için en önemli sorun verinin kaliteli ve yeterli olmasıdır. Bununla birlikte, STS geliştirmek için kullanılan veri setlerinin neredeyse tamamı sınıf dengesizliği probleminden mustarıptır ve bu durum da verilerden elde edilecek modeller için sorun anlamına gelmektedir. Dengesiz veri setleri üzerinde eğitilen algoritmalar çoğunluk sınıfına karşı bir eğilim ile sonuçlanan tahminlerde bulunurlar ve bazı olağanüstü durumlarda azınlık sınıfları göz ardı edilirler. Ancak, asıl tespit edilmesi gereken bu azınlık sınıflarıdır. Bu amaçla, sistemin verimliliğini artırmak ve metriklerin performans oranlarını artırmak için dengesizlik oranı azaltılmalıdır.

Son yıllarda gerçekleştirilen akademik çalışmalarda sıklıkla güncel veri setlerinden birisi olan CSE-CIC-IDS2018 kullanılmaktadır. En yaygın kullanılan derin öğrenme algoritmaları ise ESA, YSA, BiRNN, LSTM, BiLSTM, CNN-LSTM, GRU ve DAE olmuştur.

Veri seti üzerindeki dengesizlik oranlarını azaltmak için, azınlık gruplarının veri sayısını artıran sentetik veri örnekleme modeli kullanılmıştır. Dengesizlik oranlarını azaltmanın diğer bir yöntemi olarak da çoğunluk örneklerinden rastgele silme yöntemiyle azaltma işlemi yapılmasıdır. Deneysel sonuçlar, uygulanan modellerin son çalışmalarla karşılaştırıldığında çok iyi bir doğruluk düzeyine sahip olduğunu göstermiştir. Örneklenmiş bir veri setinin kullanılması, modellerin ortalama doğruluğunun %4,01 ile %30,59 arasında artmasına neden olmuştur [104]. Yine de STS'lerin tüm ortam ve koşullara göre başarı sağlayabilmesi için gerçek ağ trafiği üzerinde eğitilmesi

gerekmektedir. Güvenlik ve gizlilik ihlallerine yol açacağı endişesiyle her zaman ilgili derin öğrenme modelinin gerçek verilere ulaşması söz konusu olmayabilir. Bu tip çekinceleri azaltmak için Federe Derin Öğrenme tekniklerden yararlanılabileceği değerlendirilmektedir. Bununla birlikte giderek daha fazla derin ağ türleri ortaya çıkmıştır. Bu ağ türlerinin kaynak sınırlılıkları da hesaba katıldığında daha az kaynak tüketen derin öğrenme modellerinin oluşturulması da gerekli görülmektedir.

Yapılan tez çalışması ESA ve AE kombinasyonunun doğruluk değerinin en yüksek olduğunu göstermiştir. Ancak en verimli derin öğrenme yöntemi kullanılan veri setine, saldırı türüne, sistemin genel gereksinim ve kaynaklarına göre değişmektedir. Bu nedenle belirli bir bağlama göre farklı derin öğrenme teknikleri en iyi performansı göstermektedirler.

Yapılan çalışmalar kapsamında ulaşılan belli başlı sonuçlar aşağıda verilmiştir;

- Bu tez çalışmasında Derin Öğrenme algoritmaları ile geliştirilen Saldırı Tespit Sistemlerinin aykırılık tabanlı ataklardaki tespit başarısıyla ilgili geçmiş çalışmalar incelenmiştir.
- Son yıllarda yapılan çalışmaların çoğunluğunda gerçekçilik açısından güncel ve kapsamlı bir veri seti olan CSE-CIC-IDS2018 tercih edilmiştir. Bu da gelişen veri trafiği türüne uyumlu derin öğrenme tekniklerine ihtiyaç olduğunu göstermektedir.
- Son 20 yıl içerisinde yapılan makine öğrenmesi çalışmalarında ise bu tezin de tanıttığı KDD Cup 1999, NSL-KDD, UNSW-NB15, CIC-IDS2017 veri setlerinin yoğun bir şekilde kullanıldığı görülmüştür.
- Gerçek dünyada bulunan verilerin çoğu dengesiz bir dağılıma sahiptir, incelenen çalışmaların çoğunda doğru şekilde incelenebilmeleri için belirli veri örnekleme işlemlerinden geçirilmiş oldukları görülmüştür.
- Veri setlerinin dengeli olmasının yanında normal dağılıma sahip olması da gerekir. Veri setlerinin optimizasyonu için farklı derin öğrenme yöntemlerine ihtiyaç duyulduğu anlaşılmıştır.

- Derin öğrenme modelleri çok katmanlı bir yapıya sahip olduğu için GPU üzerinde daha uzun çalışırlar. Hem kullanılan veri setinin boyutu (CSE-CIC-IDS2018 veri setinin orijinal boyutu yaklaşık 400 GB civarındadır) hem de kullanılan algoritmaların çok fazla katman / düğüme sahip olması açısından bu tip algoritmalar daha çok işlem gücüne sahip GPU'lar üzerinde çalışmalıdır. Ancak farklı özellik ve kaynaklara sahip ağ türleri dikkate alındığında daha az kaynak ihtiyacı olan derin öğrenme modellerine olan ihtiyaç artmaktadır.
- Derin Öğrenme algoritmalarının orijinal veri setine uygulandığı tek katmanlı yapıda %98,32 doğruluk oranı, %62,02 ortalama doğruluk ve 21513 ms ile CNNLSTM en başarılı algoritma olmuştur. Diğer algoritmalar özellikle SQL Injection tipi atakları tespit edememiştir. Veri örnekleme işleminden sonra ise BiLSTM modelinin ortalama doğruluk oranı (incelenen atak tiplerine göre) %57,52'den %87,79'a yükselmiştir. Doğruluk oranı ise %98,11'den %97,93'e düşmüştür [104].

Yapılan çalışmalar göstermiştir ki, siber dünya daha karmaşık, daha yetenekli, daha akıllı hale geldikçe paralel bir şekilde saldırı türleri de daha akıllı ve karmaşık hale gelmektedir. Derin öğrenme teknikleri burada büyük önem kazanmaktadır. Ancak her durum altında başarılı tespitler yapabilen genel bir derin öğrenme yönteminden bahsetmek mümkün değildir. Bunun yerine durum ve ortama en uygun derin öğrenme tekniğini seçerek gelecek çalışmaların yönlendirilmesinin daha uygun olacağı değerlendirilmektedir.

KAYNAKLAR

- [1] **B. Mukherjee, L. Heberlein ve K. Levitt**, (2002) «Network intrusion detection,» *IEEE Network*, cilt 8, no. 3, pp. 26-41.
- [2] **J. Hu, Q. Luo ve J. Zhang**, (2020) «The Fluctuations of Bitcoin Price during the Hacks,» *International Journal of Applied Research in Management and Economics*, cilt 3, no. 1, pp. 10-20.
- [3] **M. Kamaludeen, S. Ismaeel, S. Asiri, T. Allen ve C. Scarfo**, (2020) «A framework for cyber protection (FCP) in K-12 education sector,» %1 içinde *3rd Smart Cities Symposium (SCS 2020)*, Çevrimiçi Konferans.
- [4] **P. Mishra, V. Varadharajan, U. Tupakula ve E. S. Pilli**, (2018) «A Detailed Investigation and Analysis of Using Machine Learning Techniques for Intrusion Detection,» *IEEE Communications Surveys & Tutorials*, cilt 21, no. 1, pp. 686-728.
- [5] **M. R. İbrahim**, (2019) «Derin öğrenme yöntemiyle ağ saldırı tespit sistemi / Network intrusion detection system with deep learning method,». [Çevrimiçi]. Available: <https://tez.yok.gov.tr/UlusalTezMerkezi/tezDetay.jsp?id=CBq4itvriju0o4w9hHeIx&no=IWN86rOI6oq-jnzUWEUhpq>. [Erişildi: 6 Ekim 2024].
- [6] **R. Padmaja ve P. R. Challagundla**, (2024) «Exploring A Two-Phase Deep Learning Framework For Network Intrusion Detection,» %1 içinde *2024 IEEE International Students' Conference on Electrical, Electronics and Computer Science (SCEECs)*, Bhopal, India.
- [7] **M. K. Hooshmand ve D. Hosahalli**, (2022) «Network anomaly detection using deep learning techniques,» *CAAI Transactions on Intelligence Technology*, cilt 7, no. 2, pp. 228-243.
- [8] **M. S. Erçin ve E. Yolaçan**, (2022) «SQLi ve XSS Saldırı Tespitinde Kullanılan Yeni Bir Özellik Çıkarma Yöntemi,» *Uluslararası Bilgi Güvenliği Mühendisliği Dergisi*, cilt 8, no. 1, pp. 1-11.
- [9] **A. Utku**, (2022) «Ağ trafiği analizi ile derin öğrenme tabanlı Android kötücül yazılım tespiti,» *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, cilt 37, no. 4, pp. 1823-1838.
- [10] **K. BAYSAL**, (2022) «DERİN ÖĞRENME TEMELLİ YENİ NESİL GÜVENLİK DUVARININ TASARLANMASI,». [Çevrimiçi]. Available:

<https://acikerisim.trakya.edu.tr/server/api/core/bitstreams/5c69b45f-d22c-4ba0-bfe7-160e6040fbf1/content>. [Erişildi: 7 Ekim 2024].

- [11] **A. F. Uluer, Z. Albayrak, A. N. Özalp, M. Çakmak ve H. C. Altunay**, (2022) «BGP Anomali Tespitinde Hibrit Model Yaklaşımı,» %1 içinde *2022 30th Signal Processing and Communications Applications Conference (SIU)*, Safranbolu, Turkey.
- [12] **P. Pitre, A. Gandhi, V. Konde, R. Adhao ve V. Pachghare**, (2022) «An Intrusion Detection System for Zero-Day Attacks to Reduce False Positive Rates,» %1 içinde *2022 International Conference for Advancement in Technology (ICONAT)*, Goa, India.
- [13] **H. Ahmetoğlu ve R. Daş**, (2019) «Derin Öğrenme ile Büyük Veri Kümelerinden Saldırı Türlerinin Sınıflandırılması,» %1 içinde *2019 International Artificial Intelligence and Data Processing Symposium (IDAP)*, Malatya, Turkey.
- [14] **U. Çekmez, Z. Erdem, A. G. Yavuz, O. K. Sahingoz ve A. Buldu**, (2018) «Network anomaly detection with deep learning,» %1 içinde *2018 26th Signal Processing and Communications Applications Conference (SIU)*, Izmir, Turkey.
- [15] **S. Emanet, G. K. Baydoğan ve Ö. Demir**, (2021) «Öznitelik Seçme Yöntemlerinin Makine Öğrenmesi Tabanlı Saldırı Tespit Sistemi Performansına Etkileri,» *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, cilt 12, no. 5, pp. 743-755.
- [16] **A. Gökdemir ve A. Çalhan**, (2022) «Nesnelerin interneti ortamlarında derin öğrenme ve makine öğrenmesi tabanlı anomali tespiti,» *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, cilt 37, no. 4, pp. 1945-1956.
- [17] **O. Kaynar, H. Arslan, Y. Görmez ve Y. E. Işık**, (2018) «Makine Öğrenmesi ve Öznitelik Seçim Yöntemleriyle Saldırı Tespiti,» *Bilişim Teknolojileri Dergisi*, cilt 11, no. 2, pp. 175-185.
- [18] **B. Kızıldaş ve E. Gül**, (2020) «Network Anomaly Detection With Convolutional Neural Network Based Auto Encoders,» %1 içinde *2020 28th Signal Processing and Communications Applications Conference (SIU)*, Gaziantep, Turkey.
- [19] **T. Kim ve W. Pak**, (2022) «Early Detection of Network Intrusions Using a GAN-Based One-Class Classifier,» *IEEE Access*, cilt 10, pp. 119357-119367.
- [20] **R. Padmaja ve P. R. Challagundla**, (2024) «Exploring A Two-Phase Deep Learning Framework For Network Intrusion Detection,» %1 içinde *2024 IEEE International Students' Conference on Electrical, Electronics and Computer Science (SCEECS)*, Bhopal, India.

- [21] **V. T. Truong ve L. B. Le**, (2024) «Security for the Metaverse: Blockchain and Machine Learning Techniques for Intrusion Detection,» *IEEE Network*, cilt 38, no. 5, pp. 204-212.
- [22] **F. Zhao, H. Li, K. Niu, J. Shi ve R. Song**, (2024) «Application of Deep Learning-Based Intrusion Detection System (IDS) in Network Anomaly Traffic Detection,» *Artificial Intelligence and Machine Learning*, cilt 1, no. 86, pp. 250-256.
- [23] **D. P. R. Sanagana ve C. K. Tummalachervu**, (2024) «Securing Cloud Computing Environment via Optimal Deep Learning-based Intrusion Detection Systems,» %1 içinde *2024 Second International Conference on Data Science and Information System (ICDSIS)*, Hassan, India.
- [24] **H. Liao, M. Z. Murah, M. K. Hasan, A. H. M. Aman, J. Fang ve X. Hu**, (2024) «A Survey of Deep Learning Technologies for Intrusion Detection in Internet of Things,» *IEEE Access*, cilt 12, pp. 4745 - 4761.
- [25] **F. Nabi ve X. Zhou**, (2024) «Enhancing intrusion detection systems through dimensionality reduction: A comparative study of machine learning techniques for cyber security,» *Cyber Security and Applications*, cilt 2, no. 100033.
- [26] **S. Yaras ve M. Dener**, (2024) «IoT-Based Intrusion Detection System Using New Hybrid Deep Learning Algorithm,» *Electronics*, cilt 13, no. 1.
- [27] **S. S. Shankar, . B. T. Hung, P. Chakrabarti, T. Chakrabarti ve G. Parasa**, (2024) «A novel optimization based deep learning with artificial intelligence approach to detect intrusion attack in network system,» *Education and Information Technologies*, cilt 29, p. 3859–3883.
- [28] **A. V. Turukmane ve R. Devendiran**, (2024) «M-MultiSVM: An efficient feature selection assisted network intrusion detection system using machine learning,» *Computers & Security*, cilt 137.
- [29] **K. Roshan, A. Zafar ve S. B. U. Haque**, (2024) «Untargeted white-box adversarial attack with heuristic defence methods in real-time deep learning based network intrusion detection system,» *Computer Communications*, cilt 218, pp. 97-113.
- [30] **N. O. Aljehane, H. A. Mengash, M. M. Eltahir, F. A. Alotaibi, S. S. Aljameel, A. Yafoz, R. Alsini ve M. Assiri**, (2024) «Golden jackal optimization algorithm with deep learning assisted intrusion detection system for network security,» *Alexandria Engineering Journal*, cilt 86, pp. 415-424.

- [31] **E. Osa, P. E. Orukpe ve U. Iruansi**, (2024) «Design and implementation of a deep neural network approach for intrusion detection systems,» *e-Prime - Advances in Electrical Engineering, Electronics and Energy*, cilt 7.
- [32] **H. M. Saleh, H. Marouane ve A. Fakhfakh**, (2024) «Stochastic Gradient Descent Intrusions Detection for Wireless Sensor Network Attack Detection System Using Machine Learning,» *IEEE Access*, cilt 12, pp. 3825 - 3836.
- [33] **D. Spiekermann, T. Eggendorfer ve J. Keller**, (2024) «Deep Learning for Network Intrusion Detection in Virtual Networks,» *Electronics*, cilt 13.
- [34] **V. Ravi**, (2024) «Deep learning-based network intrusion detection in smart healthcare enterprise systems,» *Multimedia Tools and Applications*, cilt 83, p. 39097–39115.
- [35] **M. Maddu ve Y. N. Rao**, (2024) «Network intrusion detection and mitigation in SDN using deep learning models,» *International Journal of Information Security*, cilt 23, pp. 849-862.
- [36] **G. S. C. Kumar, R. K. Kumar, K. P. V. Kumar, N. R. Sai ve M. Brahmaiah**, (2024) «Deep residual convolutional neural Network: An efficient technique for intrusion detection system,» *Expert Systems with Applications*, cilt 238, no. Part B.
- [37] **Z. Ali, W. Tiberti, A. Marotta ve D. Cassioli**, (2024) «Empowering Network Security: BERT Transformer Learning Approach and MLP for Intrusion Detection in Imbalanced Network Traffic,» *IEEE Access*, cilt 12, pp. 137618-137633.
- [38] **B. Sharma, L. Sharma, C. Lal ve S. Roy**, (2024) «Explainable artificial intelligence for intrusion detection in IoT networks: A deep learning based approach,» *Expert Systems with Applications*, cilt 238.
- [39] **R. Devendiran ve A. V. Turukmane**, (2024) «Dugat-LSTM: Deep learning based network intrusion detection system using chaotic optimization strategy,» *Expert Systems with Applications*, cilt 245.
- [40] **H. Nandanwar ve R. Katarya**, (2024) «Deep learning enabled intrusion detection system for Industrial IOT environment,» *Expert Systems with Applications*, cilt 249C.
- [41] **B. S. Rani, S. Vairamuthu ve S. Subramanian**, (2024) «Archimedes Fire Hawk Optimization enabled feature selection with deep maxout for network intrusion detection,» *Computers & Security*, cilt 140.

- [42] **Y. Q. J. X. Z. Z. N. Z. M. F. J. Xiaosong Wang**, (2024) «Advanced Network Intrusion Detection with TabTransformer,» *Journal of Theory and Practice of Engineering Science*, cilt 4, no. 03, pp. 191-198.
- [43] **J. Ghadermazi, A. Shah ve N. D. Bastian**, (2024) «Towards Real-time Network Intrusion Detection with Image-based Sequential Packets Representation,» *IEEE Transactions on Big Data (Early Access)*, pp. 1-17.
- [44] **B. B. S. M. S. A. B. a. Y. G.-D. T. E. T. Djaidja**, (2024) «Early Network Intrusion Detection Enabled by Attention Mechanisms and RNNs,» *IEEE Transactions on Information Forensics and Security*, cilt 19, no. 1, pp. 7783 - 7793.
- [45] **A. A. N. H. N.-N. J. H. M. N. S. Vanlalruata Hnamte**, (2024) «DDoS attack detection and mitigation using deep neural network in SDN environment,» *Computers & Security*, cilt 138.
- [46] **T. A. T. & Y. K. S. Oluwadamilare Harazeem Abdulganiyu**, (2024) «Towards an efficient model for network intrusion detection system (IDS): systematic literature review,» *Wireless Networks*, cilt 30, no. 1, pp. 453-482.
- [47] **X. W. P. W. L. Y. Y. T. a. R. L. M. He**, (2024) «Reinforcement Learning Meets Network Intrusion Detection: A Transferable and Adaptable Framework for Anomaly Behavior Identification,» *IEEE Transactions on Network and Service Management*, cilt 21, no. 2, pp. 2477-2492.
- [48] **J. D. P. A. S. W. V. Jianan Zhang**, (2024) «Public cloud networks oriented deep neural networks for effective intrusion detection in online music education,» *Computers and Electrical Engineering*, cilt 115.
- [49] **S. H. W. H. H. Y. X. K. F. Z. Xinwei Yuan**, (2024) «A simple framework to enhance the adversarial robustness of deep learning-based intrusion detection system,» *Computers & Security*, cilt 137.
- [50] **T. Arjunan**, «Real-Time Detection of Network Traffic Anomalies in Big Data Environments Using Deep Learning Models,» *International Journal for Research in Applied Science & Engineering Technology (IJRASET)*, cilt 12, no. 3, 2024.
- [51] **J. Z. Y. Y. Y. L. C. Y. Y. Li**, (2024) «Enhancing Network Intrusion Detection Through the Application of the Dung Beetle Optimized Fusion Model,» *IEEE Access*, cilt 12, pp. 9483-9496.

- [52] **S. U. G. S. J. C.-W. L. Farhan Ullah**, (2024) «IDS-INT: Intrusion detection system using transformer-based transfer learning for imbalanced network traffic,» *Digital Communications and Networks*, cilt 10, no. 1, pp. 190-204.
- [53] **A. E. M. Eljialy, M. Y. Uddin ve S. Ahmad**, (2024) «Novel Framework for an Intrusion Detection System Using Multiple Feature Selection Methods Based on Deep Learning,» *Tsinghua Science and Technology*, cilt 29, no. 4, pp. 948 - 958.
- [54] **M. L. Wong ve T. Arjunan**, (2024) «Real-Time Detection of Network Traffic Anomalies in Big Data Environments Using Deep Learning Models,» *Emerging Trends in Machine Intelligence and Big Data*, cilt 16, no. 2, pp. 1-11.
- [55] **H. Wang, J. Wu, C. Zhang, W. Lu ve C. Ni**, (2024) «Intelligent Security Detection and Defense in Operating Systems Based on Deep Learning,» *International Journal of Computer Science and Information Technology*, cilt 2, no. 1.
- [56] **S. Muneer, U. Farooq, A. Athar, M. A. Raza, T. M. Ghazal ve S. Sakib**, (2024) «A Critical Review of Artificial Intelligence Based Approaches in Intrusion Detection: A Comprehensive Analysis,» *Journal of Engineering*, cilt 2024.
- [57] **A. Biju ve S. W. Franklin**, (2023) «Evaluated bird swarm optimization based on deep belief network (EBSO-DBN) classification technique for IOT network intrusion detection,» *Automatika*, cilt 65, no. 1, pp. 108-116.
- [58] **Y. Lu, S. Chai, Y. Suo, F. Yao ve C. Zhang**, (2024) «Intrusion detection for Industrial Internet of Things based on deep learning,» *Neurocomputing*, cilt 564.
- [59] **Z. Long, G. Shen, X. Zhang ve L. Cheng**, (2024) «A Transformer-based network intrusion detection approach for cloud security,» *Journal of Cloud Computing*, cilt 13, no. 5.
- [60] **J. A. B. Angelin ve C. Priyadharsini**, (2024) «Deep Learning based Network based Intrusion Detection System in Industrial Internet of Things,» %1 içinde *2024 2nd International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT)*, Bengaluru, India.
- [61] **S. Ali, Q. Li ve A. Yousafzai**, «Blockchain and federated learning-based intrusion detection approaches for edge-enabled industrial IoT networks: a survey,» *Ad Hoc Networks*, cilt 152, no. 1, 2024.
- [62] **K. Kethineni ve G. Pradeepini**, (2024) «Intrusion detection in internet of things-based smart farming using hybrid deep learning framework,» *Cluster Comput*, cilt 27, p. 1719–1732.

- [63] **J. A. Alzubi, O. A. Alzubi, I. Qiqieh ve A. Singh,** (2024) «A Blended Deep Learning Intrusion Detection Framework for Consumable Edge-Centric IoMT Industry,» *IEEE Transactions on Consumer Electronics*, cilt 20, no. 1, pp. 2049-2057.
- [64] **U. K. Lilhore, S. Dalal ve S. Simaiya,** (2024) «A cognitive security framework for detecting intrusions in IoT and 5G utilizing deep learning,» *Computers & Security*, cilt 136.
- [65] **Z. Li, P. Wang ve Z. Wang,** (2024) «FlowGANAnomaly: Flow-Based Anomaly Network Intrusion Detection with Adversarial Learning,» *Chinese Journal of Electronics*, cilt 33, no. 1, pp. 58-71.
- [66] **S. M. S. Bukhari, M. H. Zafar, M. A. Houran, S. K. R. Moosavi, M. Mansoor, M. Muaaz ve F. Sanfilippo,** (2024) «Secure and privacy-preserving intrusion detection in wireless sensor networks: Federated learning with SCNN-Bi-LSTM for enhanced reliability,» *Ad Hoc Networks*, cilt 155.
- [67] **S. Ahmadi,** (2024) «Network Intrusion Detection in Cloud Environments: A Comparative Analysis of Approaches,» *International Journal of Advanced Computer Science and Applications(IJACSA)*, cilt 15, no. 3.
- [68] **G. S. R. E. Selvan, T. Daniya ve J. P. A. & K. S. Kumar,** (2024) «Network Intrusion Detection and Mitigation Using Hybrid Optimization Integrated Deep Q Network,» *Cybernetics and Systems*, cilt 55, no. 1, pp. 107-123.
- [69] **M. Soltani, K. Khajavi ve M. J. S. & A. H. Jahangir,** (2024) «A multi-agent adaptive deep learning framework for online intrusion detection,» *Cybersecurity*, cilt 7, no. 9.
- [70] **M. Alazab, R. A. Khurma, P. A. Castillo, B. Abu-Salih, A. Martín ve D. Camacho,** (2024) «An effective networks intrusion detection approach based on hybrid Harris Hawks and multi-layer perceptron,» *Egyptian Informatics Journal*, cilt 25.
- [71] **Z. Sun, G. An, Y. Yang ve Y. Liu,** (2024) «Optimized machine learning enabled intrusion detection 2 system for internet of medical things,» *Franklin Open*, cilt 6.
- [72] **R. Doriguzzi-Corin, L. A. D. Knob, L. Mendozzi, D. Siracusa ve M. Savi,** (2024) «Introducing packet-level analysis in programmable data planes to advance Network Intrusion Detection,» *Computer Networks*, cilt 239.

- [73] **H. Kim, S. Park, H. Hong, J. Park ve S. Kim**, (2024) «A Transferable Deep Learning Framework for Improving the Accuracy of Internet of Things Intrusion Detection,» *Future Internet*, cilt 16, no. 3.
- [74] **K. Shaheed, P. Szczuko, M. Kumar, I. Qureshi, Q. Abbas ve I. Ullah**, (2024) «Deep learning techniques for biometric security: A systematic review of presentation attack detection systems,» *Engineering Applications of Artificial Intelligence*, cilt 129.
- [75] **Y. Akhiat, K. Touchanti, A. Zinedine ve M. Chahhou**, (2024) «IDS-EFS: Ensemble feature selection-based method for intrusion detection system,» *Multimedia Tools and Applications*, cilt 83, pp. 12917-12937.
- [76] **Y. Gong, M. Zhu, S. Huo, Y. Xiang ve H. Yu**, (2024) «Utilizing Deep Learning for Enhancing Network Resilience in Finance,» %1 içinde *2024 7th International Conference on Advanced Algorithms and Control Engineering (ICAACE)*, Shanghai, China.
- [77] **P. Silva, G. Baye, A. Broggi, N. D. Bastian, G. Kul ve L. Fiondella**, (2024) «Predicting F1-Scores of Classifiers in Network Intrusion Detection Systems,» %1 içinde *2024 33rd International Conference on Computer Communications and Networks (ICCCN)*, Kailua-Kona, HI, USA.
- [78] **Y. Wu, B. Zou ve Y. Cao**, (2024) «Current Status and Challenges and Future Trends of Deep Learning-Based Intrusion Detection Models,» *Journal of Imaging*, cilt 10, no. 10.
- [79] **G. Baye, P. Silva, A. Broggi, L. Fiondella, N. Bastian ve G. Kul**, (2024) «An Evaluation of Open-Set Recognition-Enabled End-Layers on Deep-Learning Models in Network Intrusion Detection Systems,».
- [80] **Osvaldo Arreche; Tanish R. Guntur; Jack W. Roberts; Mustafa Abdallah**, (2024) «E-XAI: Evaluating Black-Box Explainable AI Frameworks for Network Intrusion Detection » *IEEE Access*, cilt 12, pp. 23954 - 23988.
- [81] **C. L. Cikambasi, L. M. Muriira ve R. M. Murungi**, (2024) «Deep Learning Network Intrusion Detection with the Conv1d-Lstm Model: Integrating CNN and LSTM For Superior Performance,» *International Journal of Professional Practice*, cilt 12, no. 4, pp. 41-49.
- [82] **N. Aslam, S. Srivastava ve M. M. Gore**, (2024) «A Comprehensive Analysis of Machine Learning- and Deep Learning-Based Solutions for DDoS Attack Detection in SDN,» *Arab J Sci Eng*, cilt 49, pp. 3533-3573.
- [83] **J. D. Yadav, V. K. Dwivedi ve S. Chaturvedi**, (2024) «Enhancing 6G network security: GANs for pilot contamination attack detection in massive MIMO

- systems,» *AEU - International Journal of Electronics and Communications*, cilt 175.
- [84] **E. U. H. Qazi, M. H. Faheem ve T. Zia**, (2023) «HDLNIDS: Hybrid Deep-Learning-Based Network Intrusion Detection System,» *Applied Sciences*, cilt 13, no. 8.
 - [85] **V. Hnamte, H. Nhung-Nguyen, J. Hussain ve Y. Hwa-Kim**, (2023) «A Novel Two-Stage Deep Learning Model for Network Intrusion Detection: LSTM-AE,» *IEEE Access*, cilt 11, pp. 37131-37148.
 - [86] **S. A. Bakhsh, M. A. Khan, F. Ahmed, M. S. Alshehri, H. Ali ve J. Ahmad**, (2023) «Enhancing IoT network security through deep learning-powered Intrusion Detection System,» *Internet of Things*, cilt 24.
 - [87] **H. Mohammadian, A. A. Ghorbani ve A. H. Lashkari**, (2023) «A gradient-based approach for adversarial attack on deep learning-based network intrusion detection systems,» *Applied Soft Computing*, cilt 137.
 - [88] **B. Sharma, L. Sharma, C. Lal ve S. Roy**, (2023) «Anomaly based network intrusion detection for IoT attacks using deep learning technique,» *Computers and Electrical Engineering*.
 - [89] **T. Yi, X. Chen, Y. Zhu, W. Ge ve Z. Han**, (2023) «Review on the application of deep learning in network attack detection,» *Journal of Network and Computer Applications*, cilt 212.
 - [90] **J. Du, K. Yang, Y. Hu ve L. Jiang**, (2023) «NIDS-CNNLSTM: Network Intrusion Detection Classification Model Based on Deep Learning,» *IEEE Access*, cilt 11, pp. 24808-24821.
 - [91] **V. Hnamte ve J. Hussain**, (2023) «DCNNBiLSTM: An Efficient Hybrid Deep Learning-Based Intrusion Detection System,» *Telematics and Informatics Reports*, cilt 10.
 - [92] **S. Mohamed ve R. Ejwali**, «Deep SARSA-based reinforcement learning approach for anomaly network intrusion detection system,» *International Journal of Information Security*, cilt 22, pp. 235-247, 2023.
 - [93] **A. Rathee, P. Malik ve M. K. Parida**, (2023) «Network Intrusion Detection System using Deep Learning Techniques,» %1 içinde *2023 International Conference on Communication, Circuits, and Systems (IC3S)*, BHUBANESWAR, India.

- [94] **M. B. Umair, Z. Iqbal, M. A. Faraz, M. A. Khan, Y.-D. Zhang, N. Razmjooy ve S. Kadry**, (2022) «A Network Intrusion Detection System Using Hybrid Multilayer Deep Learning Model,» *Big Data*, cilt 0, no. 0.
- [95] **F. Wei, H. Li, Z. Zhao ve H. Hu**, (2023) «xNIDS: Explaining Deep Learning-based Network Intrusion Detection Systems for Active Intrusion Responses,» %1 içinde *32nd USENIX Security Symposium*, Anaheim, CA, USA.
- [96] **R. Chaganti, W. Suliman, V. Ravi ve A. Dua**, (2023) «Deep Learning Approach for SDN-Enabled Intrusion Detection System in IoT Networks,» *Information*, cilt 14, no. 1.
- [97] **J. Li, X. Tong, J. Liu ve L. Cheng**, (2023) «An Efficient Federated Learning System for Network Intrusion Detection,» *IEEE Systems Journal*, cilt 17, no. 2, pp. 2455-2464.
- [98] **S. Shafieian ve M. Zulkernine**, (2023) «Multi-layer stacking ensemble learners for low footprint network intrusion detection,» *Complex & Intelligent Systems*, cilt 9, pp. 3787-3799.
- [99] **Y. Vural**, (2007) «Kurumsal bilgi güvenliği ve sızma (penetrasyon) testleri,» %1 içinde *Master's thesis*, Fen Bilimleri Enstitüsü.
- [100] **G. Canbek ve Ş. Sağiroğlu**, (2006) «Bilgi, bilgi güvenliği ve süreçleri üzerine bir inceleme,» *Politeknik Dergisi*, cilt 9, no. 3, pp. 165-174.
- [101] **D. E. Rumelhart, G. E. Hinton ve R. J. Williams**, (1986) «Learning representations by back-propagating errors,» *Nature*, cilt 323, no. 6088, pp. 533-536.
- [102] **W. Wang, Y. Sheng, J. Wang, X. Zeng, X. Ye ve Y. Huang**, (2018) «HAST-IDS: Learning Hierarchical Spatial-Temporal Features Using Deep Neural Networks to Improve Intrusion Detection,» *IEEE Access*, cilt 6, pp. 1792 - 1806.
- [103] **J. L. Elman**, (1990) «Finding Structure in Time,» *Cognitive Science*, cilt 14, no. 2, pp. 179-211.
- [104] **G. Karataş**, (2020) *Derin Öğrenme Tabanlı Saldırı Tespit Sistemi*, İstanbul: Marmara Üniversitesi Fen Bilimleri Enstitüsü.
- [105] **N. Moustafa ve J. Slay**, (2015) «UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set),» %1 içinde *2015 Military Communications and Information Systems Conference (MilCIS)*, Canberra, ACT, Australia.

- [106] **A. Thakkar ve R. Lohiya**, (2020) «A Review of the Advancement in Intrusion Detection Datasets,» *Procedia Computer Science*, cilt 167, pp. 636-645.

